



**UNIVERSIDAD
DE GRANADA**

TRABAJO FIN DE GRADO

INGENIERÍA DE TECNOLOGÍAS DE TELECOMUNICACIÓN

**Inteligencia Artificial Explicativa (XAI) : Métodos y Prueba
de Concepto**

Autor

Adrián Macías Caballero

Director

José Camacho Páez



**ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN**

—
Granada, Junio de 2026



Inteligencia Artificial Explicativa (XAI) : Métodos y Prueba de Concepto

Autor

Adrián Macías Caballero

Director

José Camacho Páez

Inteligencia Artificial Explicativa (XAI) : Métodos y Prueba de Concepto

Adrián Macías Caballero

Resumen

El presente Trabajo Fin de Grado aborda el estudio de la Inteligencia Artificial Explicativa, conocida como XAI (*Explainable Artificial Intelligence*), con el objetivo de analizar la importancia de la interpretabilidad en los modelos actuales de inteligencia artificial. En los últimos años, los modelos de aprendizaje profundo han alcanzado un gran rendimiento en tareas complejas, especialmente en procesamiento del lenguaje natural, visión por computador y sistemas de clasificación. Sin embargo, este avance ha venido acompañado de una pérdida de transparencia, ya que muchos de estos modelos funcionan como sistemas de caja negra, ofreciendo predicciones precisas pero difíciles de comprender desde el punto de vista humano.

El trabajo se estructura en dos partes principales. En primer lugar, se realiza una revisión teórica de los modelos de inteligencia artificial, diferenciando entre técnicas tradicionales de *Machine Learning*, modelos de aprendizaje profundo y arquitecturas modernas basadas en *Transformers*. Posteriormente, se profundiza en el campo de la XAI, analizando distintos enfoques de explicabilidad relacionados con los datos, los modelos y las técnicas *post-hoc*. Dentro de este marco, se estudian métodos de atribución, visualización, explicaciones basadas en ejemplos, teoría de juegos, extracción de conocimiento y técnicas específicas para modelos neuronales y *Transformers*.

En la parte práctica del trabajo se desarrolla una prueba de concepto basada en el análisis explicativo de un modelo BERT aplicado a una tarea de clasificación de sentimiento. Para ello, se utiliza un modelo BERT previamente entrenado para clasificar frases como positivas o negativas. El objetivo no es entrenar un nuevo modelo, sino analizar su comportamiento interno a partir de los mapas de atención generados durante el procesamiento de distintas frases. Posteriormente, esta información se ha analizado mediante PCA, oMEDA, SHAP, PLS-DA y ASCA para estudiar datos multivariantes y comprobar si existen diferencias entre los patrones de atención de las frases positivas y negativas.

En conjunto, el estudio muestra que los mapas de atención, junto con PCA, oMEDA, SHAP, PLS-DA y ASCA pueden ser herramientas útiles para explorar el comportamiento interno de BERT. Este trabajo presenta por primera vez la aplicación de algunas de estas herramientas, en particular oMEDA, PLS-DA y ASCA, en el dominio xAI. El uso de ASCA, además, abre la puerta al desarrollo de esquemas de interpretación más desarrollados.

Explainable Artificial Intelligence (XAI): Methods and Proof of Concept

Adrián Macías Caballero

Abstract

This Final Degree Project addresses the study of Explainable Artificial Intelligence, known as XAI, with the aim of analysing the importance of interpretability in current artificial intelligence models. In recent years, deep learning models have achieved strong performance in complex tasks, especially in natural language processing, computer vision and classification systems. However, this progress has been accompanied by a loss of transparency, since many of these models operate as black-box systems, offering accurate predictions but making them difficult to understand from a human point of view.

The work is structured into two main parts. First, a theoretical review of artificial intelligence models is carried out, distinguishing between traditional Machine Learning techniques, deep learning models and modern architectures based on Transformers. Subsequently, the field of XAI is explored in greater depth, analysing different approaches to explainability related to data, models and post-hoc techniques. Within this framework, attribution methods, visualisation techniques, example-based explanations, game theory, knowledge extraction and specific techniques for neural models and Transformers are studied.

In the practical part of the work, a proof of concept is developed based on the explanatory analysis of a BERT model applied to a sentiment classification task. For this purpose, a previously fine-tuned BERT model is used to classify sentences as positive or negative. The aim is not to train a new model, but to analyse its internal behaviour from the attention maps generated during the processing of different sentences. Subsequently, this information is analysed using PCA, oMEDA, SHAP, PLS-DA and ASCA to study multivariate data and check whether there are differences between the attention patterns of positive and negative sentences.

Overall, the study shows that attention maps, together with PCA, oMEDA, SHAP, PLS-DA and ASCA can be useful tools for exploring the internal behaviour of BERT. This project presents, for the first time, the application of some of these tools—specifically oMEDA, PLS-DA, and ASCA—in the xAI domain. Furthermore, the use of ASCA opens the door to the development of more advanced interpretation frameworks.

Yo, **Adrián Macias Caballero**, alumno de la titulación Grado en Ingeniería de tecnologías de telecomunicación de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 71355449-L, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: Adrián Macias Caballero

Granada a 11 de Junio de 2026.

D. **José Camacho Páez**, Profesor del Área de Telemática del Departamento de Teoría de la señal, Telemática y Comunicaciones de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado ***Inteligencia Artificial Explicativa (XAI) : Métodos y Prueba de Concepto***, ha sido realizado bajo su supervisión por **Adrián Macías Caballero**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a 11 de Junio de 2026 .

El director:

José Camacho Páez

Agradecimientos

Quiero dedicar estas líneas de una forma especial y de una manera sentimental a todas aquellas personas que me han acompañado en esta etapa tan bonita y especial de mi **vida** y han conseguido llevarme en volandas a finalizarla de la mejor manera que uno puede imaginar.

En primer lugar, agradecer a mi **tutor** José Camacho, aunque me gustaría hacerlo de manera que le pueda dar las gracias a mi amigo Pepe, porque para mí has significado mucho más que un simple tutor. Gracias por llevarme de tu mano desde el primer día en Septiembre cuando te propuse realizar este proyecto de manera conjunta, muchas gracias por tu organización y tu gestión del trabajo de una forma que no podía ser más acorde a lo que yo deseaba. Muchas gracias por tu continua disponibilidad y por tu eterna paciencia conmigo, por tus explicaciones en la pizarra del despacho y sobre todo por tu confianza en mí, la cual me ha dado más fuerza y tranquilidad de la que te puedas imaginar. Gracias por hacerme descubrir un mundo paralelo a las telecomunicaciones, por tu experiencia, conocimientos y por la oportunidad de aprender del presente y sobre todo, del futuro. Te admiro Pepe.

En segundo lugar, quiero agradecer a mis **amigos de clase**, con los cuales he tenido la gran suerte de compartir sufrimiento, desesperación, trabajo y momentos de agonía, pero también de compartir risas, alegría, experiencias y la felicidad de poder disfrutar hasta en los malos momentos, simplemente por estar unidos. Quiero acordarme de Guillermo y Miguel, con los que he compartido momentos que solo nosotros podemos entender y recordar con demasiada añoranza a estas alturas. También hacerlo de mis últimos y grandes descubrimientos en este último año como Daniel y Alejandra, así como de todo el gran grupo que hemos formado, sois el tipo de personas que se quedan para siempre y la verdadera recompensa que me llevo de esta carrera, más importante que un simple título. Y por último, de una manera especial, a Paula, la única persona que me ha acompañado de una forma u otra desde el primer día hasta el último, gracias por haber sido una de mis referentes dentro y fuera de clase, gracias por ser tan buena en todo lo que haces y haber podido tener a alguien que me inspiraba tanto a superarme como a tener la mejor versión de mí mismo. Muchas gracias porque esta etapa no hubiera sido lo mismo sin vosotros.

También acordarme y agradecer a mis **compañeros de piso y amigos**, Alejandro y Javier, por aguantarme en mis momentos de agobio y desesperación, así como de animarme, sacarme una sonrisa y haber hecho que haya podido disfrutar de esta etapa universitaria acompañado de personas que son la definición de familia elegida.

Finalmente, como no podía ser de otra manera, agradecer a mi **familia**. Gracias a ti, **papá**, por ser la persona a la que espero llegar a parecerme en algún momento, gracias por ser mi mayor ídolo e inculcarme el valor del trabajo y del esfuerzo de una manera que nadie podría entender. Gracias a ti, **mamá**, por ser mi luz y guía en este sendero tan largo que es la vida y por tu eterno apoyo y amor. Y gracias a ti, **Noelia**, porque me obligas cada día a ser mejor persona y mejor hermano, porque haces que esté en constante evolución para poder darle a mi hermana pequeña el mejor ejemplo a seguir y, cómo no, siempre de mi mano, pequeña.

Índice general

Agradecimientos	11
1. Introducción	13
1.1. Motivación	13
1.2. Objetivos del trabajo	15
1.3. Estructura de la memoria	16
1.4. Uso de IA Generativa	17
2. Modelos de Inteligencia Artificial	19
2.1. Tipos de Modelos (Machine Learning Tradicional)	21
2.1.1. Aprendizaje No Supervisado	21
2.1.1.1. Clustering	21
2.1.1.2. Auto-Encoding Model (AE)	23
2.1.2. Aprendizaje Supervisado	24
2.1.2.1. Árboles De Decisión (Decision Tree)	24
2.1.2.2. Regresión Convencional	25
2.1.2.3. Máquinas de Vectores de Soporte (SVM)	27
2.1.2.4. Clasificador del Vecino más Cercano (K-NN)	27
2.1.3. Aprendizaje Por Refuerzo	28
2.1.3.1. Crítico Heurístico Adaptativo (AHC)	28
2.1.3.2. Q-Learning	29
2.2. Modelos de Aprendizaje Profundo	29
2.2.1. Aprendizaje Autosupervisado	30
2.2.1.1. Auto-Regressive Model (AR)	31
2.2.1.2. Transformers	31
2.2.2. Red Neuronal Recurrente (RNN)	32
2.2.3. Red Neuronal de Memoria a Largo Plazo (LSTM)	33
2.2.4. Gated Recurrent Unit (GRU)	33
2.2.5. Red Neuronal Convolutiva (CNN)	34
2.2.6. Red Generativa Antagónica (GAN)	35
2.2.7. Red Neuronal Probabilística Profunda (DPNN)	35
2.2.8. Transformers	36

3. XAI: Inteligencia Artificial Explicativa	41
3.1. Explicabilidad de los Datos	43
3.1.1. Análisis Exploratorio de Datos	43
3.1.2. Ingeniería de características explicable	44
3.1.3. Estandarización en la descripción de conjuntos de datos	44
3.1.4. Metodologías para la síntesis de conjuntos de datos	45
3.1.5. Grafos de conocimiento	45
3.1.6. Redes neuronales informadas por la física	46
3.2. Explicabilidad del Modelo	47
3.2.1. Familia de modelos intrínsecamente interpretables	48
3.2.2. Modelos híbridos explicables	48
3.2.3. Predicción y explicables conjuntas	50
3.2.4. Explicabilidad mediante ajustes arquitectónicos	51
3.2.5. Explicabilidad mediante regularización	53
3.3. Post-Hoc Explainability	54
3.3.1. Métodos de atribución	54
3.3.1.1. Deep Taylor Descomposition (DTD)	55
3.3.1.2. Métodos de Perturbación	55
3.3.1.3. Métodos de Retropropagación (Backpropagation Methods)	56
3.3.1.4. Deep LIFT (Deep Learning Important Features)	57
3.3.2. Métodos de Visualización	57
3.3.2.1. Gráfico de Dependencia Parcial (PDP)	57
3.3.2.2. Expectativas Condicionales Individuales (ICE)	58
3.3.2.3. Efectos Locales Acumulados (ALE)	59
3.3.3. Métodos de explicación basados en ejemplos	60
3.3.3.1. Prototipos y Críticas	60
3.3.3.2. Contrafactuales	61
3.3.3.3. Ejemplos adversarios	61
3.3.4. Métodos basados en teoría de juegos	62
3.3.4.1. Shapley Additive Explanations (SHAP)	63
3.3.5. Métodos de extracción de conocimiento	64
3.3.5.1. Extracción de reglas (Rule Extraction)	64
3.3.5.2. Destilación de modelos (Model Distillation)	65
3.4. Métodos neuronales (Neural Methods)	65
3.4.1. Métodos de influencia	65
3.4.2. Métodos basados en conceptos	66
3.5. XAI Transformer	67
3.5.1. Enfoques previos para la explicabilidad de Transformers	68
3.5.2. Perspectiva teórica sobre la explicabilidad en Transformers	68
3.5.2.1. Propagación en las cabezas de atención	69
3.5.2.2. Normalización por capa	69

3.5.3.	Nuevas reglas de propagación LRP para Transformers	70
3.5.3.1.	Regla de propagación para las cabezas de atención	70
3.5.3.2.	Regla de propagación para LayerNorm	71
4.	Planificación y Estimación de Costes	73
4.1.	Planificación temporal	73
4.2.	Fases del proyecto	73
4.2.1.	Estudio de modelos de inteligencia artificial	73
4.2.2.	Estudio de la Inteligencia Artificial Explicativa	74
4.2.3.	Definición de materiales y métodos	74
4.2.4.	Diseño de pruebas	75
4.2.5.	Análisis de resultados	75
4.2.6.	Redacción y revisión de la memoria	75
4.2.7.	Preparación de la presentación	75
4.3.	Diagrama de Gantt	76
4.4.	Resumen de la planificación	77
4.5.	Estimación de recursos	78
4.5.1.	Recursos humanos	78
4.5.2.	Recursos hardware	78
4.5.3.	Recursos software	79
4.6.	Coste total estimado	79
4.7.	Conclusión de la planificación	80
5.	Materiales y Métodos	81
5.1.	Caso de estudio: análisis explicativo de BERT mediante mapas de atención, PCA , oMEDA, SHAP, PLS-DA y ASCA	81
5.1.1.	Transformers y modelo BERT	81
5.1.2.	Modelo utilizado y tarea de clasificación de sentimiento	85
5.1.3.	Análisis de Componentes Principales	86
5.1.4.	oMEDA como herramienta de interpretación de variables	87
5.1.5.	SHAP como método de comparación explicativa	88
5.1.6.	PLS-DA como método supervisado de comparación	89
5.1.7.	ASCA como método exploratorio multivariante	90
6.	Análisis individualizado por frase	93
6.1.	Análisis de los mecanismos de atención en BERT	93
6.1.1.	Metodología	93
6.1.2.	Visualización de mapas de atención	93
6.1.3.	Interpretación de los mapas de atención	96
6.1.4.	Evolución del comportamiento de las cabezas	97
6.1.5.	Clasificación funcional de las cabezas de atención	97
6.1.6.	Discusión	97
6.1.7.	Conclusión	98

7. Diseño de Pruebas Multifrase	99
7.1. Extracción de mapas de atención	99
7.2. Conjunto experimental de frases	100
7.2.1. Aplicación del Análisis de Componentes Principales . .	100
7.3. Aplicación de oMEDA mediante la MEDA Toolbox	101
7.4. Análisis de importancia de variables	102
7.5. Agrupación de la importancia por capas y cabezas	103
7.6. Flujo de trabajo en Python y MATLAB	103
7.6.1. Interpretación general del análisis	105
7.7. Limitaciones del estudio	106
7.8. Aplicación de SHAP sobre el modelo BERT	107
7.9. Implementación del análisis PLS-DA	108
7.10. Implementación del análisis ASCA	110
8. Análisis de Resultados	113
8.1. Análisis de resultados	113
8.2. Comparación explicativa mediante SHAP	114
8.2.1. Importancia relativa por token mediante SHAP	117
8.3. Análisis de la varianza explicada mediante PCA	118
8.3.1. Representación de las observaciones en el espacio PCA	119
8.4. Análisis global del vector oMEDA	122
8.4.1. Distribución de la importancia de las variables	123
8.4.2. Importancia acumulada por capas	124
8.4.3. Importancia por capa y cabeza de atención	125
8.4.4. Importancia relativa por token mediante oMEDA . . .	127
8.4.5. Importancia global de tokens mediante oMEDA-PCA .	128
8.4.6. Relación entre PCA y oMEDA	129
8.5. Análisis mediante PLS-DA y comparación con oMEDA	130
8.5.1. Selección del número de componentes	130
8.5.2. Varianza residual de la variable de clase en PLS-DA .	131
8.5.3. Representación de las observaciones en el espacio PLS-DA	133
8.5.4. Predicción continua y matriz de confusión	133
8.5.5. Distribución de importancia de variables	135
8.5.6. Importancia por capas y cabezas de atención	135
8.5.7. Comparación entre oMEDA y PLS-DA	137
8.5.8. Importancia relativa por token mediante PLS-DA . . .	140
8.5.9. Importancia global de tokens mediante PLS-DA	142
8.6. Análisis mediante ASCA	143
8.6.1. Representación del efecto de clase	143
8.6.2. Análisis de importancia mediante ASCA	145
8.6.3. Importancia por token origen	145
8.6.4. Importancia por token destino	146
8.6.5. Importancia por cabezas de atención	147

8.6.6. Importancia por capa	148
8.6.7. Importancia por capa y cabeza de atención	149
8.6.8. Importancia combinada por posición de token	150
8.6.9. Importancia ASCA por pares de tokens	151
8.6.10. Importancia global de tokens mediante ASCA	153
8.7. Comparación conjunta entre oMEDA, PLS-DA, ASCA y SHAP	154
8.7.1. Comparación de la importancia por capas	154
8.7.2. Comparación de la importancia por capa y cabeza de atención	156
8.7.3. Comparación global de importancia por tokens	158
8.7.4. Interpretación conjunta	161
8.8. Conclusiones del análisis	162
9. Conclusiones y líneas de trabajo futuro	169
9.1. Conclusiones	169
9.2. Líneas de trabajo futuro	174
9.3. Valoración de una línea futura propuesta	176
A. Frases utilizadas en el conjunto experimental	179
Bibliografía	182

Índice de figuras

3.1. Mapas de atención obtenidos a partir del análisis interno del modelo BERT.	52
3.2. Ejemplo de gráficos de dependencia parcial unidimensionales y bidimensionales. La figura muestra cómo varía la predicción media del modelo en función de distintas características de entrada. Fuente: documentación de Scikit-learn.	58
3.3. Ejemplo de gráficos ICE junto con la curva promedio de dependencia parcial. Cada línea representa el comportamiento individual de una muestra al variar una característica de entrada. Fuente: documentación de Scikit-learn.	59
4.1. Diagrama de Gantt correspondiente a la planificación temporal del Trabajo Fin de Grado.	76
5.1. Visualización general de la arquitectura BERT-base obtenida en MATLAB. La red está formada por una etapa inicial de <i>embedding</i> y una sucesión de 12 bloques codificadores <i>Transformer</i>	83
5.2. Detalle de la capa inicial del modelo BERT-base visualizada en MATLAB. Se observa la estructura repetida de los bloques codificadores correspondientes a la capa inicial del modelo. . .	84
5.3. Mapas de atención obtenidos a partir del análisis interno del modelo BERT.	85
6.1. Mapas de atención correspondientes a las capas 0–7 del modelo BERT. Cada subfigura representa una capa completa e incluye sus 12 cabezas de atención.	95
6.2. Mapas de atención correspondientes a las capas 8–11 del modelo BERT. Cada subfigura representa una capa completa e incluye sus 12 cabezas de atención.	96
7.1. Representación de las observaciones en el plano formado por PC1 y PC2.	111

8.1. Explicación SHAP para una frase clasificada como positiva por el modelo BERT.	114
8.2. Explicación SHAP para una frase clasificada como negativa por el modelo BERT.	115
8.3. Tokens con mayor importancia global según SHAP en el conjunto experimental.	116
8.4. Importancia relativa por posición de token obtenida mediante SHAP.	117
8.5. Varianza explicada por cada componente principal del modelo PCA.	118
8.6. Varianza explicada acumulada en función del número de componentes principales.	119
8.7. Representación de las observaciones en el plano formado por PC1 y PC2.	120
8.8. Representación de las observaciones en el plano formado por PC1 y PC3.	121
8.9. Vector oMEDA obtenido al comparar frases positivas frente a frases negativas.	122
8.10. Distribución de la importancia absoluta de las 9216 variables de atención.	123
8.11. Importancia acumulada por capa del modelo BERT.	124
8.12. Mapa de importancia acumulada por capa y cabeza de atención.	126
8.13. Importancia relativa por posición de token obtenida mediante oMEDA.	127
8.14. Tokens más importantes según oMEDA-PCA en el conjunto experimental.	128
8.15. Selección del número de componentes en PLS-DA mediante validación cruzada.	131
8.16. Evolución de la varianza residual de la variable de clase en función del número de variables latentes del modelo PLS-DA.	132
8.17. Representación de las observaciones en el espacio PLS-DA formado por LV1 y LV2.	133
8.18. Predicción continua del modelo PLS-DA para las 40 frases del conjunto experimental.	134
8.19. Matriz de confusión obtenida mediante PLS-DA.	134
8.20. Distribución de la importancia de variables en PLS-DA a partir de los coeficientes del modelo.	135
8.21. Importancia acumulada por capa obtenida mediante los coeficientes del modelo PLS-DA.	136
8.22. Importancia acumulada por capa y cabeza de atención obtenida mediante PLS-DA.	137
8.23. Comparación de la importancia normalizada por capas obtenida mediante oMEDA y PLS-DA utilizando la MEDA Toolbox.	138

8.24. Comparación variable a variable entre la importancia obtenida mediante oMEDA y PLS-DA.	139
8.25. Importancia relativa por posición de token obtenida mediante los coeficientes del modelo PLS-DA.	140
8.26. Tokens más importantes según PLS-DA en el conjunto experimental.	142
8.27. Representación de scores asociada al Factor 1 del modelo ASCA, correspondiente al efecto de clase positiva o negativa. . .	144
8.28. Distribución de la importancia ASCA de las variables de atención.	145
8.29. Importancia relativa ASCA por token origen.	146
8.30. Importancia relativa ASCA por token destino.	147
8.31. Importancia relativa acumulada por cabeza de atención obtenida mediante ASCA.	148
8.32. Importancia relativa por capa obtenida mediante ASCA. . . .	149
8.33. Mapa de importancia ASCA agrupada por capa y cabeza de atención.	150
8.34. Importancia relativa por posición de token obtenida mediante ASCA, considerando el token como origen, como destino y de forma combinada.	151
8.35. Mapa de importancia ASCA acumulada por pares de tokens. . .	152
8.36. Tokens más importantes según ASCA en el conjunto experimental.	153
8.37. Comparación de la importancia por capas.	155
8.38. Comparación de la importancia por capa y cabeza de atención mediante oMEDA, PLS-DA y ASCA.	157
8.39. Comparación global de los tokens más importantes mediante SHAP y oMEDA-PCA.	159
8.40. Comparación global de los tokens más importantes mediante PLS-DA y ASCA.	160

Índice de cuadros

3.1. Clasificación de los sistemas de inteligencia artificial según el nivel de riesgo en el AI Act de la Unión Europea.	42
4.1. Resumen de la planificación temporal del Trabajo Fin de Grado.	77
4.2. Estimación de costes asociados a recursos humanos.	78
4.3. Estimación de costes asociados a recursos hardware.	79
4.4. Estimación de costes asociados a recursos software.	79
4.5. Coste total estimado del Trabajo Fin de Grado.	80
6.1. Clasificación funcional de las cabezas de atención	98
A.1. Frases positivas y negativas utilizadas en el conjunto experimental.	179

Capítulo 1

Introducción

1.1. Motivación

En los últimos años, la inteligencia artificial ha experimentado un crecimiento extraordinario, impulsado principalmente por el desarrollo de modelos de aprendizaje profundo capaces de resolver tareas cada vez más complejas. Estos modelos se emplean actualmente en ámbitos muy diversos, como el procesamiento del lenguaje natural, la visión por computador, la medicina, la ingeniería, la industria o los sistemas de recomendación. Sin embargo, este aumento en capacidad predictiva sumado a un gran incremento en el número de parámetros ha venido acompañado de una pérdida progresiva de interpretabilidad.

Otra de las motivaciones principales que han impulsado la realización de este trabajo ha sido el propio proceso de aprendizaje que ha supuesto enfrentarse a un ámbito prácticamente desconocido desde el inicio. El proyecto ha partido de una base inicial donde el estudiante contaba con un conocimiento muy limitado en relación con la Inteligencia Artificial y mucho menos con la Inteligencia Artificial Explicativa, los modelos *Transformer* y las técnicas de análisis multivariante aplicadas a representaciones internas de modelos de lenguaje, realizándose así un trabajo previo mucho más intenso acompañado de una gran y rápida capacidad de aprendizaje en un ámbito totalmente desconocido para finalmente poder llegar a realizar un trabajo nunca antes efectuado como es la aplicación de algunas herramientas, en particular oMEDA, PLS-DA y ASCA, en el dominio xAI. Sin embargo, el desarrollo progresivo del trabajo ha permitido adquirir una comprensión cada vez más profunda de estos conceptos, pasando de una primera aproximación teórica a la construcción de una metodología práctica de análisis. Este recorrido ha sido especialmente enriquecedor, no solo por el conocimiento técnico adquirido, sino también por la posibilidad de explorar enfoques poco habituales

en este contexto. De esta forma, el trabajo no se limita a aplicar técnicas conocidas, sino que abre la puerta a nuevas líneas de estudio relacionadas con el uso de métodos multivariantes y explicativos para analizar el comportamiento interno de modelos BERT, planteando caminos que pueden ser desarrollados en futuras investigaciones.

Muchos de los modelos más avanzados, especialmente las redes neuronales profundas y las arquitecturas basadas en *Transformers*, funcionan habitualmente como sistemas de caja negra. Es decir, **son capaces de generar predicciones precisas, pero resulta difícil comprender de forma directa qué información utilizan, cómo la procesan internamente y qué elementos de la entrada influyen realmente en la decisión final**. Esta falta de transparencia puede suponer un problema importante cuando los sistemas de inteligencia artificial se aplican en contextos donde la confianza, la seguridad, la trazabilidad y la responsabilidad son factores esenciales.

En este contexto surge la Inteligencia Artificial Explicativa, conocida como XAI (*Explainable Artificial Intelligence*), cuyo objetivo es desarrollar métodos que permitan comprender, interpretar y justificar el comportamiento de los modelos de inteligencia artificial. La XAI no pretende únicamente obtener modelos más precisos, sino también modelos más transparentes, auditables y comprensibles para los usuarios, investigadores y desarrolladores.

La necesidad de explicabilidad resulta especialmente relevante en los modelos de lenguaje actuales. Arquitecturas como BERT han demostrado un gran rendimiento en tareas de procesamiento del lenguaje natural, entre ellas la clasificación de sentimiento. No obstante, su funcionamiento interno se basa en la repetición, poco justificada desde un conocimiento profundo de la ciencia de datos, de múltiples capas, cabezas de atención y representaciones distribuidas, lo que dificulta interpretar de forma directa cómo se construye una predicción. En particular, aunque los mecanismos de atención proporcionan una primera aproximación visual al comportamiento del modelo, no siempre pueden interpretarse como una explicación completa de la decisión tomada.

La motivación principal de este Trabajo Fin de Grado es estudiar la explicabilidad de este tipo de modelos desde una doble perspectiva. En primer lugar, se realiza una revisión de los principales conceptos, métodos y familias de técnicas asociadas a la XAI. En segundo lugar, se desarrolla una prueba de concepto centrada en el análisis de un modelo BERT aplicado a clasificación de sentimiento. Para ello, se extraen mapas de atención de distintas frases y se analizan mediante técnicas de reducción de dimensionalidad y análisis multivariante, concretamente PCA, oMEDA, SHAP, PLS-DA y ASCA.

De esta forma, el trabajo busca conectar la parte teórica de la Inteligencia Artificial Explicativa con un caso práctico concreto. El estudio no se limita a observar si el modelo clasifica una frase como positiva o negativa, sino

que pretende analizar qué ocurre internamente durante ese proceso, cómo se distribuye la atención entre los tokens y qué capas o cabezas parecen tener una mayor contribución en la diferenciación entre frases positivas y negativas.

1.2. Objetivos del trabajo

El objetivo general de este Trabajo Fin de Grado es estudiar la Inteligencia Artificial Explicativa y aplicar sus principios al análisis de un modelo BERT utilizado en una tarea de clasificación de sentimiento.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- Presentar una introducción general a los modelos de inteligencia artificial, diferenciando entre modelos tradicionales de *Machine Learning* y modelos de aprendizaje profundo.
- Analizar el papel de la explicabilidad dentro de los sistemas de inteligencia artificial, prestando atención a la explicabilidad de los datos, del modelo y de los métodos *post-hoc*.
- Estudiar los principales métodos de XAI aplicados a modelos complejos, incluyendo técnicas de atribución, visualización, explicaciones basadas en ejemplos, teoría de juegos, extracción de conocimiento y métodos neuronales.
- Profundizar en la explicabilidad de modelos *Transformer*, prestando especial atención a los mecanismos de atención, sus limitaciones interpretativas y las técnicas orientadas a mejorar la propagación de relevancia en este tipo de arquitecturas.
- Utilizar un modelo BERT previamente entrenado para clasificación binaria de sentimiento, concretamente `textattack/bert-base-uncased-SST-2`, como base para una prueba de concepto explicativa.
- Construir un conjunto experimental equilibrado de frases positivas y negativas que permita analizar el comportamiento del modelo ante entradas controladas.
- Extraer las matrices y mapas de atención generados por BERT en sus distintas capas y cabezas, con el fin de visualizar cómo se relacionan los tokens de entrada durante el procesamiento interno del modelo.
- Transformar los mapas de atención en una matriz de datos adecuada para aplicar técnicas de análisis multivariante.

- Aplicar Análisis de Componentes Principales (PCA) para estudiar la estructura global de las observaciones y analizar si existen patrones diferenciados entre frases positivas y negativas.
- Implementar una versión manual de oMEDA en MATLAB para identificar qué variables de atención, capas y cabezas contribuyen en mayor medida a las diferencias observadas entre ambos grupos de frases.
- Extraer conclusiones sobre la utilidad y las limitaciones de combinar mapas de atención, PCA, oMEDA y SHAP como herramientas exploratorias para el análisis explicativo de modelos BERT.
- Presentar por primera vez la aplicación de algunas de estas herramientas, en particular oMEDA, PLS-DA y ASCA, en el dominio xAI.

1.3. Estructura de la memoria

Para facilitar la lectura y comprensión del trabajo, la memoria se ha organizado en los siguientes capítulos:

Capítulo 2. Modelos de Inteligencia Artificial. En este capítulo se introducen los conceptos fundamentales de la inteligencia artificial y se presentan los principales tipos de modelos utilizados en aprendizaje automático. Se describen modelos de *Machine Learning* tradicional, como el aprendizaje supervisado, no supervisado y por refuerzo, así como modelos de aprendizaje profundo, incluyendo redes recurrentes, convolucionales, generativas y arquitecturas basadas en *Transformers*.

Capítulo 3. XAI: Inteligencia Artificial Explicativa. Este capítulo constituye el núcleo teórico del trabajo. En él se analiza la necesidad de la explicabilidad en inteligencia artificial y se presentan las principales familias de métodos XAI. Se estudian técnicas relacionadas con la explicabilidad de los datos, la explicabilidad del modelo y la explicabilidad *post-hoc*. Además, se dedica una sección específica a la explicabilidad en modelos *Transformer*, abordando tanto los enfoques basados en atención como sus limitaciones.

Capítulo 4. Planificación y Estimación de Costes. En este capítulo se recoge la planificación seguida durante el desarrollo del trabajo, así como una estimación de los recursos necesarios. Se consideran aspectos temporales, recursos humanos, hardware y software, con el objetivo de ofrecer una visión organizada del proceso de desarrollo del proyecto.

Capítulo 5. Materiales y Métodos. Este capítulo presenta los elementos utilizados en la prueba de concepto. Se describe el modelo BERT empleado, la tarea de clasificación de sentimiento, las herramientas utilizadas para la extracción de mapas de atención y las técnicas de análisis multivariante apli-

cadass. También se introducen PCA, oMEDA, SHAP, PLS-DA y ASCA como métodos empleados para estudiar la estructura de los datos y la relevancia de las variables de atención.

Capítulo 6. Análisis individualizado por frase. En este capítulo se analiza el comportamiento interno de BERT a partir de una frase concreta. Para ello, se estudian los mapas de atención generados en las distintas capas y cabezas del modelo, observando cómo se relacionan los tokens de entrada durante el proceso de clasificación. Este análisis individual sirve como primera aproximación visual antes de abordar el estudio multifrase y multivariante de los capítulos posteriores.

Capítulo 7. Diseño de Pruebas Multifrase. En este capítulo se detalla el procedimiento experimental seguido. Se explica cómo se construye el conjunto de frases, cómo se tokenizan las entradas, cómo se extraen las matrices de atención y cómo se transforman en una matriz numérica de alta dimensión. Además, se describe el flujo de trabajo seguido entre Python y MATLAB, así como la metodología empleada para aplicar PCA, oMEDA, SHAP, PLS-DA y ASCA.

Capítulo 8. Análisis de Resultados. En este capítulo se presentan y discuten los resultados obtenidos. Primero se analizan los resultados del PCA, incluyendo la varianza explicada y la representación de las observaciones en el espacio de componentes principales. Posteriormente, se estudian los resultados de oMEDA, analizando la importancia de las variables, la contribución acumulada y la distribución de relevancia por capas y cabezas de atención. Posteriormente se hace una comparativa con SHAP, PLS-DA y ASCA como métodos exploratorios para obtener una visión desde diferentes ángulos.

Capítulo 9. Conclusiones y líneas de trabajo futuro. Finalmente, se recogen las conclusiones principales del trabajo. Se resumen las aportaciones realizadas, se valoran las ventajas y limitaciones del enfoque propuesto y se plantean posibles líneas de trabajo futuro relacionadas con la ampliación del conjunto experimental, el uso de otros modelos de lenguaje y la aplicación de técnicas XAI más avanzadas.

1.4. Uso de IA Generativa

Durante el desarrollo de este Trabajo Fin de Grado se han utilizado herramientas de inteligencia artificial generativa como apoyo en tareas auxiliares relacionadas con la generación de código, así como en la elaboración inicial del conjunto experimental de frases. En concreto, estas herramientas se han empleado para asistir en la elaboración y depuración de fragmentos de código utilizados durante el desarrollo del sistema. Todo el contenido generado o sugerido mediante estas herramientas ha sido revisado, contrastado y editado

por el autor. Por tanto, el autor asume la plena responsabilidad sobre el contenido final de la memoria, la corrección técnica del sistema implementado y las conclusiones presentadas en este trabajo.

Capítulo 2

Modelos de Inteligencia Artificial

Este trabajo trata sobre la Inteligencia Artificial Explicativa por lo que haremos una introducción a lo largo de este capítulo sobre la Inteligencia Artificial, sus modelos y sus aplicaciones.

Abordaremos temas como los **Modelos de Machine Learning Tradicional** y **Modelos de Aprendizaje Profundo**.

Un modelo de inteligencia artificial es un programa que ha sido entrenado con un conjunto de datos para reconocer determinados patrones o tomar decisiones sin más intervención humana. Los sistemas complejos suelen emplear varios modelos simultáneamente, utilizando técnicas de aprendizaje conjunto como bagging, boosting o stacking.

Cuando las herramientas de IA se vuelven más complejas y versátiles, necesitan cada vez mayores cantidades de datos y potencia informática para entrenarse y ejecutarse. Esto está dando paso a los modelos fundacionales, preentrenados con grandes conjuntos de datos no etiquetados y capaces de una amplia gama de aplicaciones.

Es de gran relevancia diferenciar entre algoritmos y modelos. Los algoritmos son procedimientos, que se describen a menudo en lenguaje matemático o pseudocódigo, que se aplican a un conjunto de datos para lograr una función o propósito determinados. Los modelos son el output de un algoritmo que se ha aplicado a un conjunto de datos.

Machine Learning

El aprendizaje automático (Machine Learning) se utiliza cada vez más en la investigación, así como en muchas otras aplicaciones, ofreciendo nuevas herramientas para superar desafíos para los cuales los métodos estadísticos tradicionales no son adecuados.

Estos modelos se diferencian debido a su entrenamiento aplicándose marcos matemáticos a un conjunto de datos de muestra cuyos puntos de datos sirven de base para futuras predicciones del modelo en el mundo real.

Primeramente, estos modelos necesitan un database completo del problema el cual se va a analizar, ese database debe ser dividido en tres partes. La primera parte de estos datos debe ser la que mayor cantidad de datos tenga, conocidos como datos de train y corresponderán a aproximadamente un 70 % de los datos del database, donde se realizará la parte del entrenamiento sobre ellos y se podrá obtener así una curva tanto de error como de rendimiento del aprendizaje del modelo en función a estos datos.

Posteriormente y con la parte de datos que quedan en el database se realiza otra división para obtener los datos de validating y los datos de tests. Cada uno de ellos conformará aproximadamente el 15 % del database. De igual manera, se entrena el modelo, primero con los datos de validating y finalmente con los de tests, momento en el que se podrán sacar conclusiones finales y un resultado concreto y fiable, ya que el modelo habrá terminado su entrenamiento y se podrá realizar análisis sobre el mismo en función del tipo de datos entrenados y poder evitar el overfitting del modelo.

El primer paso para determinar el modelo de machine learning a utilizar consiste en especificar y pensar en cuál es el objetivo final y qué tipo de solución se requiere según el caso específico.

Las principales tareas que podemos diferenciar para el uso de estos modelos son la exploración y detección de anomalías, relacionadas con el aprendizaje no supervisado. La regresión o predicción y la clasificación, establecidas en un marco del aprendizaje supervisado. Finalmente la optimización, sin embargo, es algo más compleja de encapsular en un tipo de aprendizaje específico. Según Tammy Jiang [1], existen tres grandes tareas en la ciencia de datos: **descripción, predicción e inferencia causal**.

Las técnicas de modelos de ML se pueden dividir en tres grandes categorías. A continuación se hace una breve introducción a cada una de ellas de manera superficial, pero necesaria para poder comprender las bases de los modelos basados en ML.

Aprendizaje no supervisado: detectan patrones inherentes en conjuntos de datos para agrupar puntos de datos a nivel de clasificación y poder realizar regresiones. No requieren de un etiquetado y no hay exigencias externas de

una respuesta es correcta o incorrecta.

Aprendizaje supervisado: conocido como machine learning “clásico”, requiere que un experto humano etiquete los datos de entrenamiento. Es necesario que el humano etiquete esa serie de datos para que el modelo pueda influir sobre esas características conociendo sobre qué dato está trabajando.

Aprendizaje por refuerzo: un modelo aprende de manera holística mediante ensayo y error, y recompensa sistemáticamente los outputs correctos y penaliza los incorrectos.

Aprendizaje Autosupervisado: modelo más novedoso y caracterizado por su rápido avance en el aprendizaje de representaciones durante los últimos años. Utiliza los propios datos de entrada como supervisión y beneficia a casi todo tipo de tareas posteriores (downstream tasks) [2] .

2.1. Tipos de Modelos (Machine Learning Tradicional)

2.1.1. Aprendizaje No Supervisado

Los métodos de aprendizaje no supervisado son especialmente útiles en las tareas descriptivas, ya que su objetivo es encontrar relaciones dentro de una estructura de datos sin disponer de una serie de datos etiquetados.

Su objetivo es identificar patrones, tendencias, comportamientos anómalos, agrupaciones o trayectorias subyacentes dentro de una estructura de datos.

Puede utilizarse también para identificar y determinar la mejor manera de categorizar unas supuestas dimensiones en ciertos subtipos, esta identificación basada en datos puede conducir a la formulación de nuevas hipótesis.

Este modelo se puede utilizar para derivar empíricamente clases e integrar múltiples niveles de datos con el fin de desarrollar enfoques alternativos de clasificación.

2.1.1.1. Clustering

En la clasificación no supervisada, también llamada clustering, no se dispone de datos etiquetados como se ha comentado anteriormente, teniendo directa y únicamente una base de datos de entrada sobre los que trabajar.

El objetivo del clustering es dividir un conjunto finito de datos no etiquetados en un conjunto finito y discreto de estructuras de datos naturales u ocultas, más que ofrecer una caracterización precisa de muestras no observadas generadas a partir de la misma distribución de probabilidad [3] .

Es decir, se busca descubrir patrones o estructuras que ya existen en los datos, aunque no estén indicadas explícitamente. A diferencia de los modelos supervisados, el clustering no pretende predecir correctamente nuevos datos futuros, sino organizar los datos disponibles en grupos que tengan sentido interno. En otras palabras, su finalidad principal es encontrar cómo se relacionan entre sí los datos actuales, más que generalizar a muestras nuevas provenientes de la misma distribución.

Esto se puede llevar a cabo mediante la factorización de matrices previa a la realización del clustering, uno de los métodos más conocidos es el Análisis de Componentes Principales (PCA), cuyo objetivo es transformar las variables originales en un nuevo conjunto de variables lineales ortogonales denominadas componentes principales. Estas componentes capturan la mayor proporción posible de la varianza total de los datos, permitiendo así una representación más compacta sin pérdida significativa de información.

El Análisis de Componentes Independientes (ICA), por su parte, busca descomponer los datos en componentes estadísticamente independientes entre sí. A diferencia de PCA, que maximiza la varianza, ICA maximiza la independencia estadística, lo que lo hace especialmente útil en problemas de separación de señales o en contextos donde se asume la existencia de fuentes latentes independientes.

El Análisis Factorial (FA) comparte similitudes con PCA, pero se fundamenta en un modelo estadístico explícito que asume que las variables observadas están influenciadas por un número reducido de factores latentes no observables. FA es especialmente frecuente en ciencias sociales, donde se pretende identificar constructos subyacentes que explican la correlación entre variables.

La Factorización No Negativa de Matrices (NMF) introduce una restricción adicional al exigir que los factores obtenidos sean no negativos. Esta característica favorece la interpretabilidad, ya que las representaciones resultantes pueden entenderse como combinaciones aditivas de componentes básicos, siendo especialmente útil en análisis de imágenes o texto.

Finalmente, PARAFAC (Parallel Factor Analysis) constituye una extensión de la factorización a estructuras de datos multidimensionales o tensores. Mientras que los métodos anteriores trabajan con matrices bidimensionales, PARAFAC permite descomponer datos de mayor orden, como aquellos que incluyen dimensiones adicionales.

Cabe destacar que el clustering difiere del escalamiento multidimensional, cuyo objetivo es representar todos los objetos evaluados minimizando la distorsión topográfica y utilizando el menor número posible de dimensiones. Los algoritmos de clustering dividen los datos en un número determinado de grupos, subconjuntos o categorías. Mayoritariamente se describe un cluster

considerando su homogeneidad interna y su separación externa, es decir, los patrones dentro de un mismo cluster deben ser similares entre sí, mientras que los patrones en distintos clusters deben ser diferentes.

Desde el punto de vista de la interpretabilidad, los algoritmos de clustering presentan una ventaja inicial: su objetivo es estructurar los datos en grupos homogéneos según una métrica de similitud. Modelos como k-means o clustering jerárquico son relativamente interpretables, ya que los centroides o las estructuras dendrográmicas permiten comprender la organización global del conjunto de datos. No obstante, la interpretabilidad depende en gran medida de la dimensionalidad y de la métrica utilizada. En espacios de alta dimensión, la interpretación geométrica pierde claridad, y el significado semántico de los clusters puede resultar ambiguo. Además, estos métodos no proporcionan explicaciones causales, sino descriptivas.

2.1.1.2. Auto-Encoding Model (AE)

El objetivo de los modelos Auto-Encoder (AE) es reconstruir total o parcialmente las entradas originales a partir de versiones corrompidas o reducidas de las mismas. Gracias a su flexibilidad, son uno de los modelos generativos más utilizados, con múltiples variantes [2].

El modelo AE básico fue introducido originalmente para el preentrenamiento de redes neuronales artificiales. Es un modelo gráfico dirigido y entrenable de forma eficiente, generalmente usado para reducción de dimensionalidad. Consta de un codificador y decodificador y su objetivo es minimizar la diferencia entre la entrada y su reconstrucción.

El modelo de Predicción de Contexto (CPM) busca predecir información contextual a partir de una entrada.

El modelo AE de Eliminación de Ruido (Denoising AE) busca representaciones robustas al ruido. En NLP, el Masked Language Model (MLM), como BERT, puede considerarse un AE de eliminación de ruido, ya que enmascara palabras en el texto y las predice usando el contexto.

El modelo AE Variacional (VAE) asume que los datos se generan a partir de las variables latentes ocultas, al igual que el AE pero sin una distribución, y su objetivo es aproximar la distribución posterior mediante una distribución variacional. Durante el entrenamiento, se maximiza la evidencia inferior, que equilibra la reconstrucción del dato original con una regularización que aproxima el posterior al prior.

Los Auto-Encoders son modelos no supervisados diseñados para aprender representaciones comprimidas de los datos. Desde la perspectiva XAI, su interpretabilidad es limitada, ya que las variables latentes aprendidas no suelen tener un significado explícito. Aunque es posible analizar las activaciones del

espacio latente o visualizar reconstrucciones para entender qué características prioriza el modelo, la relación directa entre entrada y representación interna no es transparente. Su principal inconveniente interpretativo es la naturaleza abstracta del espacio codificado.

2.1.2. Aprendizaje Supervisado

Haciendo referencia al artículo mencionado anteriormente [1], comienzo explicando qué es y cómo funciona el aprendizaje supervisado y algunos modelos basados en su estructura.

El aprendizaje supervisado es utilizado para describir tareas de predicción, ya que el objetivo es predecir o clasificar un resultado específico de interés.

Este modelo se ha aplicado a grandes estructuras de datos, afectando de tal manera actualmente a todas las áreas, como por ejemplo predictores demográficos, clínicos y sociales, con el fin de desarrollar puntuaciones de riesgo. También se ha utilizado para desarrollar puntuaciones pronósticas que predicen la probabilidad de responder a una intervención específica.

Aunque la mayoría de los estudios desarrollan estas puntuaciones utilizando predictores evaluados en un único momento temporal, existiendo diversas formas de integrar medidas repetidas en los algoritmos de aprendizaje supervisado.

2.1.2.1. Árboles De Decisión (Decision Tree)

Clasificación y regresión mediante árboles

Los métodos basados en árboles de decisión automatizan la detección de interacciones y efectos principales no lineales. Los predictores se dividen (según sus valores) y se apilan para construir árboles de decisión; estos árboles pueden combinarse en un conjunto de bosque agregado.

Uno de sus puntos fuertes es que son visualmente interpretables y una de sus principales limitaciones es que los árboles de clasificación individuales se pueden sobreajustar a los datos.

Bosques Aleatorios (Random Forest)

Los bosques aleatorios construyen numerosos árboles en muestras bootstrap y generan un árbol agregado promedio, lo que reduce el sobreajuste u overfitting.

En cuanto a su punto fuerte, es obvio que los bosques aleatorios tienen menor riesgo de sobreajuste que un árbol individual, pero como contra, no son tan visualmente interpretables.

Árboles Bayesianos

Los árboles bayesianos se basan en un modelo probabilístico subyacente para la estructura y la verosimilitud de los datos en los nodos terminales; el árbol final se obtiene promediando los posteriores de todos los árboles, lo que también reduce el sobreajuste.

La principal ventaja de los árboles bayesianos es que ofrecen métricas de importancia de variables, útiles para identificar los predictores más influyentes.

Los árboles de decisión constituyen uno de los modelos más interpretables por naturaleza. Su estructura jerárquica basada en reglas IF-THEN permite rastrear explícitamente el camino que conduce a una predicción. Cada nodo representa una condición fácilmente comprensible, lo que facilita la trazabilidad y justificación de resultados. Sin embargo, cuando el árbol crece en profundidad, la interpretabilidad puede deteriorarse debido a la complejidad estructural. Aun así, siguen siendo considerados modelos white-box y frecuentemente se utilizan como referencia en estudios de explicabilidad.

2.1.2.2. Regresión Convencional

La regresión es una técnica utilizada para realizar los análisis de regresión, empleados habitualmente para pronóstico y predicción, campos en los que su aplicación tiene importantes coincidencias con el aprendizaje automático y, en algunos casos también puede utilizarse para determinar relaciones entre las variables independientes y dependientes.

Es importante destacar que la regresión implícitamente muestra relaciones entre una variable dependiente y un conjunto fijo de variables independientes dentro de un conjunto de datos determinado.

Regresión Lineal

La regresión lineal es uno de los algoritmos más simples y más utilizados. Se trata de un método matemático empleado para realizar análisis predictivos, que permite proyectar variables continuas o reales [4] .

La regresión lineal es un modelo utilizado para evaluar y cuantificar la relación entre variables consideradas. Se utiliza ampliamente en métodos de investigación cuantitativa donde es posible medir los efectos esperados y modelarlos en función de múltiples variables de entrada. Siendo un método de evaluación y modelización de datos que establece relaciones lineales entre variables dependientes e independientes.

Regresión Logística

Los modelos de regresión logística se basan en teoría y supuestos estadísticos y se benefician de la intervención humana y del conocimiento experto en la definición del modelo [5] .

La regresión logística modela la relación entre una variable dependiente y

una o más variables independientes mediante una función lineal, permitiendo realizar predicciones y analizar el efecto de los predictores sobre el resultado. Siendo así una versión de clasificación de la regresión lineal.

Por su parte, el Análisis Discriminante Lineal (LDA) es un modelo generativo que adopta un enfoque diferente. En lugar de modelar directamente la probabilidad condicional, LDA modela la distribución de las variables predictoras dentro de cada clase, es decir, estima la probabilidad de las variables explicativas condicionadas a la clase y posteriormente aplica el teorema de Bayes para clasificar nuevas observaciones. Este método asume que las variables siguen una distribución normal multivariante y que todas las clases comparten la misma matriz de covarianza. Cuando estos supuestos se cumplen, LDA puede ofrecer resultados muy eficientes y una frontera de decisión lineal similar a la obtenida con regresión logística. Desde el punto de vista interpretativo, también es un modelo transparente, ya que la función discriminante permite analizar el peso de cada variable en la separación entre clases.

El Partial Least Squares (PLS), en su versión original, es un método de regresión diseñado para escenarios con alta dimensionalidad y multicolinealidad entre variables predictoras. Su estrategia consiste en proyectar los datos originales en un espacio latente de menor dimensión, construyendo componentes que maximizan la covarianza entre las variables independientes y la variable respuesta. Esta característica lo hace especialmente útil cuando el número de variables es elevado o cuando existe fuerte correlación entre ellas.

A partir de este método surge el PLS-DA, que adapta el enfoque de PLS a problemas de clasificación. En este caso, las clases se codifican numéricamente y el modelo busca componentes latentes que optimicen la separación entre categorías. PLS-DA resulta particularmente adecuado en contextos donde la regresión logística o LDA pueden verse afectados por la alta dimensionalidad o la multicolinealidad. Aunque la interpretación de los componentes latentes no es tan directa como la de los coeficientes en la regresión logística, sigue siendo un modelo relativamente interpretable en comparación con métodos más complejos como redes neuronales profundas.

Modelos como la regresión lineal o logística son altamente interpretables, ya que cada coeficiente representa la contribución directa de una variable al resultado. La magnitud y el signo de los parámetros permiten interpretar la influencia positiva o negativa de cada característica. No obstante, esta interpretabilidad es válida bajo el supuesto de independencia entre variables y ausencia de multicolinealidad. En presencia de correlaciones elevadas, los coeficientes pueden volverse inestables y difíciles de interpretar. A pesar de ello, estos modelos siguen siendo una referencia fundamental en XAI por su transparencia estructural.

2.1.2.3. Máquinas de Vectores de Soporte (SVM)

Las máquinas de vectores de soporte tratan cada predictor como una dimensión en un espacio de alta dimensionalidad y buscan identificar el hiperplano óptimo que separa las muestras en diferentes clases. Cabe mencionar que hay SVM lineales que no proyectan en el hiperplano infinito.

El objetivo es encontrar el hiperplano con el máximo margen entre los dos puntos más cercanos (vectores de soporte) en el espacio. Capturando asociaciones lineales, aunque mediante funciones kernel alternativas también pueden modelar relaciones no lineales.

Las ventajas de este modelo es el buen rendimiento con datos altamente complejos como textos o imágenes, funcionando correctamente incluso cuando el número de predictores es mayor que el número de observaciones (datos de alta dimensionalidad) .

Uno de los problemas del modelo es su tendencia al sobreajuste respecto a otros modelos si no se aplican técnicas de regularización adecuadas o de validación, además de ser un modelo tipo caja negra, debido a que no ofrecen métricas interpretables sobre cómo se combinan los predictores para optimizar el hiperplano.

Las SVM presentan una interpretabilidad intermedia. En su versión lineal, pueden interpretarse de forma similar a un modelo lineal, donde los vectores de soporte determinan la frontera de decisión. Sin embargo, cuando se emplean núcleos no lineales (kernel trick), la interpretabilidad disminuye considerablemente, ya que la transformación implícita a espacios de alta dimensión dificulta la comprensión de la frontera de separación.

2.1.2.4. Clasificador del Vecino más Cercano (K-NN)

En la segunda edición del libro de kubat, basado en una introducción a machine learning, hace referencia en uno de sus capítulos al clasificador del Vecino más cercano [6] .

Este algoritmo clasifica nuevas instancias como la clase mayoritaria de entre los k vecinos más cercanos de entre los datos de entrenamiento. Cuanto menos diferencia haya, mayor será la similitud.

Es un algoritmo perezoso, ya que solo guarda las instancias, no construye ningún modelo diferenciándolo así de los árboles de decisión. Es un algoritmo no paramétrico, es decir, no hace suposiciones sobre la distribución que siguen los datos. Funciona de manera local, asume que la clase de un dato depende sólo de los k vecinos más cercanos y es válido para problemas multiclase.

El hecho de que cada ejemplo pueda representarse como un punto en un espacio n-dimensional permite calcular la distancia geométrica entre cualquier

par de ejemplos, por ejemplo, mediante la distancia euclidiana.

Teniendo en cuenta que limitaciones sufre, cabría destacar su lentitud debido a que hay que tener almacenados todos los datos del entrenamiento y depende directamente de la función distancia utilizada, además de que la interpretabilidad a nivel de variables es más limitada.

El modelo KNN es conceptualmente interpretable, ya que basa su decisión en la similitud con instancias vecinas. La predicción puede justificarse mostrando los ejemplos más cercanos en el espacio de características. No obstante, su interpretabilidad depende de la métrica de distancia empleada y de la escala de las variables. En espacios de alta dimensión, el fenómeno de la maldición de la dimensionalidad reduce la claridad interpretativa. Además, no ofrece un modelo explícito de decisión, sino un procedimiento basado en instancias.

2.1.3. Aprendizaje Por Refuerzo

El aprendizaje por refuerzo tiene sus raíces en los inicios de la cibernética, así como en investigaciones relacionadas con la estadística, la psicología, la neurociencia y la informática.

Esta metodología se basa en la programación de agentes a través de la utilización de recompensas y penalizaciones, sin requerir una definición precisa de los métodos para alcanzar las metas establecidas.

El aprendizaje por refuerzo se centra en la dificultad que enfrenta un agente al intentar adquirir comportamientos mediante el proceso de ensayo y error en un entorno en constante cambio. Esto queda demostrado junto a la explicación de varios modelos que explicaré a continuación en un artículo de Leslie Pack [7] .

Dentro de las dos estrategias fundamentales, una se dedica a explorar el conjunto de comportamientos para identificar aquel que garantizará un rendimiento óptimo en el entorno, mientras que la otra utiliza enfoques estadísticos y técnicas de programación dinámica para evaluar la efectividad de llevar a cabo ciertas acciones en situaciones específicas.

2.1.3.1. Crítico Heurístico Adaptativo (AHC)

El algoritmo Crítico Heurístico Adaptativo (AHC) es una arquitectura de aprendizaje por refuerzo que combina un módulo de evaluación (crítico) y otro de toma de decisiones (agente), funcionando de forma conjunta para aprender una política óptima.

El crítico estima el valor esperado de cada estado según la política actual, mientras que el agente actualiza sus acciones para mejorar ese valor.

El aprendizaje se basa en el algoritmo TD (0) , que ajusta los valores estimados a partir de la recompensa obtenida y del valor del siguiente estado.

Su versión general TD (λ) , incorpora una "traza de elegibilidad" que permite actualizar no solo el estado actual, sino también los visitados recientemente. Acelerando la convergencia, aunque aumentando el coste computacional.

El método combina evaluación y mejora de políticas de forma continua, siendo una de las bases teóricas del aprendizaje por refuerzo moderno.

2.1.3.2. Q-Learning

Q-learning es un algoritmo de aprendizaje por refuerzo sin modelo que permite a un agente aprender una política óptima mediante la experiencia directa con el entorno.

El agente actualiza una tabla de valores (Q-values) que estiman la utilidad de realizar una acción en un estado, basándose en la recompensa obtenida y el valor futuro esperado.

Con el tiempo, el agente aprende qué acciones conducen a mejores resultados, sin necesidad de conocer la dinámica del entorno. Q-Learning equilibra la exploración de nuevas acciones y la explotación de las mejores conocidas.

Su principal ventaja es que converge a la solución óptima independientemente de la estrategia de exploración, siempre que se prueben suficientes acciones.

Es considerado el algoritmo más utilizado y efectivo para el aprendizaje a partir de refuerzos diferidos, aunque pueda resultar lento en espacios de estados grandes.

2.2. Modelos de Aprendizaje Profundo

Clarificar que el aprendizaje profundo (deep learning) es una rama del aprendizaje automático (machine learning), que representa una de las fronteras más avanzadas de la inteligencia artificial, cuyo objetivo es acercarse al propósito principal de esta disciplina: la creación de inteligencia artificial real. Esta búsqueda la seguiremos en esta sección basándonos en el reciente artículo de Shi Dong [8].

El aprendizaje profundo no es más que muchos clasificadores trabajando conjuntamente, basados en regresiones lineales seguidas de funciones de activación. Su fundamento es el mismo que el del enfoque estadístico tradicional de regresión lineal, la única diferencia, es que existen múltiples nodos neuronales en lugar de un solo nodo, junto a las activaciones que hacen su entrenamiento mucho más complejo. Estos nodos conforman lo que se conoce como una red neuronal, y cada nodo clasificador individual se denomina

unidad neuronal o perceptrón.

Otra diferencia importante es que existen muchas capas entre la entrada y la salida. Cada capa puede contener cientos o incluso miles de unidades neuronales, y las capas situadas entre la entrada y la salida se denominan capas ocultas, mientras que los nodos dentro de ellas se conocen como nodos ocultos.

La limitación de los clasificadores tradicionales de ML es que requieren que el investigador trate con un modelo más intenso en cómputo y difícil de interpretar, mientras que en una red neuronal profunda, dicha hipótesis se genera automáticamente mediante el propio modelo, lo que convierte el DL en una herramienta poderosa para aprender relaciones no lineales de manera efectiva.

2.2.1. Aprendizaje Autosupervisado

Este apartado explicará el aprendizaje autosupervisado, un inciso y descubrimiento cercano al momento actual, definido como evolución y relacionado con los tres modelos de aprendizaje explicados anteriormente y basado de nuevo en el artículo ya referenciado [2] .

El término aprendizaje autosupervisado se introdujo por primera vez en el campo de la robótica, donde los datos de entrenamiento se etiquetaban automáticamente aprovechando las relaciones entre diferentes señales de entrada de los sensores.

Se podría describir como la predicción de cualquier parte de la entrada realizada por la máquina a partir de cualquier otra parte observada.

Sus características principales se podrían resumir en obtener etiquetas a partir de los propios datos mediante un proceso “semiautomático” y predecir una parte de los datos en función de otras.

Realmente la otra parte se puede encontrar incompleta, transformada, distorsionada o corrompida pero la máquina aprende a recuperar todo lo posible de su entrada original.

Es confundible con el término de aprendizaje no supervisado, ya que este se podría considerar una rama del mismo, ya que no utiliza etiquetas manuales, sin embargo, el aprendizaje no supervisado se centra en detectar patrones específicos en los datos, como el clustering (previamente comentado), descubrimiento de comunidades o detección de anomalías; mientras que el aprendizaje autosupervisado tiene como objetivo reconstruir o recuperar información, lo cual aún encaja dentro del paradigma supervisado, aunque las etiquetas provengan de los propios datos.

2.2.1.1. Auto-Regressive Model (AR)

Los modelos autorregresivos (AR) pueden interpretarse como una estructura de red bayesiana, es decir, un modelo gráfico dirigido. Son originales de series temporales, y posteriormente es cuando se usan en NLP. La distribución conjunta puede factorizarse como un producto de distribuciones condicionales, donde la probabilidad de cada variable depende de las variables anteriores.

En procesamiento del lenguaje natural (NLP), el objetivo del modelado de lenguaje autorregresivo consiste en maximizar la verosimilitud bajo esta factorización hacia adelante (forward AR factorization).

Los modelos AR también se han aplicado en el campo de la visión por computador, como en PixelRNN y PixelCNN, incluido el dominio de los grafos, por ejemplo en su generación proponiendo GraphRNN.

Sin embargo, una limitación importante de los modelos AR es que el token en cada paso debe generarse de forma secuencial, lo que reduce la velocidad de inferencia y dificulta el paralelismo durante el entrenamiento y la generación.

Los modelos autorregresivos tradicionales, como AR o ARIMA, son relativamente interpretables, ya que modelan explícitamente la dependencia temporal entre observaciones pasadas y presentes. Los coeficientes indican el peso de cada retardo temporal, lo que permite analizar la influencia histórica en la predicción actual. No obstante, cuando se incorporan extensiones no lineales o combinaciones con redes neuronales, la interpretabilidad disminuye progresivamente.

2.2.1.2. Transformers

Este apartado genera especial atención debido a su profundización a lo largo del trabajo. En este punto empieza una introducción y visión general de los Transformers, clasificados en un modelo de aprendizaje autosupervisado pero no de manera encasillada ni mucho menos cerrada, debido a que su funcionamiento (al igual que el modelo self-supervised) es muy novedoso y en continuo estudio, como el que encontramos en el artículo [9].

Los resultados sorprendentes de los modelos Transformers en tareas de lenguaje natural han despertado un gran interés en la comunidad de visión por computador.

Entre sus principales ventajas, los Transformers permiten modelar dependencias a largo plazo entre los elementos de una secuencia de entrada y admiten el procesamiento paralelo de las mismas, a diferencia de las redes recurrentes, como las LSTM.

A diferencia de las redes convolucionales, los Transformers requieren un mínimo de sesgos inductivos en su diseño y se adaptan de forma natural como

funciones de conjunto. Además, su estructura simple y modular permite procesar múltiples modalidades utilizando bloques de procesamiento similares, y demuestran una excelente escalabilidad tanto en capacidad de red como en tamaño de datos.

Modelo de Lenguaje de gran escala (LLM)

El modelado estadístico del lenguaje se ha convertido en un pilar fundamental para muchas tareas de comprensión y generación del lenguaje natural [10] , incluyendo reconocimiento del habla, la traducción automática y la recuperación de información.

Los avances recientes de este modelado están basados en Transformers, pre-entrenados en corpus de texto masivos procedentes de la web. Por ejemplo, ChatGPT y GPT-4, desarrollados por OpenAI, pueden utilizarse no solo para tareas de procesamiento del lenguaje natural, sino también como solucionadores generales de tareas, impulsando sistemas como Microsoft Copilot, capaces de seguir instrucciones humanas complejas y realizar razonamientos multietapa cuando es necesario.

Tienen amplias aplicaciones, como tareas de reconocimiento (clasificación de imágenes, detección de objetos, reconocimiento de acciones y segmentación) , modelado generativo, tareas multimodales (como respuesta visual a preguntas, razonamiento visual, y asociación de texto e imagen) , procesamiento de vídeo (reconocimiento de actividades, predicción de secuencias) , visión de bajo nivel (superresolución, mejora y colorización de imágenes) y análisis tridimensional (clasificación y segmentación de nubes de puntos) .

Entre los modelos más populares se incluyen Representaciones Bidireccionales de Codificadores basadas en Transformers (BERT) y Transformer Generativo Preentrenado (GPT). El profundo impacto de los modelos Transformer se ha hecho aún más evidente con su capacidad de escalar a modelos de muy gran tamaño. Por ejemplo el modelo BERT-large, con 340 millones de parámetros, fue superado significativamente por GPT-3, que cuenta con 175 mil millones de parámetros, mientras que uno de los más recientes, Switch Transformer, basado en una arquitectura de mezcla de expertos, alcanza la asombrosa cifra de 1,6 billones de parámetros. Aunque actualmente GPT-5, considera un mayor número de parámetros.

2.2.2. Red Neuronal Recurrente (RNN)

Las redes neuronales recurrentes son una clase de modelos de aprendizaje profundo que poseen una memoria interna, lo que les permite capturar dependencias secuenciales en los datos. A diferencia de las redes neuronales tradicionales, que tratan las entradas como entidades independientes, las RNN tienen en cuenta el orden temporal de las entradas, lo que las hace es-

pecialmente adecuadas para tareas que implican información secuencial [11]

Mediante el uso de un bucle recurrente, las RNN aplican la misma operación a cada elemento de una secuencia, donde el cálculo actual depende tanto de la entrada presente como de las salidas anteriores. Esta capacidad de aprovechar la información contextual es especialmente valiosa en tareas como el procesamiento del lenguaje natural, la clasificación de vídeos y el reconocimiento del habla.

Sin embargo, una limitación importante es su memoria a corto plazo, lo que restringe su capacidad para retener información a lo largo de secuencias largas.

2.2.3. Red Neuronal de Memoria a Largo Plazo (LSTM)

La Long Short-Term Memory (LSTM) es una variante avanzada de las RNN diseñada para superar el problema de las dependencias a largo plazo. En comparación con las RNN estándar, las LSTM son mucho más eficaces a la hora de retener y aprovechar información en secuencias largas.

En una red LSTM, la entrada actual en un instante de tiempo y la salida del paso anterior se introducen en la unidad LSTM, que genera una nueva salida que se pasa al siguiente paso temporal. La última capa oculta del último paso temporal, o en ocasiones todas las capas ocultas, se utiliza habitualmente para tareas de clasificación.

En conjunto, las LSTM mantienen información relevante durante largos periodos de tiempo, lo que las hace fundamentales en tareas como traducción automática, análisis de secuencias de vídeo, reconocimiento del habla y modelado del lenguaje natural.

Las LSTM, diseñadas para modelar dependencias temporales, presentan dificultades interpretativas debido a sus múltiples puertas (input, forget, output). Aunque puede analizarse la evolución de estados ocultos y activaciones internas, la relación exacta entre una entrada específica y la salida final no es transparente. Métodos como análisis de atención temporal o atribuciones basadas en gradientes son necesarios para mejorar su explicabilidad.

2.2.4. Gated Recurrent Unit (GRU)

La arquitectura Gated Recurrent Unit (GRU) constituye una simplificación del modelo LSTM, reduciendo el número de puertas de control a dos mecanismos principales: la puerta de actualización (update gate) y la puerta de reinicio (reset gate). El estado oculto en cada instante se calcula como una combinación interpolada entre el estado anterior y un nuevo estado candida-

to, regulada por la puerta de actualización. De este modo, el modelo decide qué proporción de la información previa debe mantenerse y cuánto del nuevo contenido debe incorporarse. El estado candidato, a su vez, se construye aplicando una función no lineal sobre la entrada actual y el estado oculto anterior modulado por la puerta de reinicio, lo que permite controlar el grado en que la información pasada influye en la nueva representación [12].

En comparación con la LSTM, la GRU elimina una de las puertas externas, lo que reduce el número de parámetros y simplifica la estructura interna. Concretamente, el número total de parámetros de una GRU es aproximadamente tres veces mayor que el de una RNN simple, aunque sigue siendo menor que el de una LSTM. Diversos estudios han demostrado que la GRU ofrece un rendimiento comparable, e incluso superior en algunos casos, al de la LSTM, manteniendo una mayor eficiencia computacional.

2.2.5. Red Neuronal Convolutiva (CNN)

Las redes neuronales convolucionales constituyen un tema central de investigación en el campo de análisis de datos de voz y el reconocimiento de imágenes. Estas redes poseen una estructura con parámetros compartidos, lo que las hace más similares a las redes neuronales biológicas.

Dicha arquitectura permite reducir significativamente la complejidad del modelo y disminuir el número de pesos entrenables, mejorando la eficiencia e interpretabilidad en el procesamiento de imágenes de alta dimensión.

Las redes neuronales convolucionales pueden recibir directamente las imágenes como entrada, evitando los procesos manuales y complejos de extracción y reconstrucción de características requeridos por los algoritmos tradicionales. Durante el proceso de reconocimiento de imágenes, las redes convolucionales presentan una alta invariancia frente a transformaciones como escalado, inclinación, traslación u otras formas de deformación visual, lo que las convierte en una de las herramientas más robustas y eficaces en visión por computador.

Las CNN permiten cierto grado de interpretabilidad mediante mapas de activación y técnicas como Grad-CAM, que identifican regiones relevantes en imágenes. No obstante, los filtros aprendidos en capas profundas son abstractos y no siempre fácilmente asociables a conceptos humanos. Aunque pueden visualizarse características de bajo nivel (bordes, texturas), la interpretación semántica de capas profundas sigue siendo limitada sin técnicas XAI específicas.

2.2.6. Red Generativa Antagónica (GAN)

Estos modelos constituyen una clase de modelos generativos basados en la teoría de juegos, que no modelan explícitamente la distribución de los datos, sino que aprenden a generar muestras que provienen de dicha distribución. La muestra se realiza mediante una red neuronal profunda, la cual toma como entrada un vector de ruido aleatorio y lo transforma en una distribución de modelo.

El objetivo es encontrar un modelo que aproxime la distribución real de los datos. La red generativa adversaria se compone de dos redes neuronales, un generador (G) y un discriminador (D) .

Se denomina adversarial porque el generador intenta engañar al discriminador haciéndole creer que las muestras generadas provienen de los datos reales, mientras que el discriminador intenta distinguir constantemente entre ambas.

El generador (G) es una red neuronal que recibe como entrada un vector de ruido aleatorio y lo transforma en una muestra generada perteneciente a la distribución del modelo.

El discriminador (D) es una red neuronal que distingue entre las muestras reales del conjunto de entrenamiento y las muestras falsas generadas por el generador. Actúa como un clasificador binario, determinando si la entrada es real o falsa.

Ambas redes compiten entre sí, obteniendo un valor de probabilidad que se utiliza para actualizar los pesos de ambas redes durante el entrenamiento, la formulación matemática del problema se plantea como un juego de suma cero tipo MiniMax, en el cual el discriminador busca maximizar su precisión, mientras que el generador intenta minimizarla, es decir, engañarlo con éxito.

Las GAN son particularmente complejas desde el punto de vista interpretativo, ya que implican la interacción competitiva entre generador y discriminador. La representación latente aprendida por el generador puede explorarse mediante interpolaciones, pero la relación entre dimensiones latentes y características generadas no suele ser directa. Además, la inestabilidad del entrenamiento complica aún más el análisis interpretativo.

2.2.7. Red Neuronal Probabilística Profunda (DPNN)

Las redes neuronales probabilísticas (PNN) , se basaban en arquitecturas de redes neuronales superficiales. Constan de cuatro capas básicas, una capa de entrada que recibe y distribuye el vector de entrada, una capa de patrones que aplica un núcleo (kernel) al vector de entrada, una capa de suma que calcula el promedio de las salidas de las unidades de patrón para cada clase,

y una capa de decisión que determina la clase asignada al vector de entrada basándose en la unidad que produce la salida máxima en la capa de suma.

Avanzando posteriormente a las redes neuronales probabilísticas profundas (DPNN) . La ventaja principal frente a las redes neuronales tradicionales es que pueden ofrecer un mejor rendimiento incluso con una cantidad limitada de datos de entrenamiento. Resultando especialmente útiles en campos donde los datos disponibles son escasos, como la imagen médica o el procesamiento de señales.

Estas presentan una mayor robustez frente a ataques adversarios, lo que las convierte en una opción prometedora, ya que las DNN suelen fallar ante pequeñas perturbaciones o errores aleatorios.

Esta mejora se produjo mediante unas modificaciones menores sobre las redes neuronales convencionales, aplicando dos enfoques principales, sustituir la capa de salida tradicional por una capa de salida probabilística e incorporar la incertidumbre en las activaciones internas de la red, mediante un proceso de propagación profunda de la incertidumbre (deep uncertainty propagation) .

Las redes neuronales probabilísticas profundas combinan aprendizaje profundo con modelado probabilístico, lo que introduce una ventaja interpretativa en términos de estimación de incertidumbre. Aunque la arquitectura subyacente puede ser compleja, la posibilidad de cuantificar la confianza en las predicciones mejora la transparencia. Sin embargo, la interpretación estructural de las capas internas sigue siendo tan compleja como en otras redes profundas.

2.2.8. Transformers

En esta sección de Transformers, avanzaremos con el tema y nos centraremos en sus aplicaciones.

Transformers para Detección de Objetos

Los Transformers para detección de objetos han revolucionado este campo al eliminar módulos manuales como RPN (Region Proposal Network) [13] o NMS (Non-Maximum Suppression) [14]. El modelo DETR (DEtection TRansformer) [15] combina CNNs y Transformers para predecir todos los objetos de una imagen de una sola vez, simplificando la arquitectura tradicional.

No obstante, presenta alto coste computacional y lenta convergencia, problemas abordados por variantes como Deformable DETR, que introduce atención selectiva y reduce el entrenamiento hasta 10x.

Modelos posteriores como Ancho DETR y Pix2Seq optimizan aún más la efi-

ciencia y generalizan el enfoque a una formulación de secuencia a secuencia. Finalmente, YOLOs (You Only Look at One Sequence) [16] y PVT+DETR (Pyramid Vision Transformer) [17] representan la nueva generación de modelos de detección totalmente basados en Transformers, con alto potencial para el futuro del aprendizaje visual extremo a extremo.

Transformers para Segmentación

Los Transformers en segmentación de imágenes aprovechan la autoatención para modelar interacciones globales entre píxeles, superando las limitaciones de los métodos basados en CNN.

El modelo Axial Attention reformula la autoatención 2D en dos pasos 1D (altura y anchura), logrando mayor eficiencia y mejor captura del contexto global. El enfoque Cross-modal Self-Attention integra lenguaje e imagen, permitiendo segmentar regiones descritas textualmente.

Por otro lado, arquitecturas completas como Segmentation Transformer, SegFormer y Segmenter emplean codificadores ViT y decodificadores Transformer o MLP, ofreciendo segmentación semántica, instanciada y multimodal, combinando precisión, generalización y escalabilidad.

Transformers para Generación de Imágenes

Los Transformers en generación de imágenes han revolucionado el modelado generativo al superar las limitaciones de los métodos convolucionales. Modelos como Image Transformer y iGPT introdujeron la generación autorregresiva de píxeles, demostrando que los Transformers pueden aprender relaciones espaciales sin supervisión.

Posteriormente, VQGAN (Vector Quantized Generative Adversarial Network) +Transformer [18] combinó sesgos inductivos de CNN con autoatención para generar imágenes de alta resolución y realismo. El modelo TransGAN reemplazó completamente las convoluciones, obteniendo resultados de vanguardia en métricas de calidad visual. Por su parte, SceneFormer amplió este enfoque al dominio 3D, creando escenas realistas mediante relaciones espaciales entre objetos.

El hito más notable es DALL·E [19], capaz de generar imágenes fotorrealistas a partir de texto, controlando múltiples atributos y combinaciones creativas. Estos avances consolidan a los Transformers como una base unificada para la generación visual y multimodal, abriendo paso a modelos de creación automática y comprensión contextual profunda.

Transformers para Visión de Bajo Nivel

Tras el éxito de los modelos Transformer en tareas de visión de alto nivel, han surgido numerosos métodos basados en Transformers aplicados a visión de bajo nivel, como la superresolución de imágenes, la reducción de ruido (denoising), la eliminación de lluvia (deraining) y la colorización.

La restauración de imágenes requiere una correspondencia píxel a píxel entre la imagen degradada y la restaurada, con el objetivo de preservar detalles finos como bordes y texturas.

Las CNNs logran esto mediante arquitecturas de una sola escala, sin operaciones de reducción espacial, pero los Transformers presentan una complejidad cuadrática respecto al número de parches de imagen, lo que hace inviable operar a escala completa. Por ello, los modelos de restauración con Transformers implementan estrategias para reducir la carga computacional, como la autoatención local por ventanas, la reducción espacial de atención, o diseños codificador-decodificador.

Transformers para Procesamiento de Imágenes

A diferencia de las tareas de visión de alto nivel (que se benefician de modelos preentrenados en grandes conjuntos como ImageNet), las tareas de bajo nivel (denoising, superresolución, deraining) suelen entrenarse directamente sobre datasets pequeños y específicos, lo que limita su generalización.

El Image Processing Transformer (IPT), es un modelo preentrenado basado en Transformer capaz de abordar múltiples tareas de restauración. El IPT utiliza una arquitectura multi-cabeza y multi-salida (multi-head/multi-tail) con un encoder-decoder compartido. El modelo fue preentrenado con 10 millones de imágenes sintéticas derivadas de ImageNet (simulando degradaciones como ruido, baja resolución o lluvia) y posteriormente ajustado (fine-tuned) para cada tarea. Los resultados experimentales muestran que el IPT supera los métodos previos en tareas de restauración específicas.

Transformers para Tareas Multimodales

Los modelos Transformer también se han empleado extensamente en tareas multimodales de visión y lenguaje, como respuesta visual a preguntas (VQA), razonamiento visual con sentido común, búsqueda cruzada entre texto e imagen y generación de descripciones de imágenes (captioning).

El objetivo de muchos de estos trabajos es realizar un preentrenamiento de visión-lenguaje (VLP) a gran escala para aprender representaciones genéricas multimodales que capturen relaciones entre modalidades (por ejemplo, asociar descripciones semánticas con regiones visuales). Estas representaciones pueden luego transferirse a tareas específicas, alcanzando resultados de vanguardia.

Generalmente, estos modelos emplean CNNs como backbone visual para extraer características, mientras que los Transformers procesan texto y fusionan la información de ambas modalidades. Aunque el bloque de autoatención no cambia sustancialmente, los modelos difieren en su configuración y funciones de pérdida, clasificándose en Transformers de múltiples flujos (multi-stream) y Transformers de flujo único (single-stream).

Modelos como ViLBERT (Vision-and-Language BERT) [20] y LXMERT (Learning Cross-Modality Encoder Representations from Transformers) [21] emplean arquitecturas de dos flujos (visión y lenguaje) con capas co-atencionales, logrando excelentes resultados en tareas de comprensión visual-lingüística. PEMT (Pre-trained Encoder for Multimodal Tasks) [22] extiende el enfoque a audio y video, optimizando recursos mediante aprendizaje contrastivo y parámetros compartidos.

El concepto de tokens introduce supervisión visual en modelos lingüísticos, mejorando la comprensión semántica. Transformers aplicados a navegación visión-lenguaje permiten a los agentes planificar rutas basadas en descripciones textuales. Finalmente, CLIP (Contrastive Language–Image Pretraining) [23] unifica visión y lenguaje a gran escala mediante aprendizaje contrastivo, alcanzando rendimiento zero-shot sobresaliente sin entrenamiento supervisado.

En conjunto, estos avances establecen a los Transformers como la base dominante del aprendizaje multimodal, combinando visión, texto, audio y razonamiento en un mismo marco.

Los Transformers, ampliamente utilizados en NLP y visión, son modelos altamente complejos y tradicionalmente considerados cajas negras. Aunque los mecanismos de atención proporcionan cierta interpretabilidad al mostrar qué partes de la entrada reciben mayor peso, investigaciones recientes han demostrado que la atención no equivale necesariamente a explicación. Su principal dificultad interpretativa radica en la interacción no lineal entre múltiples capas y cabezas de atención.

Capítulo 3

XAI: Inteligencia Artificial Explicativa

Avanzando en la Inteligencia Artificial, llegamos al tema principal, XAI (Inteligencia Artificial Explicativa), sección en la que me basaré en el artículo Ali et al. de Ali Sajid [24].

Uno de los problemas actuales que encontramos en este sector, es la aplicación tan masiva de la inteligencia artificial en una amplia variedad de ámbitos avanzados y complejos, de manera que los resultados obtenidos y generados por estos modelos resultan muy difíciles de interpretar y de confiar debido a su naturaleza de caja negra (black box).

En la práctica es primordial y un requisito esencial comprender el razonamiento que existe detrás de las decisiones de un modelo de IA, por ello la necesidad de desarrollar métodos de XAI que permiten aumentar la transparencia y la confianza en los sistemas. El AI Act o Reglamento de Inteligencia Artificial de la Unión Europea es la primera norma europea específica para regular el desarrollo, comercialización y uso de sistemas de inteligencia artificial. Su objetivo principal es permitir el uso de la IA dentro de la UE, pero garantizando que estos sistemas sean seguros, transparentes y respeten los derechos fundamentales de las personas. La idea central del AI Act es que no todos los sistemas de IA deben regularse igual. Para ello, la norma utiliza un enfoque basado en el riesgo: cuanto mayor sea el posible impacto negativo de un sistema de IA sobre la seguridad, la salud, los derechos fundamentales o la sociedad, más estrictas serán las obligaciones legales.

Nivel de riesgo	Descripción	Ejemplos
Riesgo inaceptable	Sistemas prohibidos porque pueden vulnerar derechos fundamentales, manipular a las personas o suponer una amenaza para la seguridad.	Sistemas de puntuación social, manipulación subliminal dañina o ciertas formas de vigilancia biométrica.
Alto riesgo	Sistemas permitidos, pero sometidos a requisitos estrictos de seguridad, transparencia, documentación, supervisión humana y gestión de riesgos.	IA aplicada a selección de personal, educación, infraestructuras críticas, sanidad, justicia o acceso a servicios esenciales.
Riesgo limitado	Sistemas sujetos principalmente a obligaciones de transparencia. El usuario debe saber que interactúa con una IA o que un contenido ha sido generado artificialmente.	Chatbots, sistemas generativos, deepfakes o contenidos generados mediante IA.
Riesgo mínimo o nulo	Sistemas que apenas presentan riesgo y no están sometidos a obligaciones específicas relevantes por parte del AI Act.	Filtros de spam, videojuegos con IA o sistemas de recomendación simples.

Cuadro 3.1: Clasificación de los sistemas de inteligencia artificial según el nivel de riesgo en el AI Act de la Unión Europea.

Como he comentado antes, en los últimos años, se ha consolidado clave la investigación de estos nuevos modelos dentro del campo de la inteligencia artificial, es cierto que anteriormente se habían realizado revisiones previas que abordan conceptos fundamentales y terminología general, así como técnicas de explicabilidad de post-hoc, pero hasta 2023 no empezaron a aparecer estudios exhaustivos.

A lo largo de esta sección, trataré temas de suma relevancia, separándolo en tres partes principales: **Explicabilidad de los datos**, **Explicabilidad del modelo** y **Explicabilidad Post-hoc**.

3.1. Explicabilidad de los Datos

La explicabilidad de los datos es fundamental debido a que abarca un conjunto de técnicas destinadas a comprender en profundidad los conjuntos de datos que se usan durante el entrenamiento y diseño de los modelos de inteligencia artificial.

Debido a que el comportamiento y resultados finales de un modelo de IA dependen en gran medida de los datos con los que se entrena, este nivel de explicabilidad es relevante para garantizar la fiabilidad y el rendimiento del sistema.

Si tenemos datos que no sean precisos, representativos o de alta calidad, el modelo no podrá ofrecer buenos resultados, por tanto el objetivo principal es conseguir que estos datos sean comprensibles, eficientes y robustos.

3.1.1. Análisis Exploratorio de Datos

El Análisis Exploratorio de Datos, tiene como objetivo principal identificar y resumir las características más relevantes de un conjunto de datos, tales como dimensionalidad, media, desviación estándar, rango y valores ausentes. Una de las herramientas actuales más potentes, rápida y eficaces es Google Facets, que permite extraer y visualizar estas propiedades clave de los datos.

En cuanto a las acciones que se pueden tomar tras un análisis EDA, una de ellas sería la detección de sesgos o desequilibrios de clases, para poder identificar dónde estaría el problema en cuanto a la clasificación de datos. Posteriormente a realizar esta detección, ya sería posible seguir diferentes estrategias de corrección, como el reajuste de clases o el muestreo equilibrado, para mejorar la calidad del modelo.

Aún así, no es aconsejable basarse solo en características estadísticas para evaluar un conjunto de datos de forma adecuada, ya que Matejka et al. [25], demostraron que dos conjuntos de datos con métricas estadísticas similares pueden representar estructuras visuales completamente diferentes al mostrarse gráficamente. Por tanto, predomina la obviedad si hay que pensar que las técnicas de visualización de datos son un componente esencial dentro de los EDA, para poder detectar patrones, relaciones y anomalías que puedan pasar desapercibidos en un análisis puramente numérico.

Para superar la complejidad de la representación de conjuntos de datos complejos y multidimensionales, existen herramientas clave como los gráficos de coordenadas paralelas (Parallel Coordinate Plots, PCP) [26], que sirven para examinar la relación entre múltiples variables y decidir cuáles conservar o descartar. Otra posible solución sería proyectar los datos de alta dimensión en espacios de menor dimensión, procurando preservar al máximo la

estructura subyacente.

Entre las técnicas más utilizadas para este fin se encuentran el Análisis de Componentes Principales (PCA) y el t-Distributed Stochastic Neighbor Embedding (t-SNE) , ambos disponibles en la herramienta Embedding Projector [27] .

3.1.2. Ingeniería de características explicable

Además de mejorar el rendimiento de los modelos de IA, la explicabilidad de los datos desempeña un papel clave en el desarrollo de modelos más interpretables y en la comprensión de las explicaciones post-hoc. Un concepto fundamental en este contexto es la atribución de características, que consiste en evaluar la importancia relativa de cada variable de entrada en la decisión final de un modelo.

Para ello, es necesario que estas características sean también explicables, de manera que se le pueda atribuir un significado intuitivo a cada variable y determinar cuáles son las explicaciones más relevantes para un usuario final determinado. En otras palabras, la capacidad de un modelo para ofrecer predicciones precisas depende directamente de la calidad y la interpretabilidad de las características utilizadas.

Un campo estrechamente relacionado con esta línea de trabajo es el del aprendizaje de representaciones desentrelazadas (disentangled representation learning) [28] . Este enfoque busca obtener representaciones en las que las variables latentes que generan los datos estén separadas e individualizadas, de modo que cada una de ellas corresponda a un factor explicativo concreto del conjunto. Dichas variables latentes pueden interpretarse como características explicables, ya que proporcionan una visión estructurada y comprensible del origen de la información dentro del modelo de aprendizaje automático.

3.1.3. Estandarización en la descripción de conjuntos de datos

Frecuentemente, los conjuntos de datos se publican sin la documentación adecuada, lo que dificulta su correcta interpretación, reutilización y evaluación. Esta falta de estandarización puede generar problemas de sesgo sistemático en los modelos de IA y favorecer un uso inadecuado o poco ético de los datos.

Se han propuesto diversas iniciativas para formalizar la documentación de los datasets, destacando: **Datasheets for Datasets** [29] y **Data Declarations for Natural Language Processing (NLP)** [30] . Estas propuestas definen esquemas estructurados de metadatos que describen los aspectos más relevantes de un conjunto de datos, como su origen, contenido, evolución y

consideraciones legales.

Esta práctica aumenta la transparencia, trazabilidad de los datos y además promueve el uso ético y responsable de los datos dentro de los proyectos de inteligencia artificial.

3.1.4. Metodologías para la síntesis de conjuntos de datos

El razonamiento basado en casos es una técnica de modelado que realiza predicciones comparando una nueva entrada con ejemplos previos del conjunto de entrenamiento, utilizando principalmente una métrica de distancia, pero presenta una limitación importante: requiere almacenar una totalidad del conjunto de datos de entrenamiento, lo que puede resultar costoso e impracticable si se trabaja con unos grandes volúmenes de datos.

Para abordar estos problemas, surge el concepto de síntesis de conjuntos de datos, cuyo objetivo es conservar solo una fracción del conjunto original que represente de manera fiel la esencia y diversidad de los datos completos. Entre las principales técnicas encontramos, el resumen de documentos, el resumen de escenas y la selección de prototipos.

En este tipo de métodos, el enfoque habitual consiste en identificar un conjunto reducido de muestras representativas o “prototipos”, que permitan ofrecer una visión general del conjunto completo. No obstante, cuando se trata de datasets extensos y complejos, basarse únicamente en prototipos puede ser insuficiente para comprender la totalidad de la información. En estos casos, resulta necesario incorporar también críticas, es decir, ejemplos atípicos o poco comunes que no están adecuadamente representados por los prototipos.

Otra técnica destacada es el data squashing, cuyo propósito es crear una versión reducida del conjunto original que, a pesar de su menor tamaño, mantenga la capacidad de producir resultados estadísticamente similares. A diferencia de la simple síntesis, el data squashing asigna pesos específicos a cada muestra conservada, de modo que las observaciones más representativas tengan mayor influencia en el modelo.

3.1.5. Grafos de conocimiento

Los grafos de conocimiento constituyen una herramienta fundamental para representar y estructurar el conocimiento dentro de un dominio específico (como finanzas, salud o educación), mediante una red dirigida de nodos y aristas etiquetadas.

En este tipo de grafo, los nodos representan entidades (conceptos, objetos o individuos), y las aristas expresan las relaciones semánticas entre ellas,

organizadas según un esquema ontológico. Permitiendo así conceptualizar un dominio de manera formal, facilitando la interpretación y razonamiento sobre los datos de forma coherente y contextualizada. También permiten detectar relaciones causales o de dependencia entre factores y enriquecer la información contenida en los conjuntos de datos.

Estas estructuras ontológicas, definidas como estructuras formales que explican conceptos y relaciones de un dominio, ofrecen una base sólida para justificar semánticamente las predicciones realizadas por los algoritmos de IA, favoreciendo así a describir las propiedades de los datos y ofrecer explicaciones comprensibles y adaptadas al lenguaje del usuario final.

Por otro lado, se extendió un algoritmo denominado Trepan [31], utilizado para generar explicaciones a partir de redes neuronales, integrando ontologías dentro del proceso explicativo, demostrando que las explicaciones basadas en conocimiento ontológico eran percibidas como más comprensibles, precisas y coherentes que aquellas generadas sin apoyo semántico.

Esta fusión entre la inteligencia artificial simbólica y la estadística moderna permite dotar de significado, contexto y justificación a las predicciones automáticas, dirigiendo así hacia el éxito de encontrar modelos de IA más interpretables, confiables y transparentes.

3.1.6. Redes neuronales informadas por la física

Las redes neuronales informadas por la física (Physics-Informed Neuronal Networks, PINN) [32] constituyen una categoría avanzada de modelos que integran principios físicos, leyes naturales y restricciones matemáticas dentro de la propia arquitectura de la red neuronal. Este enfoque busca el objetivo de combinar la habilidad predictiva del aprendizaje profundo (deep learning) con la coherencia y el rigor exacto de modelos físicos tradicionales, buscando y logrando una vez más una mayor interpretabilidad, robustez y capacidad de generalización en contextos científicos y de ingeniería.

La idea principal de estas redes neuronales es incorporar ecuaciones diferenciales, leyes de conservación o principios físicos directamente en la función de pérdida del modelo, de manera que la red no solo aprenda de los datos introducidos sino que respete las leyes fundamentales del dominio que representa. Esto permite modelar procesos complejos y no lineales con mayor fidelidad, incluso cuando los datos disponibles son escasos o ruidosos.

Varios estudios han demostrado que en ámbitos y disciplinas como las ciencias del sistema terrestre, que abarcan áreas como la modelización atmosférica y oceánica, los procesos de superficie terrestre o la ciencia de la criosfera, estas redes han obtenido una gran eficacia [33], [34], [35], [36], [37].

Este campo se está tratando de manera actual y de una manera novedosa,

estudiándose en busca de la aplicación de principios teóricos, aplicaciones prácticas e intentando enfrentar desafíos complejos y recientes. Las PINN, representan un puente entre la inteligencia artificial y la modelización científica, promoviendo como todo lo visto anteriormente, el desarrollo de modelos más interpretables, fiables y en este caso físicamente coherentes.

3.2. Explicabilidad del Modelo

Aunque los datos hayan sido cuidadosamente limpiados, procesados y analizados mediante las técnicas de explicabilidad de datos comentadas anteriormente, un modelo de inteligencia artificial puede seguir siendo difícil de comprender o interpretar. La explicabilidad del modelo se considera esencial dentro del diseño y evaluación de los diferentes sistemas de IA debido a la complejidad de introducir en los modelos los conocimientos expertos de los desarrolladores dentro del proceso de aprendizaje, limitando su capacidad para mejorar el rendimiento del modelo.

El objetivo principal de la explicabilidad del modelo es construir arquitecturas que sean intrínsecamente interpretables, de manera que sea posible entender de manera directa cómo se generan las predicciones y qué factores influyen en ellas.

Es completamente necesario profundizar en el propio proceso del entrenamiento, comprender cómo se ajustan los parámetros internos y cómo se representan las relaciones entre variables, ya que analizar solamente el resultado que se obtiene dada una entrada única no es suficiente para determinar por qué un modelo no alcanza el rendimiento esperado o por qué no es la respuesta más óptima.

En términos generales, el objetivo de la explicabilidad del modelo es dotar a los sistemas de un mecanismo explicativo integrado, que proporcione transparencia y trazabilidad a lo largo de todo el ciclo de aprendizaje.

Actualmente, los avances están relacionados con la inclusión de métodos híbridos, modelos que incluyan una predicción en sintonía con una explicación conjunta y arquitecturas modernas capaces de generar interpretaciones de manera autónoma, buscando el ir más allá de depender únicamente de análisis posteriores (post-hoc explainability).

En definitiva, la parte más compleja de este proceso sigue siendo el diseño de mecanismos explicativos que estén profundamente integrados en la estructura interna del modelo, de modo que las decisiones puedan justificarse de manera coherente y comprensible.

3.2.1. Familia de modelos intrínsecamente interpretables

El método más tradicional para obtener modelos explicables es seleccionar modelos y técnicas de modelado que sean interpretables por su propia naturaleza, más bien conocidas como modelos de caja blanca (white-box models), estos modelos permiten ver de forma directa lo que está ocurriendo en su interior, de manera que se puede apreciar claramente la relación entre variables de entrada y decisiones o predicciones generadas por el sistema.

Existen tres propiedades fundamentales que en caso de cumplirse, garantizan la interpretabilidad del modelo: la **Transparencia algorítmica** que implica que todo el funcionamiento interno del modelo debe ser comprensible y reproducible, la **Simulabilidad** que se define de manera que un humano pueda ser capaz de seguir el razonamiento del modelo paso a paso, y por último la **Descomponibilidad** que es entendida en este ámbito como la necesidad de que cada parte del modelo debe tener un significado claro y explicable [38], [39] .

El problema de utilizar estos tipos de modelos es que en ciertos casos de complejidad mayor, como trabajar con datos de alta dimensionalidad, es difícil llegar a obtener una alta interpretabilidad de lo que está ocurriendo y para ciertos fenómenos del mundo real estos modelos son demasiado simples. Llevando así al conocido compromiso entre interpretabilidad y rendimiento, este principio sostiene que cuanto más preciso es un modelo, menos interpretable tiende a ser, y viceversa.

El objetivo principal es desarrollar modelos suficientemente simples de entender y comprender su funcionamiento por un público objetivo, pero que a su vez sea lo bastante complejo para representar con precisión la realidad subyacente y mantener un alto nivel de desempeño.

3.2.2. Modelos híbridos explicables

El desarrollo de modelos híbridos explicables surge de la necesidad de combinar alto rendimiento de los modelos de caja negra con la transparencia de los modelos intrínsecamente interpretables. La idea fundamental es que un modelo puede ser potente y preciso sin renunciar a la interpretabilidad, integrando ambos enfoques en un mismo marco metodológico. Hay varios ejemplos destacados que se acercan a la definición anterior, pero como todo tienen una serie de inconvenientes que no permiten que sean estrictamente perfectos o sean un ejemplo ideal.

El **Deep k-Nearest Neighbors (DkNN)**, aplica el algoritmo k-NN sobre representaciones internas generadas por las capas ocultas de una red neuronal profunda. Este modelo justifica sus decisiones mostrando las muestras de entrenamiento más similares utilizadas en cada capa, demostrando ser

eficiente, robusto y transparente, ya que permite comprender las decisiones a partir de las vecindades más relevantes. El inconveniente es que requiere almacenar las representaciones ocultas de todo el conjunto de entrenamiento, siendo computacionalmente costoso en caso de un gran volumen de datos [40] .

En el caso de **Deep Weighted Averaging Classifier (DWAC)** encontramos una gran similitud al caso anterior, con la única diferencia que se calcula únicamente a partir de la representación de la capa final, simplificando el proceso sin sacrificar interpretabilidad [41] .

Las **Self-Explaining Neural Networks (SENN)** representan otro avance en esta línea. Estas redes generalizan los clasificadores lineales al aprender simultáneamente las características, los coeficientes asociados y la forma en que se combinan para generar una predicción. La arquitectura se compone de tres redes neuronales: un codificador de conceptos, un parametrizador dependiente de la entrada y un agregador. De esta forma, se obtiene un modelo híbrido que mantiene la estructura explicativa de un modelo lineal, pero con la capacidad expresiva y la flexibilidad de una red profunda [42] .

Otra aproximación interesante son las **BagNets**, modelos utilizados principalmente en clasificación de imágenes. Su idea principal es analizar la imagen por partes pequeñas en lugar de estudiar toda la imagen de forma global. Cada una de estas regiones se procesa para obtener información local sobre la posible clase de la imagen. Después, el modelo combina la información obtenida en todas las regiones y calcula la predicción final. Este enfoque resulta interpretable porque permite observar qué zonas concretas de la imagen han influido más en la decisión del modelo. De esta forma, no solo se obtiene una clasificación, sino también una indicación visual de las partes de la imagen que han sido más relevantes para llegar a ese resultado.[43] .

En un nivel bastante más abstracto, los **modelos neuro-simbólicos (NeSy)** representan una de las corrientes más prometedoras. Estos sistemas integran mecanismos conexionistas (neurales) con principios de computación simbólica y lógica, permitiendo analizar, visualizar y controlar la complejidad interna de las redes neuronales [44] . Por ejemplo, los Conceptors [45] incorporan una interpretación semántica basada en lógica booleana, mientras que los **Logic Explained Networks (LENs)** permiten traducir las decisiones de modelos de caja negra en axiomas de lógica de primer orden, ofreciendo explicaciones legibles y estructuradas [46] .

Existen también otros componentes simbólicos prometedores que incluyen el uso de espacios de estados aprendidos [47] y autómatas de estados finitos (Finite State Automata) para extraer conocimiento implícito de los agentes y detectar los llamados momentos Eureka durante el aprendizaje [48]. Además, los grafos causales (causal graphs) pueden emplearse de forma post-hoc para realizar análisis de mediación causal, identificando factores de confu-

sión y mediadores que expliquen las decisiones del modelo o posibles sesgos discriminatorios [49] .

En conjunto, los modelos híbridos explicables representan un punto de convergencia entre la precisión de los modelos profundos y la interpretabilidad de los enfoques simbólicos y estadísticos, marcando una evolución significativa hacia sistemas de inteligencia artificial más transparentes, confiables y comprensibles.

3.2.3. Predicción y explicables conjuntas

Un modelo explicable no solo puede estar diseñado para predecir, sino también para explicar de forma explícita las razones detrás de cada predicción. En este enfoque, conocido como predicción y explicación conjuntas (Joint Prediction and Explanation) , el modelo se entrena simultáneamente para generar un resultado y su correspondiente justificación, integrando el proceso predictivo y el explicativo dentro de un único marco de aprendizaje. Esta sección aborda los principales métodos que combinan ambos procesos, analizando sus ventajas, limitaciones y aplicaciones.

Uno de los primeros enfoques en esta línea es el marco **Teaching Explanations for Decisions (TED)**. Este modelo amplía el conjunto de entrenamiento tradicional añadiendo, además de las características de entrada y las etiquetas de salida, una explicación proporcionada por el usuario que justifica la decisión tomada. Así, cada muestra de entrenamiento incluye tanto la respuesta esperada como el razonamiento asociado. Durante el entrenamiento, ambos elementos se combinan en una única etiqueta compuesta. De este modo, en la fase de prueba, el modelo es capaz de generar simultáneamente una predicción y una explicación coherente con ella [50] .

Este enfoque ofrece varias ventajas notables, permite producir explicaciones adaptadas al perfil del usuario final y puede aplicarse a una amplia variedad de contextos y modalidades, incluyendo explicaciones multimodales que combinan información textual y visual [51]. Aún así presenta dos limitaciones principales, este modelo supone que las explicaciones están disponibles en el conjunto de entrenamiento, lo cual no siempre es cierto en la práctica y aparte, las explicaciones generadas pueden no reflejar fielmente el razonamiento real del modelo, sino más bien ajustarse a lo que el usuario espera o desea ver, comprometiendo su validez como herramienta de auditoría ya que no es completamente objetivo.

Para superar estas limitaciones se han propuesto métodos que no requieren explicaciones explícitas de cada muestra del conjunto de entrenamiento. Uno de estos modelos solo necesita las etiquetas de clase, una descripción textual general durante el entrenamiento, ofreciendo explicaciones visuales específicas por clase. Otro enfoque relevante es un modelo que se divide en dos

módulos entrenados de forma conjunta, un generador y un codificador. El generador selecciona los fragmentos más representativos del texto de entrada que puedan servir como explicación para una predicción determinada. El codificador así realiza las predicciones básicas basándose exclusivamente en las explicaciones generadas por el módulo anterior, siendo un sistema más transparente y trazable [52] . No obstante, proporcionar una justificación no siempre es suficiente para que un usuario comprenda completamente el proceso de decisión. En muchos casos, se requiere un nivel adicional de interpretación contextual, que conecte las explicaciones con el conocimiento del dominio o con representaciones visuales y lingüísticas más ricas [53] .

En resumen, los enfoques de predicción y explicación conjuntas representan un avance importante hacia modelos de inteligencia artificial que no solo sean precisos, sino también transparentes y auditables, capaces de explicar su razonamiento de forma automática y comprensible para el ser humano.

3.2.4. Explicabilidad mediante ajustes arquitectónicos

Otra vía efectiva para mejorar la explicabilidad de los modelos de inteligencia artificial consiste en modificar la arquitectura de las redes neuronales, de forma que la estructura misma del modelo favorezca la comprensión de su funcionamiento interno. Este enfoque no depende de métodos externos de interpretación, sino que busca que el modelo sea explicable por diseño (explainable-by-design).

Tenemos el ejemplo de una red neuronal convolucional explicable, cuyo objetivo es que las representaciones generadas en las capas superiores de la red correspondan a componentes semánticos de los objetos, en lugar de simples combinaciones de patrones abstractos. Para lograrlo, se introduce una función de pérdida específica aplicada sobre los mapas de características (feature maps) de una CNN convencional. Esta función de pérdida fomenta que ciertos filtros se activen únicamente ante partes concretas del objeto dentro de una categoría determinada, mientras permanecen inactivos en imágenes de otras clases.

Un aspecto especialmente destacable de este método es que no requiere anotaciones de componentes de objetos, es decir, la red aprende a identificar partes relevantes sin supervisión explícita. Como resultado, las CNN explicables almacenan información más significativa en sus filtros de alto nivel que las redes convolucionales tradicionales, facilitando una interpretación más clara de qué regiones o patrones han influido en una decisión concreta.

Por otra parte, los mecanismos de atención (Attention Mechanisms) han adquirido un papel central en el diseño de modelos explicables, transformando la manera en que se aplican los algoritmos de aprendizaje profundo. Estos mecanismos se han utilizado ampliamente en procesamiento del lenguaje na-

tural (NLP), visión por computador y modelado de series temporales. Su función principal es identificar qué partes del conjunto de entrada son más relevantes para la tarea en cuestión, asignando pesos o puntuaciones a cada componente de entrada, lo que se representa mediante un mapa de atención (Attention Map) [54] .

Con el objetivo de analizar el comportamiento interno del modelo, he extraído diferentes mapas de atención correspondientes a una frase procesada por BERT. Estos mapas representan las relaciones de atención entre los tokens de entrada, permitiendo observar cómo cada palabra distribuye su atención sobre el resto de elementos de la secuencia. La visualización de estos patrones resulta útil para estudiar la forma en que el modelo construye representaciones contextuales. En particular, permite identificar qué tokens reciben mayor atención, qué relaciones aparecen entre palabras y cómo estas interacciones pueden influir en la decisión final del clasificador.




Figura 3.1: Mapas de atención obtenidos a partir del análisis interno del modelo BERT.

En términos generales, las redes neuronales explicables suelen incorporar algún tipo de módulo de atención, ya que este mecanismo proporciona una forma intuitiva de visualizar qué características influyen más en la decisión del modelo. Sin embargo, la atención no debe confundirse con una explicación propiamente dicha. Los ajustes arquitectónicos orientados a la explica-

bilidad, ya sea mediante capas de prototipos, funciones de pérdida especializadas o mecanismos de atención, constituyen una estrategia fundamental para construir modelos más transparentes, interpretables y alineados con el razonamiento humano, sin comprometer su rendimiento predictivo.

3.2.5. Explicabilidad mediante regularización

Las técnicas de regularización se han utilizado tradicionalmente para mejorar la capacidad de generalización y el rendimiento predictivo de los modelos de inteligencia artificial. Sin embargo, en los últimos años también se han convertido en una herramienta poderosa para incrementar la explicabilidad de los modelos, al incorporar restricciones que orientan el proceso de aprendizaje hacia comportamientos más comprensibles y coherentes con el conocimiento humano.

Un ejemplo representativo es la **Tree Regularization** que consiste en fomentar que el modelo aprenda una frontera de decisión que pueda ser bien aproximada mediante un árbol de decisión de tamaño reducido. Esto se logra introduciendo una función de pérdida, basada en un término adicional de regularización, durante el entrenamiento, de manera que penalice las configuraciones excesivamente complejas o alejadas de una estructura arbórea [55]. Aparte existe una amplia línea de investigación dedicada a emplear la regularización como medio para restringir las explicaciones generadas por el modelo, asegurando que las decisiones sean correctas por las razones adecuadas (right for the right reasons) [56].

Los experimentos realizados con explicaciones simuladas en diferentes tareas demostraron que el aprendizaje basado en saliencia (Saliency Learning) produce resultados más precisos, estables y coherentes, reforzando la idea de que la regularización, además de mejorar la capacidad predictiva, puede servir como un mecanismo explícito de control sobre la interpretabilidad de los modelos de inteligencia artificial. Este enfoque se basa en el uso de anotaciones expertas para concentrar la atención del modelo en las partes más relevantes de la entrada y evitar que se enfoque en elementos irrelevantes. A diferencia de otros métodos, estas anotaciones se aplican a nivel de embeddings de palabras, en lugar de hacerlo directamente sobre las dimensiones de entrada [57].

A nivel de resumen, las estrategias de regularización aplicadas a la explicabilidad permiten moldear el proceso de aprendizaje de manera que los modelos no solo aprendan a predecir con precisión, sino también a justificar sus decisiones de manera comprensible, coherente y alineada con el conocimiento experto.

3.3. Post-Hoc Explainability

Una vez abordadas las cuestiones relacionadas con la explicabilidad de los datos y los modelos, es el momento de profundizar en la explicabilidad post-hoc, es decir, aquellas técnicas que se aplican después del entrenamiento del modelo para comprender su comportamiento o justificar sus decisiones.

La explicabilidad post-hoc se centra en analizar los modelos ya entrenados, especialmente los considerados “de caja negra”, como las redes neuronales profundas o los ensamblajes de modelos complejos, con el fin de revelar cómo y por qué producen determinadas predicciones.

En el aprendizaje supervisado, un modelo puede representarse como una función, que recibe un vector de entrada y devuelve una salida esperada. Durante el proceso de entrenamiento, este modelo aprende a partir de un conjunto de datos etiquetados. Dependiendo de la naturaleza de la salida, el problema se puede clasificar como clasificación (si la salida toma valores discretos) o regresión (si toma valores continuos). Para evaluar el rendimiento del modelo, se utiliza una función de error o pérdida, que mide la discrepancia entre las predicciones del modelo y las etiquetas reales. El objetivo del aprendizaje supervisado consiste en minimizar la pérdida promedio sobre el conjunto de datos.

En el contexto de la explicabilidad post-hoc, una vez que el modelo está entrenado, el desafío consiste en analizar el comportamiento interno de la manera en la que se ha obtenido la hipótesis óptima con el menor error posible dentro de su espacio de hipótesis, para identificar qué variables, características o estructuras de entrada influyen en sus decisiones y en qué medida.

3.3.1. Métodos de atribución

Dentro del ámbito de la visión por computador, los métodos de atribución constituyen una de las aproximaciones más extendidas para lograr explicaciones visuales. Su objetivo principal es determinar qué píxeles o regiones de una imagen de entrada son relevantes para una predicción específica.

En términos generales, cada píxel recibe un valor de atribución que cuantifica su relevancia o contribución a la activación del modelo. El objetivo de un método de atribución es, por tanto, asignar a cada píxel un valor numérico que refleje su influencia en la decisión final del modelo, permitiendo visualizar qué partes de la imagen guiaron la predicción.

3.3.1.1. Deep Taylor Descomposition (DTD)

Explica las decisiones de una red neuronal descomponiendo la salida del modelo en contribuciones de primer orden de las entradas. Cada valor de salida expresa como una suma de relevancias asociadas a los píxeles, la técnica ignora los términos de orden superior a la expansión de Taylor (centrándose en los componentes lineales que explican parcialmente la decisión), y el resultado es un mapa de relevancia por píxel, útil para visualizar qué regiones de la imagen influyeron en la clasificación.

La ventaja de esta familia es que proporciona una explicación matemática coherente, mientras que una de sus limitaciones es que puede perder información compleja al omitir términos de orden superior [58] .

3.3.1.2. Métodos de Perturbación

Estos métodos calculan la importancia de una característica modificando o eliminando partes de la entrada y observando el cambio en la salida. Son intuitivos pero computacionalmente costosos, ya que requieren múltiples evaluaciones del modelo. Incluyen variables basadas en modelos sustitutos que explican local o globalmente el comportamiento del modelo principal.

LIME (Local Interpretable Model-Agnostic Explanations) genera modelos locales interpretables — como regresiones lineales o árboles de decisión — en el entorno de una instancia específica mediante la creación de perturbaciones en los datos de entrada. Su objetivo es aproximar el comportamiento del modelo complejo en una región cercana al ejemplo analizado [59] .

LORE (Local Rule-based Explanation) construye explicaciones locales en forma de reglas interpretables utilizando algoritmos genéticos para generar ejemplos sintéticos y árboles de decisión para extraer reglas comprensibles que describan la predicción del modelo [60] .

CluReFI (Cluster Representative with Feature Importance) extiende el enfoque de LIME al análisis de agrupamientos, proporcionando explicaciones a nivel de cluster. Identifica y visualiza las características más relevantes que describen cada grupo de datos [61] .

SP-LIME (Submodular Pick LIME) selecciona un subconjunto óptimo de ejemplos representativos con el fin de explicar el comportamiento global del modelo, maximizando la cobertura explicativa dentro de un presupuesto limitado de complejidad [59] .

NormLIME integra múltiples explicaciones locales generadas por LIME para construir una visión global de la importancia de las caracterís-

ticas. Utiliza técnicas de regularización como LASSO para identificar patrones consistentes en las explicaciones [62] .

anchors Produce reglas interpretables del tipo if-then que explican predicciones individuales con alta fidelidad local. A diferencia de LIME, garantiza que la regla encontrada mantenga su validez dentro de una región bien definida del espacio de datos, mejorando la precisión interpretativa [63] .

3.3.1.3. Métodos de Retropropagación (Backpropagation Methods)

Estos enfoques calculan la contribución de cada entrada usando gradientes durante la retropropagación. Son más rápidos que los métodos de perturbación, ya que requieren menos evaluaciones del modelo.

DeconvNet reconstruye las activaciones intermedias de una red convolucional proyectándolas de nuevo al espacio de entrada, con el objetivo de identificar qué píxeles contribuyeron a la activación de determinados filtros [64] .

Grad-CAM (Gradient-weighted Class Activation Mapping) genera mapas de calor que resaltan las regiones más relevantes para una clase específica utilizando la información de los gradientes de la última capa convolucional [65] .

Guided Backpropagation y Guided Grad-CAM combinan la técnica Grad-CAM con la retropropagación guiada para producir visualizaciones más precisas y discriminativas, mejorando la localización fina de las características relevantes [65], [66] .

Score-CAM sustituye el uso directo de gradientes por el incremento en la confianza del modelo al enmascarar regiones de la imagen, reduciendo el ruido y mejorando la estabilidad de las explicaciones [67] .

Vanilla Gradient (Saliency Maps) Calcula los gradientes de la salida respecto a la entrada para identificar las regiones con mayor influencia en la predicción. Es un método sencillo y computacionalmente eficiente, aunque puede generar mapas ruidosos [68] .

SmoothGrad mejora los mapas de gradiente promediando múltiples explicaciones obtenidas tras añadir ruido gaussiano a la entrada, lo que incrementa la estabilidad y claridad visual [69].

Integrated Gradients (IG) Estima la relevancia acumulada integrando los gradientes a lo largo de un camino que conecta una imagen base (por ejemplo, una imagen negra) con la imagen real, proporcionando explicaciones más consistentes y teóricamente fundamentadas [70] .

3.3.1.4. Deep LIFT (Deep Learning Important Features)

DeepLIFT asigna relevancias comparando las activaciones del modelo con respecto a una referencia base (por ejemplo, una entrada nula). Mide las diferencias en las activaciones de cada neurona entre la entrada real y la referencia.

Propaga estas diferencias hacia atrás a lo largo de la red para obtener la contribución de cada característica. Se considera una extensión más eficiente del Layer-wise Relevance Propagation (LRP) [71] .

Una de sus cualidades es que calcula contribuciones más estables y coherentes que los gradientes tradicionales. Pero requiere elegir adecuadamente la referencia, lo que puede afectar la interpretación final.

3.3.2. Métodos de Visualización

La visualización de modelos constituye una herramienta esencial para comprender el funcionamiento interno de los algoritmos de aprendizaje automático, especialmente en entornos supervisados. Mediante la representación gráfica de las relaciones entre características y predicciones, estas técnicas permiten explorar los patrones subyacentes y evaluar de qué manera los distintos atributos influyen en el comportamiento del modelo. En esta sección se presentan las principales aproximaciones utilizadas, junto con una explicación detallada de sus fundamentos, ventajas y limitaciones.

3.3.2.1. Gráfico de Dependencia Parcial (PDP)

El PDP es una técnica ampliamente utilizada para analizar cómo varía la predicción promedio de un modelo cuando una característica concreta cambia a lo largo de su rango de valores, manteniendo las demás constantes. De este modo, se obtiene una representación de la influencia global que ejerce una variable sobre las predicciones del modelo, lo que facilita la interpretación del comportamiento general del sistema.

En el gráfico resultante, el eje horizontal muestra los valores posibles de la característica analizada, mientras que el eje vertical representa la predicción promedio del modelo. Además, se suelen incluir elementos visuales complementarios, como una línea roja que indica el valor medio estimado, un histograma con la distribución de los datos reales y líneas de puntos que reflejan un intervalo de una desviación estándar alrededor de la media.

El PDP permite observar tendencias globales, aunque puede verse afectado por la correlación entre variables, lo que podría incluir interpretaciones erróneas. Entre sus ventajas encontramos que es sencillo, intuitivo y útil para

obtener una visión general del efecto de una característica, pero en su contra pueden producirse resultados distorsionados si las variables presentan una dependencia mutua.

Con el fin de visualizar de forma más clara el funcionamiento de los gráficos de dependencia parcial, en la Figura 3.2 se muestra un ejemplo de PDP aplicado a un modelo de regresión. En ella se observan dos gráficos de dependencia parcial unidimensionales, donde se analiza por separado el efecto de variables como la temperatura y la humedad sobre la predicción media del modelo, y un gráfico bidimensional que representa el efecto conjunto de ambas variables. Esta representación permite comprender cómo cambia la respuesta estimada del modelo al variar una o varias características de entrada, manteniendo el resto de variables marginalizadas.




Figura 3.2: Ejemplo de gráficos de dependencia parcial unidimensionales y bidimensionales. La figura muestra cómo varía la predicción media del modelo en función de distintas características de entrada. Fuente: documentación de Scikit-learn.

3.3.2.2. Expectativas Condicionales Individuales (ICE)

Los ICE plots son una extensión del PDP que permiten analizar la influencia de una característica a nivel individual, en lugar de hacerlo de forma agregada. En este caso, se representa una curva por cada observación del conjunto de datos, mostrando cómo varía la predicción del modelo cuando se modifica la característica de interés para esa instancia específica, manteniendo fijas las demás.

A diferencia del gráfico de dependencia parcial, que muestra el efecto medio de una variable sobre la predicción del modelo, los gráficos ICE permiten analizar ese efecto de forma individual para cada muestra del conjunto de datos. En la Figura 3.3 se representa esta idea mediante varias curvas individuales, donde cada línea muestra cómo cambia la predicción para una observación concreta al variar una característica determinada.

Este tipo de representación resulta útil para detectar comportamientos heterogéneos que podrían quedar ocultos en un PDP. Mientras que la curva promedio resume la tendencia global, las curvas ICE permiten observar si todas las muestras siguen un patrón similar o si existen diferencias importantes entre ellas.




Figura 3.3: Ejemplo de gráficos ICE junto con la curva promedio de dependencia parcial. Cada línea representa el comportamiento individual de una muestra al variar una característica de entrada. Fuente: documentación de Scikit-learn.

Existen variantes de este método, como las ICE centradas o las ICE derivadas, que permiten identificar con mayor precisión efectos locales y posibles interacciones no lineales. Este sistema revela diferencias individuales y heterogeneidad en las respuestas del modelo pero es menos legible en conjuntos de datos muy grandes y susceptible a ruido o solapamiento visual.

3.3.2.3. Efectos Locales Acumulados (ALE)

El método ALE constituye una alternativa moderna a los PDP e ICE, diseñada para evitar los problemas derivados de la extrapolación en presencia de variables correlacionadas. A diferencia del PDP, el ALE no promedia directamente las predicciones, sino que acumula los cambios locales en las predicciones a lo largo del rango de la característica analizada.

En esencia, el ALE estima cómo varía la predicción del modelo cuando una característica cambia dentro de pequeños intervalos, promediando las diferencias locales y luego acumulándolas para representar el efecto global. Además, se centra restando una constante para que el promedio del efecto sea cero,

lo que facilita la comparación entre variables.

Este enfoque presenta tres diferencias principales con respecto al PDP, una de ellas es que promedia los cambios en la predicción en lugar de las predicciones mismas, a parte, evalúa los efectos locales mediante derivadas parciales acumuladas y además se centra en el resultado restando el valor medio, de forma que el efecto global promedio sea nulo.

3.3.3. Métodos de explicación basados en ejemplos

Las explicaciones basadas en ejemplos, también conocidas como case-based explanations, constituyen un enfoque interpretativo que permite comprender el comportamiento de un modelo de aprendizaje automático mediante instancias concretas de datos. En lugar de analizar los parámetros internos del modelo, estas técnicas explican sus decisiones a partir de ejemplos representativos, casos contrafactuales o instancias contrastivas.

En este Trabajo Fin de Grado, el caso de estudio se enmarca dentro de esta perspectiva, ya que el análisis se realizará a partir de ejemplos concretos procesados por un modelo de clasificación de sentimiento basado en BERT. En lugar de estudiar el modelo únicamente desde una perspectiva global, se analizarán predicciones individuales y sus correspondientes patrones internos, prestando especial atención a las matrices y mapas de atención generados para distintas frases. De esta forma, cada ejemplo permite observar cómo el modelo distribuye la atención entre los distintos tokens de entrada y qué elementos parecen tener mayor influencia en la clasificación final.

3.3.3.1. Prototipos y Críticas

Los prototipos son ejemplos concretos del conjunto de datos que representan de manera efectiva la estructura o distribución general de la información. En cambio, las críticas son ejemplos atípicos o poco representados que, aunque no encajan con los prototipos, ofrecen información complementaria útil para comprender mejor los límites o las excepciones del modelo.

Visualmente, puede imaginarse que los prototipos se sitúan en el centro de los grupos de datos, mientras que las críticas se localizan en zonas periféricas o marginales de la distribución.

Uno de los métodos clásicos para identificar prototipos es K-medoids, una técnica de agrupamiento similar a k-means que selecciona como centroide un ejemplo real del conjunto. Sin embargo, este tipo de métodos no consideran la selección de críticas [72] .

Para resolver esta limitación, se desarrolló el método MMD-critic (Maximum Mean Discrepancy critic) [73] , que integra la búsqueda de prototipos y

críticas en un mismo marco. Este método compara la distribución de los datos reales con la distribución de los prototipos seleccionados mediante una medida de discrepancia media cuadrática (MMD) . A través de una búsqueda greedy, identifica las instancias que mejor representan los datos (prototipos) y aquellas que más difieren (críticas) . Utiliza una función kernel para estimar densidades de datos y una función testigo (witness function) para detectar diferencias locales entre ambas distribuciones.

3.3.3.2. Contrafactuales

Las explicaciones contrafactuales responden a la siguiente pregunta; “¿Qué tendría que cambiar en esta entrada para que el modelo hubiera dado una predicción diferente?”

A diferencia de los prototipos, los contrafactuales no necesitan existir en el conjunto de datos original, sino que pueden ser instancias sintéticamente generadas. Estas buscan modificar lo mínimo posible la instancia original para alcanzar un resultado alternativo.

Una de las posibles soluciones es mediante una función de pérdida que equilibra dos objetivos, minimizar la distancia entre la predicción del contrafactual y el resultado deseado, y minimizar la diferencia entre la instancia original y la contrafactual, garantizando que el cambio sea lo más pequeño posible. La ponderación entre ambos objetivos se controla mediante un parámetro de equilibrio, que ajusta el compromiso entre proximidad y precisión.

3.3.3.3. Ejemplos adversarios

Los ejemplos adversarios son instancias especialmente diseñadas para engañar a los modelos de aprendizaje profundo, provocando predicciones erróneas mediante pequeñas perturbaciones imperceptibles. Aunque su origen se asocia a la detección de vulnerabilidades en redes neuronales, estos ejemplos también pueden aprovecharse con fines explicativos y analógicos. En este contexto, se distinguen dos enfoques interpretativos [74] .

- **Explicaciones analógicas** de manera que se fundamentan en el razonamiento por analogía, estableciendo comparaciones entre casos familiares y no familiares con el objetivo de justificar una decisión del modelo. Este tipo de explicación facilita la comprensión al relacionar la predicción con ejemplos previamente conocidos o similares, permitiendo interpretar el resultado a partir de patrones comparables [75] .
- **Explicaciones contrastivas** las cuáles se apoyan en el razonamiento por contraste, comparando dos situaciones opuestas o en competencia

para identificar las diferencias determinantes que han conducido a una predicción concreta. En lugar de explicar únicamente por qué ocurrió un resultado, este enfoque responde a preguntas del tipo “¿por qué esta predicción y no otra?”, destacando los factores diferenciales más relevantes [76] .

Estas explicaciones permiten entender los límites de decisión del modelo, al mostrar cómo una pequeña variación puede modificar el resultado, lo que resulta especialmente útil en tareas de clasificación complejas o de alto impacto.

3.3.4. Métodos basados en teoría de juegos

El uso de la teoría de juegos en la explicabilidad de modelos de inteligencia artificial surge a partir de una idea clásica introducida por Lloyd Shapley (1953) [77] . Se basa en determinar la contribución individual de cada jugador dentro de un juego cooperativo, es decir, cuánto aporta cada participante al resultado final del grupo. Este razonamiento ha sido posteriormente adaptado al contexto del machine learning (ML) para evaluar cuánto contribuye cada característica (feature) al resultado de una predicción individual.

- **El “juego”**: Representa la predicción que realiza el modelo sobre una instancia concreta del conjunto de datos. En el marco de la teoría de juegos aplicada a la interpretabilidad, cada predicción individual se analiza como una partida en la que intervienen distintos factores.
- **El “beneficio” o “ganancia”**: Corresponde a la diferencia entre la predicción obtenida para una instancia específica y la predicción media calculada sobre todo el conjunto de datos. Esta magnitud cuantifica el efecto adicional generado por la combinación particular de características presentes en la instancia analizada.
- **Los “jugadores”**: Son las características de entrada del modelo, que interactúan y cooperan entre sí para producir el resultado final. Cada una de ellas aporta una contribución parcial a la predicción, la cual puede cuantificarse mediante valores de atribución como los valores de Shapley.

De este modo, permite cuantificar la contribución individual de cada característica en la predicción del modelo, proporcionando así una medida formal y equitativa de explicabilidad.

3.3.4.1. Shapley Additive Explanations (SHAP)

El método SHAP (SHapley Additive exPlanations), constituye una extensión práctica y eficiente de los valores de Shapley para la interpretación de modelos de aprendizaje automático.

SHAP proporciona un marco unificado para explicar las predicciones individuales de cualquier modelo, combinando las propiedades teóricas de los valores de Shapley con un enfoque aditivo de atribución de características. Cumple tanto las propiedades de los valores de Shapley (eficiencia, simetría, nulo y aditividad) como otras adicionales propias de su formulación.

- **Precisión local** (*local accuracy*) la suma de los valores SHAP debe igualar la predicción del modelo.
- **Ausencia** (*missingness*) establece que aquellas características que no participan en una predicción (es decir, que están ausentes en la coalición considerada) no deben influir en la explicación. En consecuencia, su valor SHAP debe ser igual a cero, garantizando que únicamente las variables presentes contribuyan a la atribución final.
- **Consistencia** si, en un modelo actualizado, una determinada característica incrementa su contribución al resultado en comparación con el modelo anterior, su valor SHAP no debe disminuir. Esta propiedad asegura coherencia en la asignación de relevancia cuando el comportamiento del modelo cambia.
- **KernelSHAP** implementación general de SHAP basada en un enfoque de estimación mediante funciones kernel, inspirado en modelos sustitutos locales similares a LIME. Es un método agnóstico al modelo, lo que permite aplicarlo a cualquier algoritmo de aprendizaje automático, aunque con mayor coste computacional [78] .
- **TreeSHAP** variante optimizada para modelos basados en árboles de decisión, como Random Forest o XGBoost. Aprovecha la estructura interna del modelo para calcular los valores SHAP de forma exacta y computacionalmente eficiente, reduciendo significativamente el tiempo de ejecución en comparación con métodos generales [79] .

Además, los valores SHAP pueden agregarse para proporcionar explicaciones globales del modelo, mostrando el impacto promedio de cada variable sobre el resultado.

- **Interpretabilidad local** los valores SHAP se asignan a cada observación individual, permitiendo analizar por qué se obtuvo una predicción concreta.

- **Interpretabilidad global** al promediar los valores SHAP de todas las instancias, se obtiene una visión general de qué variables son más influyentes y si su efecto es positivo o negativo sobre la variable objetivo.

3.3.5. Métodos de extracción de conocimiento

Uno de los principales retos en la explicabilidad de modelos de inteligencia artificial radica en describir y comprender el comportamiento interno de los modelos de tipo caja negra, especialmente de las redes neuronales artificiales (ANN). Durante el proceso de entrenamiento, estas redes ajustan sus parámetros, lo que genera representaciones internas complejas y difíciles de interpretar directamente por humanos.

La extracción de conocimiento busca precisamente recuperar y traducir la información aprendida por el modelo a un formato comprensible para el ser humano, sin comprometer excesivamente su precisión. Dentro de este ámbito, las investigaciones se han centrado principalmente en dos grandes enfoques; Extracción de reglas (Rule Extraction) y Destilación de modelos (Model Distillation).

3.3.5.1. Extracción de reglas (Rule Extraction)

La extracción de reglas consiste en producir una aproximación inteligible del comportamiento de una red neuronal entrenada, generando un conjunto de reglas que describen de forma simplificada la lógica de sus predicciones. En otras palabras, se busca traducir el conocimiento numérico codificado en los pesos de la red a reglas simbólicas y lógicas que puedan ser entendidas por expertos o usuarios finales. Existen diferentes tipos de reglas que pueden derivarse de un modelo.

- **Reglas tipo if-then:** Son la forma más simple y universal de explicación simbólica, expresándose de la siguiente manera “Esto significa que si una entrada cumple ciertas condiciones, entonces la salida pertenece a una clase específica”.

Estas reglas pueden enriquecerse con lógica difusa, utilizando etiquetas lingüísticas como bajo, medio o alto, asociadas a funciones de pertenencia. Las reglas difusas permiten capturar gradientes de incertidumbre o ambigüedad en la toma de decisiones.

- **Reglas m-of-n:** Este tipo de reglas emplea una expresión booleana para definir condiciones donde al menos M de N predicados deben cumplirse para que se produzca una determinada conclusión.

En función del tipo de razonamiento, las reglas pueden clasificarse en dos tipos. **Lógica proposicional o booleana**, cuando las condiciones son binarias (verdadero/falso). **Lógica no convencional**, que incluye lógica difusa o probabilística para expresar conocimiento impreciso.

3.3.5.2. Destilación de modelos (Model Distillation)

La destilación de modelos es otro enfoque clave dentro de la extracción de conocimiento. Consiste en transferir la información aprendida por un modelo complejo, como una red neuronal profunda (DNN) , a un modelo más simple y comprensible, generalmente mediante un proceso de compresión del modelo.

Originalmente, esta técnica se desarrolló para reducir los costos computacionales y acelerar la inferencia en sistemas grandes. Sin embargo, con el tiempo, se ha demostrado su utilidad para mejorar la explicabilidad.

Durante la destilación, el modelo estudiante aprende no solo de las etiquetas verdaderas del conjunto de datos, sino también de las predicciones suavizadas del modelo inicial, conocidas como conocimiento oscuro (dark knowledge) . Estas predicciones contienen información adicional sobre las relaciones entre clases y la estructura interna del modelo complejo.

3.4. Métodos neuronales (Neural Methods)

Los métodos neuronales de interpretación buscan comprender cómo y por qué una red neuronal genera una determinada predicción. Estas técnicas intentan explicar decisiones específicas, simplificar la red o visualizar los conceptos y características que ha aprendido. En esta sección se presentan los dos enfoques más relevantes: los métodos de influencia y los métodos basados en conceptos.

3.4.1. Métodos de influencia

Los métodos de influencia analizan cómo cambia el rendimiento del modelo cuando se modifican las entradas o los elementos internos de la red. De este modo, permiten identificar qué características o instancias de entrenamiento tienen mayor peso en una predicción. Su objetivo es evaluar la importancia de las variables y mejorar la interpretabilidad y depuración del modelo.

- **Importancia de características (Feature Importance)** evalúa cuánto depende el modelo de cada característica para realizar una predicción. Se mide el impacto en el error del modelo al permutar

(reordenar) los valores de una variable. Si el error aumenta al alterar una característica, se considera importante. Y si el error no varía, la característica es irrelevante.

Existen variantes como LOCO (Leave-One-Covariate-Out) [80], que mide la importancia local de una variable, y MCR (Model Class Reliance) [81], un enfoque agnóstico al modelo. Un aspecto crucial es distinguir entre usar datos de entrenamiento o de prueba, en entrenamiento, mide la dependencia del modelo respecto a una característica (riesgo de sobreajuste). Y en prueba, refleja la verdadera contribución de la característica a la capacidad predictiva general.

- **Propagación de relevancia por capas (LRP)** esta técnica explica una predicción redistribuyendo la relevancia desde la salida hacia las capas iniciales de la red. El algoritmo conserva la relevancia total en cada paso, garantizando que la suma de las contribuciones de todas las neuronas equivale a la predicción original. De esta manera, se obtiene un mapa de relevancia que muestra qué partes de la entrada fueron más determinantes para el resultado.
- **Análisis de sensibilidad (Sensitivity Analysis, SA)** evalúa cómo varía la salida del modelo cuando se perturban ligeramente las entradas o los pesos. El método calcula la magnitud del gradiente local, lo que permite identificar qué características afectan más a la salida. Aunque no genera explicaciones directas, el SA es útil para evaluar la estabilidad y confiabilidad del modelo, así como para detectar variables irrelevantes o redundantes.

3.4.2. Métodos basados en conceptos

Los métodos basados en conceptos surgen como respuesta a la necesidad de explicaciones más interpretables y cercanas al lenguaje humano. En lugar de centrarse en valores de activación o pesos, estos enfoques relacionan los conceptos humanos con las representaciones internas de la red.

- **Vectores de activación de conceptos (Concept Activation Vectors, CAVs)** representan direcciones conceptuales dentro del espacio de activaciones de una red neuronal. Cada vector describe la frontera entre ejemplos que contienen un concepto de interés y aquellos que no. Esto permite medir cuánto influye un concepto humano concreto en la decisión del modelo.
- **Testing with CAVs (TCAV)** el método TCAV extiende el uso de los CAVs con el objetivo de cuantificar hasta qué punto un concepto concreto influye en la predicción de una clase determinada. Para ello,

primero se representa el concepto mediante un vector en el espacio interno de activaciones de la red. Posteriormente, se analiza si desplazar las activaciones en la dirección de dicho concepto aumenta o disminuye la salida asociada a una clase.

De forma más precisa, TCAV calcula la derivada direccional del *logit* de una clase respecto al vector del concepto. Si esta derivada es positiva, significa que el concepto contribuye favorablemente a la predicción de esa clase. Finalmente, el valor TCAV se obtiene evaluando esta sensibilidad sobre un conjunto de ejemplos, indicando qué proporción de predicciones se ven influidas positivamente por el concepto analizado.

En conclusión, los métodos neuronales de interpretación constituyen una de las líneas más avanzadas de la explicabilidad moderna, los métodos de influencia proporcionan una visión detallada sobre qué variables o ejemplos dominan las decisiones de la red y los métodos basados en conceptos ofrecen explicaciones más humanas y semánticas, vinculando las abstracciones internas del modelo con nociones comprensibles.

En conjunto, estos enfoques fortalecen la transparencia y confianza en las redes neuronales profundas, permitiendo analizar tanto su comportamiento interno como las razones detrás de sus predicciones.

3.5. XAI Transformer

Los Transformers se han consolidado como una herramienta fundamental en el ámbito del machine learning, dada su amplia variedad de aplicaciones en tareas de procesamiento del lenguaje, visión por computador y otros dominios. Esta creciente relevancia ha generado la necesidad de desarrollar métodos de interpretabilidad fiables que permitan aumentar la transparencia de estos modelos.

En esta sección ampliaremos el campo de la inteligencia artificial explicativa a los modelos transformer de manera que comprendamos como se pueden aplicar los conceptos teóricos y prácticos en este ámbito [82] .

Diversas técnicas de interpretabilidad, generalmente basadas en información de gradientes, han sido propuestas para este propósito. Sin embargo, se ha demostrado que el gradiente en los modelos Transformer refleja la función del modelo únicamente de manera local, lo que limita su capacidad para identificar de forma fiable la contribución de las características de entrada a la predicción final [70], [83] .

Una de las propuestas que se ha planteado es la aplicación de un método de propagación más estable a través de dichas capas, explicado como una extensión adecuada del método LRP (Layer-wise Relevance Propagation) aplicado

específicamente a arquitecturas Transformer. Se ha demostrado que tanto resultados teóricos como empíricos han logrado superar las limitaciones de los enfoques tradicionales basados en gradientes, alcanzando un rendimiento de vanguardia en tareas de explicación para una amplia gama de modelos Transformer y conjunto de datos.

3.5.1. Enfoques previos para la explicabilidad de Transformers

La literatura sobre explicabilidad en Transformers puede agruparse en tres grandes categorías.

- **Métodos basados en la atención:** Estos métodos extraen los mapas de atención de cada bloque del Transformer para visualizar la estrategia de decisión del modelo. El problema es que en algunas investigaciones se ha demostrado que en ciertas situaciones puede no recomendarse su uso, ya que las ponderaciones de atención no siempre reflejan la verdadera importancia de las características de entrada [84], [85] .
- **Métodos basados en gradientes:** Estos métodos estiman la importancia de las características de entrada a partir de la sensibilidad de la salida del modelo respecto a dichas entradas. En el caso de *Integrated Gradients*, la atribución se obtiene acumulando los gradientes a lo largo de un camino entre una entrada de referencia y la entrada real, proporcionando una estimación más estable que el gradiente calculado en un único punto.

No obstante, estos enfoques pueden presentar limitaciones, ya que los gradientes reflejan principalmente el comportamiento local del modelo y pueden generar explicaciones ruidosas o poco robustas en determinadas arquitecturas profundas.

- **Métodos basados en perturbaciones:** Estas aproximaciones evalúan como cambia la confianza del modelo o su salida cuando se modifican o eliminan partes de la entrada. Aunque su interpretación suele ser intuitiva, estos métodos resultan computacionalmente costosos y pueden generar explicaciones inestables en modelos de gran tamaño.

3.5.2. Perspectiva teórica sobre la explicabilidad en Transformers

Con el objetivo de establecer un marco teórico sólido, se centra en los principios axiomáticos empleados en la explicabilidad de redes neuronales convencionales.

El axioma de conservación, también conocido como de completitud o eficiencia, constituye uno de los pilares de este marco. Este principio establece que la suma de las contribuciones asignadas a las variables de entrada debe ser igual a la salida del modelo, garantizando que cada entrada explique una parte específica de la predicción. Diversas metodologías como LRP, Integrated Gradients o Gradient x Input (GI) se diseñan precisamente para cumplir o aproximar este axioma.

El método LRP, en particular, aplica el principio de conservación de forma estricta, asegurando que cada capa, componente o neurona redistribuya completamente su relevancia hacia las capas anteriores. Esto permite rastrear de manera precisa cómo la información fluye a lo largo de la red y qué partes de la entrada son responsables del resultado final.

3.5.2.1. Propagación en las cabezas de atención

El análisis de la propagación de relevancia en las cabezas de atención muestra que este mecanismo introduce una dificultad específica dentro de los modelos Transformer. En una capa de atención, la representación de cada token no depende únicamente de sí misma, sino también de su relación con el resto de tokens de la secuencia. Esta interacción se controla mediante los pesos de atención, que determinan qué partes de la entrada influyen con mayor intensidad en la representación final.

Desde el punto de vista de la explicabilidad, esto implica que la relevancia no siempre puede propagarse de forma directa y conservativa desde la salida hacia las entradas. La conservación de relevancia solo se mantiene bajo determinadas condiciones, por ejemplo, cuando las representaciones están adecuadamente centradas y no existe una correlación significativa entre las entradas y las funciones de compatibilidad utilizadas por la atención.

Cuando estas condiciones no se cumplen, la relevancia puede distribuirse de manera desigual entre las distintas cabezas de atención. Como consecuencia, algunas cabezas pueden aparecer sobrerrepresentadas en la explicación, mientras que otras pueden quedar infrarrepresentadas. Esta situación reduce la fiabilidad de las explicaciones obtenidas mediante métodos simples de atribución, ya que la importancia asignada a cada componente del modelo puede no reflejar fielmente su contribución real a la predicción.

3.5.2.2. Normalización por capa

La normalización por capa, o *LayerNorm*, es otro de los componentes del Transformer que puede afectar a la conservación de relevancia. Su función principal es estabilizar las activaciones internas del modelo mediante una operación de normalización basada en la media y la varianza de las represen-

taciones. Esta normalización mejora el entrenamiento y el comportamiento numérico de la red, pero introduce dificultades cuando se intenta explicar la predicción propagando relevancia hacia las entradas.

El problema surge porque *LayerNorm* modifica las activaciones de forma global dentro de cada representación. Esto significa que la salida normalizada de una característica no depende únicamente de su valor original, sino también del conjunto de valores presentes en la misma capa. Por esta razón, la relevancia no puede asignarse de manera independiente a cada entrada sin tener en cuenta el efecto conjunto de la normalización.

3.5.3. Nuevas reglas de propagación LRP para Transformers

A partir del análisis anterior, se identifican dos componentes especialmente problemáticos para la propagación de relevancia en Transformers, las cabezas de atención y la normalización por capa.

Para resolver esta limitación, se proponen nuevas reglas de propagación basadas en Layer-wise Relevance Propagation (LRP) [82]. Estas reglas están diseñadas específicamente para adaptarse a la estructura interna de los Transformers, manteniendo la conservación de relevancia y produciendo explicaciones más estables, coherentes y representativas del comportamiento real del modelo.

3.5.3.1. Regla de propagación para las cabezas de atención

En el caso de las cabezas de atención, la idea principal consiste en tratar el mecanismo de atención como una transformación localmente lineal durante la fase de explicación. Para ello, los pesos de atención se consideran constantes en el momento de propagar la relevancia. De esta forma, la atención puede interpretarse como una operación que redistribuye información desde las entradas hacia la salida mediante una combinación ponderada.

Esta aproximación permite propagar la relevancia en sentido inverso, desde la salida del modelo hacia los tokens de entrada, respetando mejor el principio de conservación. Así, la relevancia asignada a cada token depende de su contribución dentro de la operación de atención, evitando que las cabezas sean interpretadas de forma aislada o que se atribuya importancia de manera artificial a componentes que no han tenido una influencia real en la predicción.

3.5.3.2. Regla de propagación para LayerNorm

En el caso de *LayerNorm*, la regla propuesta busca adaptar la propagación de relevancia a la operación de normalización. Dado que esta capa transforma las activaciones utilizando información global de la representación, no resulta adecuado propagar la relevancia como si cada característica actuara de forma independiente.

La regla específica para *LayerNorm* tiene en cuenta la desviación de cada activación respecto a la media, así como el efecto de la normalización sobre el conjunto de características. De este modo, la relevancia de salida se redistribuye entre las entradas de una forma más coherente con la operación realizada por la capa.

Esta regla evita el colapso o la pérdida de relevancia que puede producirse con métodos más simples, como GI. En consecuencia, permite obtener explicaciones más fieles al funcionamiento interno del Transformer, especialmente en modelos profundos donde la normalización aparece en múltiples bloques sucesivos.

Capítulo 4

Planificación y Estimación de Costes

4.1. Planificación temporal

La planificación del presente Trabajo Fin de Grado se ha organizado con el objetivo de distribuir de forma progresiva las distintas fases de estudio, desarrollo, experimentación y redacción. Dado que el trabajo combina una parte teórica extensa sobre Inteligencia Artificial Explicativa con una prueba de concepto práctica basada en BERT, PCA, oMEDA, SHAP, PLS-DA y ASCA ha sido necesario dividir el proyecto en varias etapas diferenciadas.

La planificación se ha realizado tomando como referencia un diagrama de Gantt, en el que se recogen las principales tareas desarrolladas a lo largo del proyecto. El periodo total considerado se extiende desde el 1 de octubre de 2025 hasta el 22 de junio de 2026. Durante este intervalo se han solapado algunas fases, especialmente aquellas relacionadas con el estudio teórico, el diseño de pruebas y la redacción de la memoria.

4.2. Fases del proyecto

El desarrollo del trabajo se ha estructurado en siete fases principales. Cada una de ellas se corresponde con una parte concreta de la memoria o con una actividad necesaria para la elaboración del proyecto.

4.2.1. Estudio de modelos de inteligencia artificial

La primera fase se ha centrado en el estudio de los fundamentos de los modelos de inteligencia artificial. En esta etapa se han revisado los principales

enfoques de aprendizaje automático, diferenciando entre modelos de *Machine Learning* tradicional, modelos de aprendizaje profundo y arquitecturas modernas basadas en *Transformers*. Un aspecto especialmente relevante de este trabajo es el punto de partida desde el que se ha desarrollado. Antes de iniciar el proyecto, mi experiencia práctica en inteligencia artificial se limitaba únicamente a un ejemplo básico de *Machine Learning*, por lo que abordar un estudio centrado en modelos *Transformer*, técnicas de explicabilidad y análisis multivariante ha supuesto un reto considerable. Precisamente por ello, el desarrollo de este TFG adquiere un valor añadido, ya que refleja un proceso de aprendizaje progresivo que ha permitido pasar de una base muy inicial a la construcción de una metodología completa de análisis explicativo sobre un modelo BERT.

Esta fase ha servido como base conceptual para comprender el funcionamiento de los modelos utilizados posteriormente en el caso de estudio. En particular, ha permitido contextualizar el papel de BERT dentro de los modelos de lenguaje actuales y justificar la necesidad de aplicar técnicas de explicabilidad sobre arquitecturas complejas.

4.2.2. Estudio de la Inteligencia Artificial Explicativa

La segunda fase se ha dedicado al estudio de la Inteligencia Artificial Explicativa, conocida como XAI. En esta parte se han analizado los principales métodos y enfoques existentes para interpretar modelos de inteligencia artificial, incluyendo explicabilidad de los datos, explicabilidad del modelo y explicabilidad *post-hoc*.

También se ha prestado especial atención a la explicabilidad en modelos *Transformer*, debido a la relación directa con el caso de estudio desarrollado. Esta fase ha permitido identificar las limitaciones de los métodos basados únicamente en atención o gradientes y ha servido como fundamento para justificar el análisis posterior mediante mapas de atención y técnicas multivariantes.

4.2.3. Definición de materiales y métodos

En la tercera fase se han definido los materiales y métodos utilizados en la prueba de concepto. Se ha seleccionado el modelo `textattack/bert-base-uncased-SST-2`, previamente ajustado para clasificación binaria de sentimiento, y se han estudiado las herramientas necesarias para extraer sus mapas de atención.

Además, se han definido las técnicas de análisis utilizadas posteriormente: el Análisis de Componentes Principales (PCA), oMEDA, SHAP, PLS-DA y ASCA. Esta fase ha sido clave para establecer la metodología general del

trabajo y preparar el flujo de procesamiento entre Python y MATLAB.

4.2.4. Diseño de pruebas

La cuarta fase corresponde al diseño experimental. En ella se ha construido el conjunto de frases utilizado en el análisis, formado por 40 frases generadas mediante inteligencia artificial y distribuidas de forma equilibrada entre 20 frases positivas y 20 frases negativas.

También se ha definido la longitud fija de entrada de 8 tokens, incluyendo los tokens especiales [CLS] y [SEP]. Esta decisión ha permitido obtener matrices de atención homogéneas para todas las frases. A partir de las 12 capas y 12 cabezas de atención del modelo BERT, cada frase queda representada mediante 9216 variables de atención.

4.2.5. Análisis de resultados

La quinta fase se ha centrado en el análisis de los resultados obtenidos. En primer lugar, se ha aplicado PCA sobre la matriz de atención para estudiar la estructura global de las observaciones y comprobar si existían agrupamientos diferenciados entre frases positivas y negativas.

Posteriormente, se ha implementado manualmente oMEDA en MATLAB para identificar qué variables de atención contribuyen en mayor medida a la diferencia entre ambos grupos. Este análisis ha permitido estudiar la importancia de las variables, la contribución acumulada y la distribución de relevancia por capas y cabezas de atención. Así como su comparación con otros métodos como SHAP, PLS-DA y ASCA.

4.2.6. Redacción y revisión de la memoria

La sexta fase ha consistido en la redacción, revisión y unificación de la memoria. En esta etapa se han completado los apartados de introducción, planificación, conclusiones y revisión formal del documento. También se ha revisado la coherencia entre capítulos, la numeración de figuras y cuadros, el formato de las referencias bibliográficas y la estructura general del trabajo.

4.2.7. Preparación de la presentación

La última fase se ha dedicado a la preparación de la presentación del Trabajo Fin de Grado. Esta etapa incluye la selección de los resultados más relevantes, la síntesis de la metodología aplicada y la preparación de una exposición clara y ordenada para la defensa.

4.3. Diagrama de Gantt

En la Figura 4.1 se muestra la planificación temporal seguida durante el desarrollo del proyecto. El diagrama recoge las tareas principales y su distribución a lo largo de los meses de trabajo.

A continuación se muestra el esquema correspondiente al diagrama de Gantt del proyecto:




Figura 4.1: Diagrama de Gantt correspondiente a la planificación temporal del Trabajo Fin de Grado.

4.4. Resumen de la planificación

En el Cuadro 4.1 se recoge un resumen de las tareas principales, junto con sus fechas aproximadas de inicio y finalización.

Tarea	Inicio	Fin	Descripción
T2. Modelos de IA	01/10/2025	25/11/2025	Estudio de los modelos de inteligencia artificial, aprendizaje automático, aprendizaje profundo y arquitecturas Transformer.
T3. XAI	04/11/2025	23/12/2025	Revisión de técnicas de Inteligencia Artificial Explicativa y métodos aplicados a modelos complejos.
T5. Materiales y métodos	09/12/2025	02/03/2026	Selección del modelo BERT, definición de herramientas, técnicas PCA, oMEDA, SHAP, PLS-DA, ASCA y planteamiento metodológico.
T6. Diseño de pruebas	02/02/2026	01/05/2026	Construcción del conjunto experimental, extracción de mapas de atención y preparación de la matriz de datos.
T7. Análisis de resultados	17/03/2026	08/06/2026	Aplicación de PCA, oMEDA, SHAP, PLS-DA y ASCA, análisis de gráficas, interpretación de resultados y obtención de conclusiones parciales.
Documentación final	15/05/2026	25/06/2026	Revisión global de la memoria, corrección de formato, referencias, figuras, cuadros y redacción final.
Presentación	17/06/2026	25/06/2026	Preparación de la exposición oral y selección de resultados principales para la defensa.

Cuadro 4.1: Resumen de la planificación temporal del Trabajo Fin de Grado.

4.5. Estimación de recursos

Para el desarrollo del trabajo se han empleado distintos recursos humanos, hardware y software. Al tratarse de un Trabajo Fin de Grado de carácter académico, muchos de estos recursos no han supuesto un coste económico directo, ya que se han utilizado herramientas de libre acceso o licencias académicas disponibles para estudiantes. Aun así, resulta útil realizar una estimación económica equivalente del proyecto.

4.5.1. Recursos humanos

El recurso principal del proyecto ha sido el trabajo del estudiante, encargado de la revisión bibliográfica, implementación del caso de estudio, análisis de resultados y redacción de la memoria. Además, se considera la participación del tutor académico en tareas de orientación, seguimiento y revisión.

La planificación del diagrama de Gantt contempla un periodo total aproximado de 192 días laborables. Considerando una dedicación media del 25 % de una jornada laboral estándar de 8 horas, se obtiene una dedicación aproximada de:

$$192 \cdot 8 \cdot 0.25 = 384 \text{ horas}$$

En el Cuadro 4.2 se muestra la estimación de costes asociada a los recursos humanos.

Recurso	Horas estimadas	Coste horario	Coste total
Estudiante / desarrollador	384 h	35 €/h	13.440 €
Tutor académico	20 h	80 €/h	1.600 €
Total recursos humanos			15.040 €

Cuadro 4.2: Estimación de costes asociados a recursos humanos.

4.5.2. Recursos hardware

El trabajo se ha desarrollado principalmente sobre un ordenador personal, utilizado para la redacción de la memoria, ejecución de scripts en Python, análisis en MATLAB y gestión de figuras y resultados. Dado que no ha sido necesario adquirir hardware específico, se considera únicamente un coste de amortización proporcional al periodo de uso.

Recurso hardware	Uso dentro del proyecto	Coste estimado
Ordenador personal MSI Creator M16 A12UC	Ejecución de código, análisis de datos y redacción de memoria	1314 €
Almacenamiento local y en la nube	Gestión de archivos, figuras, código y copias de seguridad	20 €
Total hardware		1334 €

Cuadro 4.3: Estimación de costes asociados a recursos hardware.

4.5.3. Recursos software

Para el desarrollo del proyecto se han utilizado principalmente herramientas software de acceso libre o disponibles mediante licencia académica. Python se ha empleado para la carga del modelo BERT, tokenización de frases, extracción de predicciones y obtención de mapas de atención. MATLAB se ha utilizado para el análisis multivariante mediante PCA y la implementación manual de oMEDA. La memoria se ha redactado en L^AT_EX mediante Overleaf.

Software	Uso dentro del proyecto	Coste estimado
Python	Procesamiento de frases, uso de BERT y extracción de atenciones	0 €
Hugging Face Transformers	Carga del modelo <code>textattack/bert-base-uncased-SST-2</code>	0 €
PyTorch	Ejecución del modelo BERT	0 €
MATLAB	Entorno	860 €
Overleaf / L ^A T _E X	Redacción y maquetación de la memoria	100 €
GanttProject	Elaboración del diagrama de planificación	0 €
MEDA	Análisis Exploratorio de Datos Multivariantes, PCA, análisis oMEDA y generación de gráficas	0 €
Total software		960 €

Cuadro 4.4: Estimación de costes asociados a recursos software.

4.6. Coste total estimado

A partir de los costes anteriores, se obtiene el coste total estimado del proyecto. Aunque el coste real desembolsado ha sido reducido, al tratarse de un

trabajo académico desarrollado con recursos propios y licencias disponibles, la valoración económica permite estimar el coste equivalente que tendría el desarrollo del proyecto en un entorno profesional.

Concepto	Coste estimado
Recursos humanos	15.040 €
Recursos hardware	1334 €
Recursos software	960 €
Subtotal	17.334 €
Costes indirectos y margen de contingencia, 10 %	1.733,4 €
Coste total estimado	19.067,4 €

Cuadro 4.5: Coste total estimado del Trabajo Fin de Grado.

4.7. Conclusión de la planificación

La planificación temporal ha permitido organizar el desarrollo del trabajo en fases diferenciadas, comenzando por el estudio teórico de los modelos de inteligencia artificial y XAI, y avanzando posteriormente hacia el diseño e implementación de una prueba de concepto basada en BERT. La superposición de algunas tareas ha sido necesaria debido a la relación directa entre la revisión bibliográfica, el diseño experimental y el análisis de resultados.

Desde el punto de vista económico, el mayor peso del proyecto corresponde a los recursos humanos, ya que el trabajo requiere principalmente dedicación intelectual, revisión bibliográfica, programación, análisis e interpretación de resultados. Los costes asociados a hardware y software son reducidos, debido al uso de herramientas gratuitas, recursos propios y licencias académicas.

En conjunto, la planificación y estimación de costes muestran que el proyecto es viable dentro del marco de un Trabajo Fin de Grado, tanto por su duración como por los recursos necesarios para su desarrollo.

Capítulo 5

Materiales y Métodos

5.1. Caso de estudio: análisis explicativo de BERT mediante mapas de atención, PCA , oMEDA, SHAP, PLS-DA y ASCA

En este apartado se presenta el caso de estudio desarrollado en el trabajo, centrado en el análisis explicativo de un modelo BERT aplicado a una tarea de clasificación de sentimiento. El objetivo principal no es únicamente obtener la etiqueta predicha por el modelo, sino estudiar parte de su comportamiento interno mediante los mapas de atención generados durante el procesamiento de frases de entrada. Para ello, se combinan herramientas propias del procesamiento del lenguaje natural con técnicas de análisis exploratorio multivariante, concretamente el Análisis de Componentes Principales (PCA) y una implementación manual de oMEDA en MATLAB, así como su comparación con SHAP, PLS-DA y ASCA.

5.1.1. Transformers y modelo BERT

Los modelos *Transformer* constituyen una de las arquitecturas más relevantes dentro del procesamiento del lenguaje natural actual. Su principal característica es el uso del mecanismo de autoatención, que permite que cada token de una secuencia establezca relaciones con el resto de tokens, independientemente de su posición. A diferencia de arquitecturas recurrentes, el *Transformer* procesa la secuencia de forma paralela y aprende representaciones contextuales a partir de las relaciones internas entre los elementos de entrada [54].

BERT, acrónimo de *Bidirectional Encoder Representations from Transformers*, es un modelo basado en la parte codificadora del *Transformer*. Su

5.1. Caso de estudio: análisis explicativo de BERT mediante 82 mapas de atención, PCA , oMEDA, SHAP, PLS-DA y ASCA

principal característica es que aprende representaciones bidireccionales, teniendo en cuenta de forma simultánea el contexto izquierdo y derecho de cada token. Esta capacidad resulta especialmente útil en tareas de comprensión del lenguaje, donde el significado de una palabra depende del contexto completo en el que aparece [86].

En una tarea de clasificación de sentimiento, el modelo recibe una frase tokenizada y genera una predicción asociada a una de las clases disponibles. En este trabajo se emplea el modelo `textattack/bert-base-uncased-SST-2`, un modelo basado en BERT ajustado para clasificación binaria de sentimiento. Al tratarse de una versión *uncased*, el texto se procesa sin distinguir entre mayúsculas y minúsculas, reduciendo así la variabilidad superficial de las entradas.

La arquitectura base corresponde a BERT-base, formada por 12 capas *Transformer* y 12 cabezas de atención por capa. Para cada frase de entrada, el modelo devuelve una predicción de sentimiento junto con las probabilidades asociadas a las clases positiva y negativa.

Para complementar la descripción anterior, en la Figura 5.1 se muestra una visualización de la arquitectura del modelo BERT-base obtenida en MATLAB. Esta representación permite observar la estructura interna del modelo como una sucesión de bloques codificadores, identificados mediante las capas `enc1`, `enc2`, ..., `enc12`.

Aunque la representación completa de la red resulta visualmente densa debido al elevado número de conexiones internas, permite comprobar que el modelo está organizado en una secuencia de bloques repetidos. Cada uno de estos bloques incluye mecanismos de atención multi-cabeza, conexiones residuales, normalización por capas y redes completamente conectadas, elementos característicos de la arquitectura *Transformer*.

Esta visualización no se emplea como herramienta principal de análisis, sino como apoyo gráfico para mostrar la organización general del modelo utilizado en el caso práctico. Para la interpretación posterior, el análisis se centra en las matrices de atención extraídas de las 12 capas y 12 cabezas del modelo BERT-base.



Figura 5.1: Visualización general de la arquitectura BERT-base obtenida en MATLAB. La red está formada por una etapa inicial de *embedding* y una sucesión de 12 bloques codificadores *Transformer*.

En la Figura 5.2 se muestra un detalle de la capa inicial del modelo. Esta vista permite apreciar con mayor claridad la repetición estructural de los bloques codificadores. En cada bloque aparecen operaciones asociadas a la atención multi-cabeza, capas completamente conectadas, funciones de activación, normalización y conexiones residuales.




Figura 5.2: Detalle de la capa inicial del modelo BERT-base visualizada en MATLAB. Se observa la estructura repetida de los bloques codificadores correspondientes a la capa inicial del modelo.

Esta visualización sirve como apoyo para entender que BERT-base no está

formado por una única capa de procesamiento, sino por una arquitectura profunda organizada en 12 bloques sucesivos. Esta estructura es precisamente la que permite extraer mapas de atención por capa y por cabeza, lo que posteriormente se aprovecha en este trabajo para analizar el comportamiento interno del modelo ante frases positivas y negativas.

Además, se han extraído las matrices de atención internas generadas en cada capa y cabeza, lo que permite estudiar cómo el modelo distribuye la atención entre los distintos tokens de la frase.




Figura 5.3: Mapas de atención obtenidos a partir del análisis interno del modelo BERT.

5.1.2. Modelo utilizado y tarea de clasificación de sentimiento

El modelo utilizado en este caso de estudio está ajustado sobre la tarea SST-2, perteneciente al *Stanford Sentiment Treebank*. SST-2 es una tarea de clasificación binaria de sentimiento en la que las frases se etiquetan como positivas o negativas. Este tipo de tarea resulta especialmente adecuado para analizar modelos de lenguaje, ya que permite estudiar cómo el modelo interpreta expresiones lingüísticas con distinta carga emocional [87], [88].

En este trabajo no se ha entrenado un modelo desde cero. En su lugar,

se ha utilizado un modelo BERT previamente ajustado para clasificación de sentimiento. Por tanto, el estudio se centra en el análisis explicativo del comportamiento de un modelo ya entrenado, observando tanto sus predicciones como los patrones de atención que genera internamente.

Esta distinción es importante: SST-2 se utiliza como referencia del entrenamiento previo del modelo, pero el conjunto de frases analizado en este trabajo no procede directamente de SST-2. El conjunto experimental empleado ha sido generado de forma controlada para facilitar el análisis comparativo entre frases positivas y negativas.

5.1.3. Análisis de Componentes Principales

El Análisis de Componentes Principales, conocido como PCA por sus siglas en inglés (*Principal Component Analysis*), es una técnica estadística de reducción de dimensionalidad ampliamente utilizada en el análisis exploratorio de datos. Su objetivo principal es transformar un conjunto de variables originales, posiblemente numerosas y correlacionadas entre sí, en un nuevo conjunto de variables no correlacionadas denominadas componentes principales.

Cada componente principal se obtiene como una combinación lineal de las variables originales. Estas componentes se ordenan de manera que la primera recoge la mayor cantidad posible de variabilidad presente en los datos, la segunda recoge la mayor parte de la variabilidad restante bajo la condición de ser ortogonal a la primera, y así sucesivamente. De esta forma, PCA permite representar la información contenida en un conjunto de alta dimensión mediante un número reducido de componentes, conservando la mayor parte de la variabilidad relevante.

Desde un punto de vista geométrico, PCA puede interpretarse como un cambio de sistema de coordenadas. Las nuevas direcciones se eligen de forma que se ajusten a las direcciones de máxima variación de los datos. Esto permite proyectar las observaciones sobre un espacio de menor dimensión, facilitando la visualización de patrones, agrupamientos, tendencias o posibles valores atípicos que podrían resultar difíciles de detectar en el espacio original.

Una de las principales ventajas de PCA es su utilidad como herramienta exploratoria. Al representar las observaciones en gráficos de puntuaciones, o *score plots*, es posible analizar si existen grupos diferenciados, relaciones entre muestras o estructuras internas dentro del conjunto de datos. Por otra parte, los gráficos de cargas, o *loading plots*, permiten estudiar la contribución de las variables originales a cada componente principal, ayudando a interpretar qué variables tienen mayor influencia en las direcciones de máxima variabilidad.

Antes de aplicar PCA suele ser habitual centrar o estandarizar los datos. El

centrado consiste en restar a cada variable su valor medio, mientras que la estandarización también divide por la desviación típica. Esta etapa es importante cuando las variables tienen escalas diferentes, ya que evita que aquellas con mayor magnitud numérica dominen el cálculo de las componentes principales.

A pesar de sus ventajas, PCA presenta algunas limitaciones. Al tratarse de una técnica lineal, solo captura relaciones lineales entre variables, por lo que puede no representar adecuadamente estructuras no lineales complejas. Además, las componentes principales no siempre tienen una interpretación directa, ya que cada una puede depender de muchas variables originales. Por ello, PCA debe entenderse como una herramienta de análisis exploratorio y no como un método explicativo definitivo por sí solo.

En resumen, PCA permite reducir la dimensionalidad de un conjunto de datos, visualizar su estructura interna y detectar patrones relevantes de forma más sencilla. Su utilidad dentro de un análisis exploratorio reside en que proporciona una representación compacta de los datos, conservando la mayor parte de la información estadística relevante y facilitando la posterior interpretación de las relaciones entre observaciones y variables.

5.1.4. oMEDA como herramienta de interpretación de variables

Una vez aplicado el Análisis de Componentes Principales, resulta necesario volver a relacionar la información obtenida en el espacio latente con las variables originales del problema. Aunque el PCA permite representar las observaciones en un espacio reducido y visualizar posibles tendencias o agrupamientos, sus componentes principales son combinaciones lineales de muchas variables, por lo que no siempre resulta inmediato identificar qué variables concretas están detrás de una determinada separación entre muestras.

Para este propósito se emplea la técnica *oMEDA* (*observation-based Missing-data methods for Exploratory Data Analysis*) [89]. Esta metodología se utiliza en el análisis exploratorio multivariante para estudiar qué variables originales están asociadas a una determinada dirección, grupo de observaciones o diferencia observada en el espacio latente. En lugar de limitarse a interpretar la posición de las muestras en el plano de componentes principales, oMEDA permite proyectar esa información de nuevo sobre el espacio original de variables.

En el contexto de este trabajo, las variables originales no corresponden a características lingüísticas directas, sino a valores de atención extraídos del modelo BERT. Cada variable representa una relación concreta entre dos tokens, dentro de una determinada capa y cabeza de atención. Por tanto, aplicar oMEDA permite identificar qué valores de atención contribuyen en

mayor medida a las diferencias observadas entre las frases analizadas.

La técnica se utilizará como una herramienta complementaria al PCA. Primero, el PCA permitirá estudiar la estructura global de los datos y observar si existen patrones diferenciados entre las frases. Posteriormente, oMEDA se empleará para interpretar esas diferencias en términos de las variables originales de atención. De esta forma, será posible pasar de una representación global en componentes principales a una interpretación más concreta basada en capas, cabezas y relaciones entre tokens.

Este enfoque resulta especialmente útil porque conecta el análisis estadístico multivariante con la interpretación interna del modelo BERT. Mientras que los mapas de atención permiten estudiar visualmente ejemplos individuales, oMEDA proporciona una forma cuantitativa de identificar qué patrones de atención son más relevantes dentro del conjunto completo de frases. Así, la metodología propuesta combina una visión local, basada en mapas de atención, con una visión global, basada en PCA y oMEDA.

Es importante señalar que oMEDA se utilizará con un propósito exploratorio. Su objetivo no es demostrar una relación causal directa entre una variable de atención y la predicción final del modelo, sino ayudar a detectar qué variables presentan mayor asociación con las diferencias observadas en el análisis multivariante. Por ello, sus resultados deberán interpretarse conjuntamente con los mapas de atención, las predicciones del modelo y el contexto lingüístico de las frases analizadas.

5.1.5. SHAP como método de comparación explicativa

Además del análisis basado en mapas de atención, PCA y oMEDA, en este trabajo se incorpora SHAP (*SHapley Additive exPlanations*) como método adicional de comparación. SHAP es una técnica de explicabilidad basada en los valores de Shapley, procedentes de la teoría de juegos, cuyo objetivo es asignar a cada característica de entrada una contribución concreta sobre la predicción final del modelo [78].

En el contexto de este trabajo, las características analizadas no son variables numéricas tradicionales, sino los tokens que componen cada frase procesada por BERT. De este modo, SHAP permite estimar qué palabras o fragmentos de la entrada contribuyen en mayor medida a que el modelo clasifique una frase como positiva o negativa.

La incorporación de SHAP resulta especialmente útil porque permite comparar dos perspectivas distintas de explicabilidad. Por un lado, los mapas de atención muestran cómo se relacionan internamente los tokens entre sí dentro del modelo. Por otro lado, SHAP estima la influencia de cada token sobre la salida final del clasificador. Por tanto, mientras que la atención ofre-

ce una visión interna del procesamiento de la frase, SHAP proporciona una atribución más directa sobre la predicción obtenida.

Esta comparación no pretende demostrar que ambos métodos deban coincidir exactamente, ya que explican aspectos diferentes del modelo. Sin embargo, sí permite analizar si los tokens destacados por SHAP coinciden parcialmente con aquellos que reciben mayor atención en determinadas capas o cabezas del modelo. De esta forma, SHAP se utiliza como una técnica complementaria para reforzar el análisis explicativo y contrastar los resultados obtenidos mediante mapas de atención.

5.1.6. PLS-DA como método supervisado de comparación

Además del análisis realizado mediante PCA y oMEDA, en este trabajo se incorpora PLS-DA (*Partial Least Squares Discriminant Analysis*) como método adicional de comparación. Esta técnica puede entenderse como una extensión supervisada del análisis multivariante, ya que no solo tiene en cuenta la matriz de datos de entrada, sino también las etiquetas de clase asociadas a cada observación.

A diferencia del PCA, que busca las direcciones de máxima variabilidad sin utilizar información sobre las clases, PLS-DA trata de encontrar un espacio latente que permita discriminar entre grupos conocidos. En el contexto de este trabajo, dichos grupos corresponden a las frases positivas y negativas utilizadas en el análisis. Por tanto, PLS-DA permite comprobar si las variables de atención extraídas del modelo BERT contienen información útil para diferenciar ambos tipos de frases.

La incorporación de PLS-DA resulta especialmente interesante porque permite contrastar los resultados obtenidos previamente con PCA y oMEDA. El PCA proporciona una visión exploratoria no supervisada de la estructura de los datos, mientras que oMEDA permite identificar qué variables originales están más asociadas a la diferencia entre grupos. PLS-DA, en cambio, introduce directamente las etiquetas de clase durante el ajuste del modelo, por lo que permite analizar la capacidad discriminante de las variables de atención desde una perspectiva supervisada.

En este trabajo, PLS-DA se utiliza con tres objetivos principales. En primer lugar, comprobar si las frases positivas y negativas pueden separarse en un espacio latente construido a partir de las variables de atención. En segundo lugar, identificar qué variables tienen mayor importancia en dicha separación mediante coeficientes. Finalmente, comparar la importancia obtenida mediante PLS-DA con la importancia calculada previamente mediante oMEDA.

Esta comparación permite evaluar si ambos enfoques destacan regiones simi-

5.1. Caso de estudio: análisis explicativo de BERT mediante 90 mapas de atención, PCA, oMEDA, SHAP, PLS-DA y ASCA

lares del modelo BERT. Si las capas, cabezas o variables relevantes coinciden parcialmente entre oMEDA y PLS-DA, la interpretación obtenida gana consistencia. En cambio, si ambos métodos señalan zonas diferentes, se pone de manifiesto la necesidad de interpretar los resultados con cautela y de combinar distintas técnicas para analizar modelos complejos.

5.1.7. ASCA como método exploratorio multivariante

Además de PCA, oMEDA, SHAP y PLS-DA, en este trabajo se incorpora ASCA (*ANOVA-Simultaneous Component Analysis*) como una técnica adicional de análisis exploratorio multivariante. ASCA combina la filosofía del análisis de varianza, ANOVA, con técnicas de reducción de dimensionalidad similares al PCA. Su objetivo principal es separar la variabilidad de una matriz de datos en función de los factores experimentales definidos, permitiendo estudiar qué parte de la variación observada puede asociarse a cada factor [90].

En un ANOVA clásico se analiza cómo una variable concreta cambia en función de uno o varios factores. Sin embargo, en este trabajo no se analiza una única variable, sino una matriz de alta dimensión formada por las atenciones extraídas del modelo BERT. Cada frase queda representada mediante 9216 variables, correspondientes a las relaciones entre tokens en las distintas capas y cabezas de atención del modelo. En este contexto, ASCA resulta especialmente interesante porque permite extender la idea de ANOVA al caso multivariante.

La motivación de incorporar ASCA en este trabajo es estudiar si el factor de clase, es decir, si una frase es positiva o negativa, introduce un efecto apreciable sobre las matrices de atención del modelo. Mientras que PCA analiza la estructura global de los datos sin utilizar las etiquetas, y PLS-DA busca explícitamente una separación supervisada entre clases, ASCA permite formular una pregunta diferente: qué parte de la estructura multivariante de las atenciones puede asociarse al diseño experimental definido.

En este caso, el diseño experimental se ha construido a partir de dos factores. El primero es la clase de sentimiento, con dos niveles: frases positivas y frases negativas. El segundo es el par de frases, ya que el conjunto experimental se ha diseñado de forma pareada. Como se recoge en el Apéndice A, para cada frase positiva existe una frase negativa equivalente, manteniendo una estructura gramatical similar y modificando principalmente el término que aporta la polaridad sentimental. Este diseño permite estudiar el efecto de la clase controlando, en cierta medida, la estructura lingüística de cada par de frases. Como línea futura, el enfoque desarrollado podría ampliarse hacia diseños experimentales más complejos. En lugar de considerar únicamente la polaridad positiva o negativa de las frases, podrían incorporarse varios facto-

res de análisis, como la longitud del texto, el idioma, la presencia de errores ortográficos o la introducción de perturbaciones controladas en determinados tokens. Este planteamiento permitiría construir diseños factoriales completos y analizarlos mediante técnicas como ASCA en MATLAB, estudiando tanto el efecto individual de cada factor como sus posibles interacciones.

También sería interesante aplicar esta idea a conjuntos de frases pareadas en los que una frase original se compara con una versión modificada mediante enmascaramiento. Por ejemplo, una frase como “*Esta peli está guay*” podría compararse con “*Esta \$\$\$\$ está guay*” para estudiar la contribución específica del token sustituido. De esta forma, se podría conectar el análisis estructural de las matrices de atención con una interpretación más directa de la influencia de palabras concretas sobre la predicción del modelo.

Desde el punto de vista metodológico, ASCA no debe interpretarse como un clasificador, sino como una herramienta de análisis de efectos. Su finalidad no es predecir si una frase es positiva o negativa, sino estudiar si el cambio de polaridad produce una variación sistemática en las variables de atención. Por este motivo, ASCA complementa de forma natural a los métodos empleados anteriormente.

La aplicación de ASCA en este trabajo tiene también un interés exploratorio adicional. Aunque esta técnica se ha utilizado ampliamente en otros ámbitos de análisis multivariante, su aplicación al estudio de matrices de atención de modelos BERT no constituye un enfoque habitual, de hecho sería el primer caso en realizarse, y no exclusivamente con ASCA, sino también con oMEDA y PLS-DA, dentro de los análisis explicativos de modelos *Transformer*. Por ello, en este TFG se plantea como una aproximación experimental para estudiar si un método basado en diseño de experimentos puede aportar información útil sobre el comportamiento interno de un modelo de lenguaje.

En resumen, ASCA se incorpora con tres objetivos principales. En primer lugar, analizar si el factor clase tiene un efecto apreciable sobre las matrices de atención. En segundo lugar, estudiar qué capas, cabezas y relaciones entre tokens concentran mayor importancia dentro de dicho efecto. Finalmente, comparar sus resultados con los obtenidos mediante PCA, oMEDA, SHAP y PLS-DA, reforzando así el análisis explicativo desde una perspectiva complementaria.

Capítulo 6

Análisis individualizado por frase

6.1. Análisis de los mecanismos de atención en BERT

En esta sección se presenta un análisis detallado del comportamiento de las cabezas de atención (attention heads) de un modelo basado en BERT entrenado para clasificación de sentimiento. El objetivo es estudiar cómo se distribuye la atención entre los distintos tokens de entrada y cómo esta contribuye a la construcción de la representación interna utilizada para la predicción final.

6.1.1. Metodología

Se ha utilizado el modelo `bert-base-uncased` ajustado sobre el dataset de análisis de sentimiento SST-2. Para el análisis, se ha seleccionado una frase de entrada representativa:

“The movie was surprisingly good.”

Se han extraído los mapas de atención correspondientes a las 12 capas del modelo, cada una compuesta por 12 cabezas de atención. Para cada cabeza, se ha analizado la evolución de los patrones de atención a lo largo de las capas.

6.1.2. Visualización de mapas de atención

Los mapas de atención permiten observar gráficamente cómo se distribuye la atención entre los tokens de una frase. En estas representaciones, cada

token aparece relacionado con el resto mediante pesos de atención, lo que permite identificar qué palabras establecen relaciones más fuertes durante el procesamiento interno del modelo.

Con el objetivo de ilustrar de forma más completa el tipo de información que proporcionan los mapas de atención, en las Figuras 6.1 y 6.2 se muestran los mapas correspondientes a las 12 capas del modelo BERT para una de las frases analizadas. En este caso, la secuencia de entrada está formada por los tokens `[CLS]`, `the`, `movie`, `was`, `surprisingly`, `good` y `[SEP]`. Cada imagen representa una capa del modelo y contiene las 12 cabezas de atención asociadas a dicha capa.

Estas representaciones permiten observar cómo cada capa y cada cabeza de atención establecen patrones de relación diferentes entre los tokens de la secuencia. En algunas cabezas se aprecia una atención más intensa hacia tokens concretos, como `movie`, `good` o `[SEP]`, mientras que en otras la distribución de atención aparece más repartida entre varios elementos de la frase. Esto pone de manifiesto que las distintas cabezas no desempeñan necesariamente la misma función, sino que pueden especializarse en capturar relaciones diferentes dentro de la entrada.

Además, la comparación entre capas permite analizar cómo evoluciona la representación interna de la frase a medida que avanza por el modelo. Las primeras capas suelen recoger relaciones más locales o superficiales entre tokens, mientras que las capas más profundas pueden capturar patrones más abstractos y relacionados con la tarea final de clasificación. En este ejemplo concreto, puede observarse que ciertos tokens con contenido semántico relevante, como `movie` o `good`, reciben una atención destacada en algunas capas y cabezas, lo que sugiere que participan de forma importante en la construcción de la representación interna de la frase.

Del mismo modo, la presencia de atención hacia `[CLS]` y `[SEP]` refleja el papel estructural que desempeñan estos tokens especiales dentro del modelo. No obstante, estos patrones no deben interpretarse de forma aislada ni generalizarse automáticamente, ya que dependen de múltiples factores: la frase analizada, la capa considerada, la cabeza concreta, la posición de los tokens y el contexto lingüístico de la entrada.

En efecto, la interpretación de los mapas de atención depende de múltiples factores, entre ellos la frase analizada, la capa considerada, la cabeza concreta y el contexto general de la tarea. Cada frase puede inducir patrones de atención distintos, y una misma palabra puede desempeñar papeles diferentes según su contexto. Además, las capas más profundas del modelo suelen capturar relaciones más abstractas que las capas iniciales, por lo que el significado de los mapas de atención puede variar notablemente a lo largo de la arquitectura. Por esta razón, los mapas de atención deben entenderse como una herramienta de análisis exploratorio que permite aproximarse al

funcionamiento interno del modelo, pero no como una explicación completa o definitiva de la decisión tomada.




Figura 6.1: Mapas de atención correspondientes a las capas 0–7 del modelo BERT. Cada subfigura representa una capa completa e incluye sus 12 cabezas de atención.




Figura 6.2: Mapas de atención correspondientes a las capas 8–11 del modelo BERT. Cada subfigura representa una capa completa e incluye sus 12 cabezas de atención.

Este tipo de visualización resulta especialmente útil como primera aproximación explicativa, ya que permite estudiar si determinados tokens reciben mayor atención o si aparecen patrones concretos en ciertas capas o cabezas del modelo. Por ejemplo, puede analizarse si palabras con carga emocional reciben más atención que otras, o si el token `[CLS]` concentra información relevante para la clasificación final.

No obstante, los mapas de atención deben interpretarse con cautela. Una atención elevada entre dos tokens indica una relación interna dentro del modelo, pero no implica necesariamente que dicha relación sea la causa principal de la predicción. Por ello, en este trabajo los mapas de atención se utilizan como herramienta exploratoria y se complementan con PCA y oMEDA para estudiar patrones globales en el conjunto de datos.

6.1.3. Interpretación de los mapas de atención

Cada mapa de atención representa la distribución de pesos entre tokens, donde las filas indican el token que atiende y las columnas el token atendido. Los valores más altos indican una mayor relevancia en la relación entre tokens.

El análisis revela que las cabezas de atención no tienen una interpretación

explícita predefinida, sino que su función debe inferirse a partir de patrones observados.

6.1.4. Evolución del comportamiento de las cabezas

Se ha observado que el comportamiento de las cabezas de atención sigue una evolución general a lo largo de las capas:

- Capas iniciales: capturan relaciones locales y estructurales (orden de palabras, identidad).
- Capas intermedias: centralizan la información en tokens especiales como [CLS] y [SEP]. Estas capas cumplen una función de reorganización y consolidación de la información, realizando una transición hacia una representación global de la frase.
- Capas profundas: capturan relaciones semánticas relevantes.
- Capa final: integran la información global para la predicción.

6.1.5. Clasificación funcional de las cabezas de atención

A partir del análisis realizado, es posible agrupar las cabezas de atención en distintas categorías según su comportamiento predominante.

6.1.6. Discusión

El análisis evidencia que el modelo no utiliza una única estrategia de atención, sino que combina múltiples mecanismos complementarios:

- Algunas cabezas capturan relaciones estructurales (orden y sintaxis).
- Otras identifican tokens clave relevantes para la tarea.
- Algunas modelan el contexto y los modificadores.
- Otras integran la información global.

Este comportamiento sugiere que la representación final del modelo es el resultado de la interacción de múltiples perspectivas parciales, en lugar de depender de una única fuente de información.

Además, se observa que la información semántica relevante emerge principalmente en las capas profundas, lo que concuerda con la hipótesis de que los transformers construyen significado de forma jerárquica.

Head	Tipo	Descripción
0	Agregación progresiva	Evoluciona desde patrones estructurales hacia la captura parcial de información semántica.
1	Estructural global	Centraliza la información en tokens especiales como [CLS] y [SEP].
2	Colapso de información	Presenta una fuerte concentración de atención en tokens especiales, reduciendo la complejidad de la representación.
3	Semántica emergente	Captura relaciones semánticas entre tokens como “good” y “movie”.
4	Híbrida	Combina patrones estructurales con señales semánticas débiles.
5	Semántica + integración	Detecta tokens relevantes y contribuye a la integración global de la información.
6	Contextual	Especializada en capturar modificadores como “surprisingly”.
7	Foco semántico	Concentra la atención en tokens clave como “good”.
8	Interacción semántica	Captura relaciones complejas entre múltiples tokens relevantes.
9	Transición	Evoluciona desde estructura secuencial hacia semántica contextual.
10	Predicado semántico	Construye relaciones entre verbo, atributo y modificadores.
11	Integración final	Realiza la consolidación global de la información antes de la predicción.

Cuadro 6.1: Clasificación funcional de las cabezas de atención

6.1.7. Conclusión

El estudio de las cabezas de atención en BERT revela que el modelo organiza el procesamiento del lenguaje en distintas fases:

estructura → relaciones → significado → integración

Las cabezas de atención desempeñan roles diferenciados dentro de este proceso, desde la captura de patrones básicos hasta la integración final de la información. Este comportamiento refuerza la idea de que la interpretabilidad en transformers debe abordarse como un análisis de sistemas complejos distribuidos, donde múltiples componentes contribuyen conjuntamente a la decisión final.

Capítulo 7

Diseño de Pruebas Multifrase

7.1. Extracción de mapas de atención

Durante el procesamiento de cada frase, BERT genera matrices de atención en cada una de sus capas y cabezas. Estas matrices representan cómo cada token de la secuencia atiende al resto de tokens. De forma intuitiva, cada fila de una matriz de atención indica cómo un token distribuye su atención sobre los demás elementos de la frase.

En este trabajo se han extraído las matrices de atención correspondientes a las 12 capas y 12 cabezas del modelo. Como cada frase se ha representado mediante 8 tokens, cada matriz de atención tiene dimensión 8×8 . Por tanto, para cada frase se obtiene un conjunto de valores de atención dado por:

$$12 \times 12 \times 8 \times 8 = 9216$$

Estos valores se reorganizan en un único vector fila, de manera que cada frase queda representada mediante 9216 variables. Al repetir este proceso para las 40 frases del conjunto experimental, se obtiene una matriz de datos:

$$X \in \mathbb{R}^{40 \times 9216}$$

donde cada fila representa una frase y cada columna representa un valor concreto de atención asociado a una capa, una cabeza y una relación token-token determinada.

Este procedimiento permite transformar la información interna del modelo en una estructura numérica adecuada para el análisis multivariante. En lugar de analizar únicamente mapas de atención de forma visual e individual, se construye una matriz global que permite comparar patrones de atención entre todas las frases del conjunto.

7.2. Conjunto experimental de frases

Para el análisis se ha construido un conjunto experimental formado por 40 frases generadas aleatoriamente mediante inteligencia artificial para no influir de manera personal y asegurar que no son frases ya entrenadas y obtenidas del dataset inicial. El conjunto se ha diseñado de forma equilibrada, incluyendo 20 frases con sentimiento positivo y 20 frases con sentimiento negativo. Esta distribución permite comparar ambos grupos en igualdad de condiciones y estudiar si los patrones de atención generados por el modelo presentan diferencias sistemáticas entre frases positivas y negativas.

Todas las frases se han ajustado a una longitud fija de 8 tokens, incluyendo los tokens especiales utilizados por BERT. En concreto, cada secuencia contiene el token [CLS] al inicio y el token [SEP] al final. El token [CLS] se emplea habitualmente como representación global de la secuencia en tareas de clasificación, mientras que [SEP] marca el final de la entrada.

La decisión de trabajar con frases de longitud fija permite que todas las matrices de atención tengan la misma dimensión. Esto facilita la construcción de una matriz de datos homogénea y permite aplicar posteriormente técnicas multivariantes como PCA y oMEDA sin necesidad de realizar ajustes adicionales por diferencias de tamaño entre secuencias.

Para cada frase se han almacenado los siguientes elementos:

- La frase original.
- La etiqueta real asignada, positiva o negativa.
- La etiqueta predicha por el modelo.
- La probabilidad asociada a la clase positiva.
- La probabilidad asociada a la clase negativa.
- Las matrices de atención generadas por todas las capas y cabezas del modelo.

7.2.1. Aplicación del Análisis de Componentes Principales

La matriz obtenida a partir de los mapas de atención tiene una dimensionalidad elevada, ya que cada frase queda descrita por 9216 variables. Esta situación dificulta la interpretación directa de los datos, por lo que resulta necesario aplicar técnicas de reducción de dimensionalidad. Para ello, se ha utilizado el Análisis de Componentes Principales, conocido como PCA.

El PCA transforma las variables originales en un nuevo conjunto de variables latentes denominadas componentes principales. Estas componentes son combinaciones lineales de las variables originales y se ordenan en función de la cantidad de varianza que explican. La primera componente principal recoge la mayor variabilidad posible de los datos, la segunda recoge la mayor parte de la variabilidad restante bajo la condición de ser ortogonal a la primera, y así sucesivamente.

Antes de aplicar PCA, la matriz de datos se estandariza para que todas las variables tengan una escala comparable. Aunque todas las variables proceden de valores de atención, la estandarización permite centrar el análisis en los patrones relativos de variación entre frases, evitando que determinadas variables dominen el resultado por diferencias de escala.

En este trabajo, el PCA se utiliza con tres objetivos principales. En primer lugar, permite representar las frases en un espacio de baja dimensión mediante gráficos de *scores*, facilitando la visualización de posibles agrupamientos entre frases positivas y negativas. En segundo lugar, permite analizar si las primeras componentes principales capturan diferencias relevantes entre ambos grupos. Por último, el PCA sirve como paso previo para aplicar oMEDA, ya que proporciona un subespacio latente desde el que proyectar de nuevo la información hacia las variables originales de atención.

7.3. Aplicación de oMEDA mediante la MEDA Toolbox

Tras aplicar PCA mediante la MEDA Toolbox, se ha utilizado la función `omeda` de la misma toolbox para analizar qué variables originales de atención están más asociadas al contraste entre frases positivas y negativas. De esta forma, el análisis oMEDA se mantiene dentro del mismo flujo metodológico que el PCA, ya que utiliza la matriz previamente preprocesada, los *loadings* del modelo PCA y una variable *dummy* que define la comparación entre ambos grupos.

El procedimiento parte de la matriz de atención preprocesada, denotada como $\mathbf{Xcs}$, obtenida mediante la función `preprocess2D`. Sobre esta matriz se calcula previamente el modelo PCA con la función `pcaEig`, de la que se obtienen los *scores* y *loadings*. A continuación, se define una variable *dummy* para codificar el contraste entre clases: las frases positivas se asignan al valor +1, mientras que las frases negativas se asignan al valor -1. Con esta codificación, el contraste analizado por oMEDA corresponde a la diferencia positivo menos negativo.

La función `omeda` recibe como entrada la matriz preprocesada, la variable *dummy* y los *loadings* del modelo PCA retenido. A partir de estos elementos,

proyecta el contraste entre grupos sobre el espacio original de variables. Como resultado, se obtiene un vector oMEDA de dimensión 9216×1 , donde cada posición corresponde a una variable original de atención del modelo BERT.

La interpretación del vector obtenido es la siguiente: un valor oMEDA positivo indica que la variable presenta una mayor asociación con el grupo de frases positivas, mientras que un valor negativo indica una mayor asociación con el grupo de frases negativas. Por su parte, los valores cercanos a cero indican que la variable tiene una contribución reducida al contraste analizado. Para estudiar la importancia de cada variable independientemente de la dirección del efecto, se utiliza el valor absoluto del vector oMEDA.

En este contexto, cada una de las 9216 variables puede asociarse a una capa del modelo BERT, una cabeza de atención y una relación concreta entre un token origen y un token destino. Por ello, el análisis oMEDA no solo permite obtener un ranking global de variables relevantes, sino también agrupar la importancia por capas, cabezas y posiciones de token. Esta agrupación facilita la interpretación de qué partes de la estructura interna del modelo participan con mayor intensidad en la diferenciación entre frases positivas y negativas.

Debe señalarse que, al utilizar la función `omeda` de la MEDA Toolbox, los valores obtenidos no son directamente equivalentes a una proyección manual de la diferencia entre medias de scores. La implementación de la toolbox considera el contraste definido sobre la matriz preprocesada y su relación con la parte explicada por el modelo PCA, por lo que la escala numérica del vector oMEDA puede diferir de una aproximación manual. En consecuencia, la interpretación se centra principalmente en la importancia relativa de las variables y en la distribución de dicha importancia por capas, cabezas y tokens.

7.4. Análisis de importancia de variables

A partir del vector oMEDA se ha calculado la importancia de cada variable mediante el valor absoluto de su contribución. Esta decisión permite analizar qué variables separan más ambos grupos, independientemente de si están asociadas a frases positivas o negativas. Posteriormente, las variables se ordenan de mayor a menor importancia para obtener un ranking global.

Además del ranking de las variables más relevantes, se ha aplicado un criterio estadístico para seleccionar automáticamente aquellas variables que destacan de forma significativa. En concreto, se ha utilizado un umbral definido como la media de las importancias más dos veces su desviación típica:

$$\mu + 2\sigma$$

donde μ representa la media de los valores absolutos del vector oMEDA y σ su desviación estándar. Las variables cuya importancia supera este umbral se consideran especialmente relevantes para explicar la diferencia entre ambos grupos.

También se ha representado la distribución de importancias mediante un histograma. Esta visualización permite observar si la mayoría de las variables tienen una contribución baja y si existe un subconjunto reducido de variables con valores claramente superiores. Asimismo, se ha calculado la contribución acumulada de las variables ordenadas por importancia, con el objetivo de determinar cuántas variables explican la mayor parte de la diferencia entre frases positivas y negativas.

7.5. Agrupación de la importancia por capas y cabezas

Dado que cada una de las 9216 variables procede de una estructura concreta del modelo BERT, es posible reorganizar la importancia obtenida mediante oMEDA en función de la capa y la cabeza de atención a la que pertenece cada variable. Para ello, se ha utilizado la relación:

$$9216 = 12 \times 12 \times 8 \times 8$$

donde los dos primeros factores corresponden a las 12 capas y 12 cabezas de atención, y los dos últimos a las relaciones entre los 8 tokens de la secuencia.

A partir de esta estructura, se ha acumulado la importancia absoluta de las variables pertenecientes a cada capa, obteniendo una medida global de la relevancia de cada nivel del modelo. Del mismo modo, se ha calculado una matriz de importancia por capa y cabeza, en la que cada elemento representa la importancia acumulada de una cabeza concreta dentro de una capa determinada.

Este análisis permite pasar de una interpretación puramente variable a variable a una interpretación estructural del modelo. En lugar de observar únicamente qué relaciones token-token son relevantes, se puede estudiar qué capas y qué cabezas de atención concentran una mayor contribución en la separación entre frases positivas y negativas.

7.6. Flujo de trabajo en Python y MATLAB

El flujo de trabajo seguido combina Python y MATLAB. En Python se realiza la parte asociada al modelo BERT: carga del modelo, tokenización de

frases, obtención de predicciones y extracción de las matrices de atención. Posteriormente, los datos se exportan a un archivo `.mat`, que contiene la matriz de atención, las frases utilizadas, las etiquetas reales, las etiquetas predichas por el modelo y las probabilidades asociadas a cada clase.

En MATLAB se desarrolla el análisis multivariante de los datos. En primer lugar, se carga la matriz de atención generada en Python y se preprocesa mediante la función `preprocess2D` de la MEDA Toolbox. A continuación, se aplica PCA mediante la función `pcaEig`, también perteneciente a dicha toolbox. Este análisis permite reducir la dimensionalidad de la matriz original y estudiar la estructura global de las observaciones mediante las representaciones de scores.

A partir del modelo PCA obtenido, se aplica oMEDA utilizando la función `omeda` de la MEDA Toolbox. Para ello, se define una variable *dummy* que codifica el contraste entre frases positivas y negativas. Las frases positivas se asignan al valor $+1$, mientras que las frases negativas se asignan al valor -1 . De esta forma, oMEDA permite proyectar el contraste entre ambos grupos sobre el espacio original de variables de atención.

Finalmente, a partir del vector oMEDA obtenido, se calculan rankings de variables, histogramas de importancia, umbrales estadísticos de relevancia y mapas de importancia agrupados por capa, cabeza de atención y posición de token. Este procedimiento permite interpretar los resultados no solo a nivel global, sino también en relación con la estructura interna del modelo BERT.

El procedimiento completo puede resumirse en las siguientes etapas:

1. Generación de un conjunto equilibrado de 40 frases mediante inteligencia artificial.
2. Asignación de etiquetas reales positivas y negativas.
3. Tokenización de cada frase con longitud fija de 8 tokens.
4. Clasificación de cada frase mediante el modelo `textattack/bert-base-uncased-SST-2`.
5. Extracción de las matrices de atención de las 12 capas y 12 cabezas del modelo.
6. Vectorización de las matrices de atención para construir una matriz 40×9216 .
7. Exportación de los datos a MATLAB mediante un archivo `.mat`.
8. Preprocesamiento de la matriz mediante `preprocess2D` de la MEDA Toolbox.

9. Aplicación de PCA mediante `pcaEig` para reducir la dimensionalidad y visualizar la estructura latente.
10. Construcción de una variable *dummy* para definir el contraste entre frases positivas y negativas.
11. Aplicación de oMEDA mediante la función `omeda` de la MEDA Toolbox.
12. Identificación de variables relevantes mediante ranking y umbral estadístico.
13. Agrupación de la importancia por capas, cabezas de atención y posiciones de token.

7.6.1. Interpretación general del análisis

La interpretación de los resultados se realiza combinando distintos niveles de análisis. En primer lugar, se observan las predicciones del modelo BERT, comprobando si las frases han sido clasificadas como positivas o negativas y con qué grado de confianza. Este primer nivel permite verificar que el modelo responde de forma coherente ante el conjunto de frases utilizado.

En segundo lugar, se analizan las matrices de atención extraídas del modelo. Estas matrices permiten estudiar las relaciones internas entre tokens para cada capa y cabeza de atención. Aunque los mapas de atención no deben interpretarse directamente como una explicación causal de la predicción, sí proporcionan una representación útil de la estructura interna que el modelo utiliza durante el procesamiento de cada frase.

En tercer lugar, se aplica PCA mediante la MEDA Toolbox con el objetivo de estudiar la estructura global de las observaciones en un espacio de menor dimensión. Las representaciones de scores permiten comprobar si las frases positivas y negativas tienden a ocupar regiones diferenciadas dentro del espacio latente. No obstante, al tratarse de una proyección reducida, la ausencia de una separación visual clara en los primeros planos de componentes principales no implica necesariamente que no existan diferencias relevantes entre ambos grupos.

Finalmente, oMEDA permite volver desde el modelo PCA al espacio original de variables de atención. En este trabajo, el análisis se realiza mediante la función `omeda` de la MEDA Toolbox, utilizando como entrada la matriz preprocesada, los *loadings* del modelo PCA y una variable *dummy* que define el contraste positivo-negativo. El resultado es un vector de dimensión 9216×1 , donde cada elemento representa la contribución de una variable de atención concreta a la diferencia entre ambos grupos.

Este enfoque resulta especialmente útil porque permite pasar de una representación global de las observaciones a una interpretación más localizada de la estructura interna de BERT. A partir del vector oMEDA, las contribuciones pueden agruparse por capas, cabezas y posiciones de token, identificando qué zonas del modelo participan con mayor intensidad en la diferenciación entre frases positivas y negativas.

En conjunto, la metodología propuesta combina la visualización de mapas de atención con herramientas de análisis multivariante de la MEDA Toolbox. Esto permite estudiar el comportamiento del modelo desde una perspectiva exploratoria, cuantitativa y visual, manteniendo una conexión directa entre la estructura latente obtenida mediante PCA y la interpretación de variables proporcionada por oMEDA.

7.7. Limitaciones del estudio

El análisis realizado debe entenderse como una prueba de concepto sobre el uso de técnicas multivariantes en el contexto xAI. En primer lugar, el conjunto experimental está formado por 40 frases generadas mediante inteligencia artificial, por lo que no constituye una muestra representativa completa del lenguaje natural ni del conjunto SST-2. Su utilidad principal es permitir un análisis controlado y equilibrado entre frases positivas y negativas, manteniendo una longitud fija de entrada que facilita la comparación entre observaciones.

En segundo lugar, los mapas de atención no deben interpretarse directamente como explicaciones causales. Una atención elevada entre dos tokens indica una relación interna dentro del modelo, pero no garantiza que dicha relación sea la causa principal de la predicción final. Por tanto, las matrices de atención se utilizan como objeto de análisis interno del modelo, no como una explicación causal completa de su comportamiento.

En tercer lugar, PCA es una técnica lineal, mientras que BERT es un modelo profundamente no lineal, aunque la ventaja fundamental no radica tanto en ese aspecto comparado con la sobreparametrización del modelo. Aunque por ello, las primeras componentes principales pueden capturar tendencias relevantes en las matrices de atención, pero no necesariamente toda la complejidad del comportamiento interno del modelo. La ausencia de una separación visual clara entre clases en los primeros planos PCA no implica que no exista información discriminativa, sino que esta puede estar distribuida en múltiples variables y componentes. Esto es debido a que PCA es un modelo no supervisado y por tanto su objetivo no es mostrar la diferencia entre clases en este caso, sino la máxima varianza.

Por último, aunque oMEDA permite identificar variables asociadas al con-

traste entre frases positivas y negativas, sus resultados deben interpretarse como una herramienta de análisis exploratorio. En este trabajo, oMEDA se aplica mediante la MEDA Toolbox a partir del modelo PCA previamente calculado, utilizando una variable *dummy* para definir la comparación entre grupos. El vector oMEDA resultante indica qué variables contribuyen en mayor medida al contraste analizado, pero no constituye una prueba causal definitiva sobre el funcionamiento del modelo BERT, sin embargo, se debe considerar causal el binomio formado por la parte de diseño del experimento y análisis de resultados. Ya que ante datos generados por un diseño experimental, el análisis multivariante es casual entre parámetros de entrada y salida, matizando que no se cumple esa causalidad si se trata entre pares de salidas.

Además, los valores absolutos de oMEDA dependen del preprocesamiento aplicado y de la definición del contraste mediante la variable *dummy*. Por ello, la interpretación debe centrarse principalmente en la importancia relativa de las variables, capas, cabezas y tokens, más que en el valor numérico aislado de cada contribución.

7.8. Aplicación de SHAP sobre el modelo BERT

Para complementar el análisis basado en mapas de atención, se ha aplicado SHAP sobre el mismo modelo BERT utilizado en el resto del trabajo, `textattack/bert-base-uncased-SST-2`. El objetivo de esta prueba es obtener una explicación a nivel de token para cada una de las frases analizadas, de manera que sea posible estudiar qué palabras contribuyen más a la predicción final del modelo.

El proceso se ha desarrollado en Python, utilizando las librerías `transformers`, `torch` y `shap`. En primer lugar, se carga el tokenizador y el modelo BERT previamente ajustado para clasificación binaria de sentimiento. A continuación, se define una función de predicción que recibe una lista de frases, las tokeniza y devuelve las probabilidades asociadas a las clases negativa y positiva.

Posteriormente, se crea un explicador SHAP utilizando un *masker* de texto. Este elemento permite ocultar o sustituir partes de la frase para observar cómo varía la predicción del modelo. A partir de estas perturbaciones, SHAP estima la contribución de cada token sobre la salida final. Este procedimiento se aplica sobre las 40 frases del conjunto experimental, formado por 20 frases positivas y 20 frases negativas.

Para cada frase se obtiene una explicación SHAP asociada a la clase predicha por el modelo. Los resultados se han guardado en distintos formatos: archivos `.html` con la visualización textual de SHAP, gráficas `.png` con la importancia

de los tokens y ficheros `.csv` con los valores numéricos obtenidos. De esta manera, se dispone tanto de una representación visual como de una tabla cuantitativa para su posterior análisis.

El flujo seguido puede resumirse en las siguientes etapas:

1. Carga del modelo BERT y su tokenizador.
2. Definición del conjunto de 40 frases utilizado en el análisis.
3. Obtención de las predicciones y probabilidades del modelo.
4. Creación del explicador SHAP para texto.
5. Cálculo de los valores SHAP para cada frase.
6. Extracción de los tokens más relevantes para la clase predicha.
7. Generación de gráficas individuales por frase.
8. Obtención de un ranking global de importancia de tokens.

A diferencia de los mapas de atención, que muestran relaciones internas entre tokens, SHAP se centra en medir cómo contribuye cada token a la predicción final. Por este motivo, ambos enfoques se consideran complementarios dentro del análisis explicativo realizado.

7.9. Implementación del análisis PLS-DA

El análisis PLS-DA se ha realizado sobre la misma matriz de datos utilizada en el análisis PCA y oMEDA. Esta matriz contiene 40 observaciones, correspondientes a las frases del conjunto experimental, y 9216 variables de atención extraídas del modelo BERT. Cada variable representa una relación concreta entre dos tokens dentro de una determinada capa y cabeza de atención.

El procedimiento se ha implementado en MATLAB a partir de la matriz X y de las etiquetas reales de las frases. En primer lugar, las etiquetas textuales se transforman en una variable binaria, asignando el valor 1 a las frases positivas y el valor 0 a las frases negativas. Esta codificación permite aplicar PLS-DA como un modelo de regresión supervisado cuya salida se interpreta posteriormente como una predicción de clase.

Antes de ajustar el modelo, la matriz de datos se estandariza. Esta etapa resulta importante porque todas las variables deben contribuir en condiciones comparables al análisis, evitando que diferencias de escala afecten al cálculo de las variables latentes. Aunque los datos proceden de valores de atención,

la estandarización permite centrar el análisis en las diferencias relativas entre variables.

Posteriormente, se ajusta el modelo PLS-DA mediante la función `plsregress` de MATLAB. Para seleccionar el número de componentes latentes se utiliza validación cruzada tipo *leave-one-out*, adecuada para conjuntos de datos reducidos como el empleado en este trabajo. En cada iteración se deja fuera una observación, se entrena el modelo con las restantes y se predice la muestra excluida. A partir de este proceso se calcula la precisión de clasificación y el error de validación cruzada para distintos números de componentes.

Una vez seleccionado el número de componentes, se ajusta el modelo final y se obtienen las puntuaciones latentes, las predicciones continuas, la matriz de confusión y las medidas de importancia de variables. Para la clasificación se utiliza un umbral de 0.5: valores superiores a dicho umbral se interpretan como clase positiva, mientras que valores inferiores se interpretan como clase negativa.

Además de los coeficientes del modelo, se calculan las puntuaciones VIP. Estas puntuaciones permiten medir la importancia de cada variable dentro del modelo PLS-DA, teniendo en cuenta su contribución a la construcción del espacio latente y a la explicación de la variable de salida. Habitualmente, valores VIP superiores a 1 se consideran indicativos de variables especialmente relevantes.

Finalmente, las importancias obtenidas mediante PLS-DA se reorganizan siguiendo la estructura interna de BERT:

$$9216 = 12 \times 12 \times 8 \times 8$$

donde los dos primeros factores corresponden a las 12 capas y 12 cabezas de atención, y los dos últimos a las relaciones entre los 8 tokens de la secuencia. De esta forma, es posible acumular la importancia por capa y por combinación capa-cabeza, permitiendo comparar estos resultados con los obtenidos previamente mediante oMEDA.

El flujo de trabajo seguido puede resumirse en las siguientes etapas:

1. Carga de la matriz de atención X y de las etiquetas reales.
2. Conversión de las etiquetas positiva y negativa a una variable binaria.
3. Estandarización de la matriz de datos.
4. Selección del número de componentes mediante validación cruzada.
5. Ajuste del modelo PLS-DA final.
6. Representación de las observaciones en el espacio latente LV1-LV2.

7. Obtención de la predicción continua y la matriz de confusión.
8. Cálculo de la importancia de variables mediante coeficientes y VIP.
9. Agrupación de la importancia por capas y cabezas de atención.
10. Comparación de la importancia obtenida mediante PLS-DA y oMEDA.

7.10. Implementación del análisis ASCA

El análisis ASCA se ha implementado en MATLAB utilizando la misma matriz de datos empleada en los análisis PCA, oMEDA y PLS-DA. Esta matriz, denotada como X , contiene 40 observaciones y 9216 variables. Cada observación corresponde a una frase del conjunto experimental, mientras que cada variable representa una relación de atención concreta extraída del modelo BERT.

La estructura de las variables procede directamente de la arquitectura del modelo utilizado. BERT-base está formado por 12 capas, cada una con 12 cabezas de atención. Además, todas las frases se han representado con una longitud fija de 8 tokens, por lo que cada cabeza genera una matriz de atención de dimensión 8×8 . Por tanto, el número total de variables por frase es:

$$12 \times 12 \times 8 \times 8 = 9216$$

Antes de aplicar ASCA, se definen los factores experimentales. El primer factor corresponde a la clase de sentimiento, distinguiendo entre frases positivas y negativas. El segundo factor corresponde al número de par, ya que las frases han sido construidas de forma pareada. De este modo, cada frase positiva tiene una frase negativa equivalente, con estructura similar pero diferente polaridad sentimental.

El uso del factor par permite incorporar al análisis la estructura del diseño experimental. Esta decisión es importante porque evita tratar las 40 frases como observaciones completamente independientes desde el punto de vista lingüístico. En realidad, el conjunto está formado por 20 pares de frases relacionadas, y ASCA permite tener en cuenta esta organización durante el análisis.

En la Figura 7.1 se puede apreciar este hecho con más detalle debido a la implementación de colores similares asignados a las parejas de frases positiva-negativa.




Figura 7.1: Representación de las observaciones en el plano formado por PC1 y PC2.

En MATLAB, la implementación se ha realizado mediante una descomposición de la matriz de datos en efectos asociados a los factores del diseño. De forma conceptual, la matriz de datos puede entenderse como la suma de una media global, un efecto debido a la clase, un efecto debido al par de frases y una parte residual no explicada por dichos factores:

$$X = 1 \times M_{\text{media}} + X_{\text{clase}} + X_{\text{par}} + E$$

El interés principal de este trabajo se centra en el efecto de clase, ya que permite estudiar cómo cambia la estructura de atención cuando la frase pasa de tener polaridad positiva a negativa. Una vez aislado este efecto, se aplica un análisis de componentes sobre la matriz asociada al factor correspondiente. Esto permite representar las observaciones en un espacio latente y visualizar si el factor clase introduce una separación clara entre frases positivas y negativas.

Además de la representación de scores, se han calculado diferentes medidas de importancia acumulada. Para ello, las variables de atención se han reorganizado de nuevo según su significado dentro de la arquitectura BERT. Cada índice de variable se ha asociado a una capa, una cabeza de atención, un token origen y un token destino. Esta reorganización permite condensar la información de ASCA en distintas vistas interpretables.

En concreto, se han calculado las siguientes representaciones:

1. Importancia acumulada por cabeza de atención.
2. Importancia acumulada por capa.

3. Importancia acumulada por token origen.
4. Importancia acumulada por token destino.
5. Mapa de importancia por capa y cabeza de atención.
6. Mapa de diferencia de atención por pares de tokens.

Estas representaciones permiten pasar de una matriz de 9216 variables a visualizaciones más interpretables, relacionadas directamente con la estructura interna de BERT. De esta forma, ASCA no solo permite estudiar si existe un efecto asociado a la clase, sino también localizar en qué partes del modelo aparece con mayor intensidad.

El flujo de trabajo seguido puede resumirse en las siguientes etapas:

1. Carga de la matriz de atención X y de las etiquetas de clase.
2. Definición del factor clase: positiva o negativa.
3. Definición del factor par, asociado a la estructura pareada del conjunto experimental.
4. Aplicación del modelo ASCA sobre la matriz de datos.
5. Extracción del efecto asociado al factor clase.
6. Representación de los scores del factor clase.
7. Reorganización de las variables según capa, cabeza, token origen y token destino.
8. Cálculo de importancias acumuladas para cada dimensión estructural.
9. Generación de mapas de importancia y diferencias de atención.
10. Interpretación de los resultados en relación con los análisis PCA, oME-DA, SHAP y PLS-DA.

El análisis ASCA se utiliza, por tanto, como una herramienta exploratoria orientada a estudiar el efecto de la polaridad de las frases sobre las matrices de atención de BERT, sin plantearlo como un modelo de clasificación, sino como una descomposición multivariante basada en factores experimentales.

Capítulo 8

Análisis de Resultados

8.1. Análisis de resultados

En este capítulo se presentan y analizan los resultados obtenidos tras aplicar las distintas técnicas de análisis explicativo y exploratorio sobre las matrices de atención extraídas del modelo BERT. El objetivo principal es estudiar si los patrones internos de atención contienen información diferenciadora entre frases positivas y negativas, así como identificar qué capas, cabezas, tokens y variables de atención contribuyen en mayor medida a dicha diferencia.

El análisis se ha dividido en varias partes complementarias. En primer lugar, se estudian los resultados obtenidos mediante Análisis de Componentes Principales (PCA), con el objetivo de visualizar la estructura global de las observaciones en un espacio de menor dimensión. En segundo lugar, se analiza el resultado de la implementación manual de oMEDA, empleada para proyectar las diferencias observadas entre frases positivas y negativas de nuevo al espacio original de variables de atención.

En tercer lugar, se incorpora SHAP como método de atribución externo a las matrices de atención, con el fin de analizar qué tokens de entrada contribuyen en mayor medida a la predicción final del modelo. Esta técnica permite comparar los resultados obtenidos a partir de la atención interna de BERT con una explicación más directamente vinculada a la salida del clasificador.

En cuarto lugar, se estudian los resultados obtenidos mediante PLS-DA, técnica supervisada que permite comprobar si las variables de atención contienen información suficiente para discriminar entre frases positivas y negativas. Este análisis actúa como una validación complementaria del estudio exploratorio, ya que introduce las etiquetas de clase durante la construcción del espacio latente.

En quinto lugar, se presenta el análisis mediante ASCA, cuyo objetivo es estudiar el efecto del factor clase sobre las matrices de atención. A diferencia de PLS-DA, ASCA no se plantea como un clasificador, sino como una técnica de descomposición multivariante que permite analizar qué parte de la variabilidad de los datos puede asociarse al diseño experimental definido.

Finalmente, se realiza una comparación global de la importancia relativa por token obtenida mediante oMEDA, PLS-DA, ASCA y SHAP. Esta comparación permite estudiar hasta qué punto los distintos métodos destacan posiciones similares de la secuencia o, por el contrario, capturan aspectos diferentes del comportamiento interno del modelo. De esta forma, el análisis no se limita a estudiar cada técnica de manera aislada, sino que busca integrar sus resultados para obtener una interpretación más completa y fundamentada del funcionamiento de BERT en la tarea de clasificación de sentimiento.

8.2. Comparación explicativa mediante SHAP

Con el objetivo de contrastar los resultados obtenidos mediante mapas de atención, se ha aplicado SHAP sobre el mismo conjunto experimental de frases. Esta técnica permite analizar qué tokens contribuyen con mayor intensidad a la predicción final del modelo BERT.

En las Figuras 8.1 y 8.2 se muestran dos ejemplos de explicaciones SHAP correspondientes a una frase positiva y a una frase negativa, respectivamente. En estas representaciones, cada barra indica la contribución de un token a la clase explicada. Los valores positivos indican que el token favorece la predicción de dicha clase, mientras que los valores negativos indican que reduce su contribución.




Figura 8.1: Explicación SHAP para una frase clasificada como positiva por el modelo BERT.

En el caso de la frase positiva, SHAP permite identificar qué palabras tienen mayor peso en la decisión del modelo. Generalmente, los tokens con mayor carga semántica o emocional son los que presentan una mayor contribución. Esto resulta coherente con la tarea de clasificación de sentimiento, ya que el modelo debe apoyarse en palabras que expresen valoración positiva o negativa para construir su predicción.




Figura 8.2: Explicación SHAP para una frase clasificada como negativa por el modelo BERT.

En el caso de la frase negativa, se observa un comportamiento análogo. Los tokens asociados a una valoración desfavorable tienden a presentar una mayor influencia sobre la clase negativa. Este tipo de visualización resulta útil porque permite interpretar la predicción del modelo de una forma más cercana al lenguaje natural, identificando directamente qué palabras han contribuido más al resultado.

Además del análisis individual, se ha calculado una importancia global de tokens a partir del valor absoluto medio de SHAP en todo el conjunto de frases. Este resultado se muestra en la Figura 8.3. La gráfica permite observar qué tokens han tenido una mayor influencia promedio en las predicciones del modelo.




Figura 8.3: Tokens con mayor importancia global según SHAP en el conjunto experimental.

El análisis global permite comprobar si las palabras más relevantes según SHAP coinciden con aquellas que, desde un punto de vista lingüístico, tienen mayor carga sentimental. En este sentido, SHAP ofrece una explicación más directa sobre la salida del modelo que los mapas de atención, ya que asigna una contribución concreta a cada token en función de su efecto sobre la predicción.

La comparación entre SHAP y los mapas de atención muestra que ambas técnicas aportan información diferente. Los mapas de atención permiten estudiar cómo el modelo relaciona internamente los tokens a través de sus capas y cabezas, mientras que SHAP permite analizar qué tokens influyen más en la decisión final. Por tanto, una atención elevada sobre un token no implica necesariamente que dicho token tenga también el mayor valor SHAP, ya que ambos métodos miden aspectos distintos del comportamiento del modelo.

Aun así, la comparación resulta útil porque permite contrastar la información interna proporcionada por la atención con una técnica de atribución externa. Cuando ambos enfoques destacan tokens similares, la interpretación obtenida gana coherencia. En cambio, cuando existen diferencias, se pone de manifiesto la necesidad de no interpretar los mapas de atención como explicaciones causales completas.

En conjunto, los resultados obtenidos mediante SHAP refuerzan la idea de que la explicabilidad de BERT debe abordarse desde varias perspectivas. Los mapas de atención permiten visualizar relaciones internas entre palabras, PCA y oMEDA ayudan a estudiar patrones globales en las matrices de atención, y SHAP aporta una explicación directa a nivel de token sobre

la predicción final. La combinación de estas técnicas proporciona una visión más completa y prudente del comportamiento del modelo.

8.2.1. Importancia relativa por token mediante SHAP

Para completar la comparación, se ha calculado la importancia relativa por posición de token mediante SHAP. A diferencia de oMEDA, PLS-DA y ASCA, SHAP no trabaja sobre las matrices de atención, sino sobre la contribución directa de cada token a la predicción final del modelo.




Figura 8.4: Importancia relativa por posición de token obtenida mediante SHAP.

En la Figura 8.4 se observa un perfil claramente diferente al de los métodos basados en atención. SHAP concentra la mayor parte de la importancia en los Tokens 5 y 6, mientras que [CLS], [SEP] y el punto presentan una contribución nula o muy reducida.

Este resultado es coherente con la naturaleza de SHAP. Al calcular atribuciones directamente sobre la salida del modelo, SHAP tiende a destacar las palabras que más influyen en la decisión de clasificación. En el conjunto experimental utilizado, las frases han sido construidas de forma pareada, modificando principalmente el término que aporta la polaridad sentimental. Por ello, es razonable que las posiciones centrales o finales donde aparecen adjetivos, verbos o modificadores relevantes concentren una mayor importancia.

La diferencia con oMEDA, PLS-DA y ASCA no debe interpretarse como una contradicción. SHAP responde a una pregunta distinta: **qué tokens influ-**

yen más directamente en la predicción final. En cambio, los métodos basados en atención estudian cómo se distribuyen las relaciones internas entre tokens dentro del modelo. Por eso SHAP destaca principalmente posiciones con contenido semántico, mientras que los métodos multivariantes también asignan importancia a tokens estructurales como [CLS] o [SEP].

8.3. Análisis de la varianza explicada mediante PCA

El primer resultado relevante corresponde a la varianza explicada por cada componente principal. En la Figura 8.5 se representa el porcentaje de varianza explicado individualmente por cada componente. Puede observarse que la primera componente principal concentra la mayor parte de la variabilidad individual, con un valor claramente superior al resto. Sin embargo, a partir de la segunda componente se produce una disminución progresiva de la varianza explicada.




Figura 8.5: Varianza explicada por cada componente principal del modelo PCA.

Este comportamiento indica que existe una dirección dominante de variabilidad en los datos, pero también que la información no queda concentrada únicamente en una o dos componentes. La caída progresiva de la curva muestra que las matrices de atención contienen una estructura distribuida, donde varias componentes contribuyen a describir la variabilidad total del conjunto. Esto resulta coherente con la naturaleza de los datos analizados, ya que cada frase está representada por 9216 variables procedentes de distintas capas, cabezas y relaciones entre tokens.

En la Figura 8.6 se muestra la varianza explicada acumulada. Esta representación permite estudiar cuántas componentes principales son necesarias para conservar una proporción determinada de la información total. Se observa

que las primeras componentes explican una parte significativa de la variabilidad, pero que es necesario conservar un número relativamente amplio de componentes para alcanzar niveles elevados de varianza acumulada, como el 80 %, 90 % o 95 %.




Figura 8.6: Varianza explicada acumulada en función del número de componentes principales.

Este resultado confirma que el comportamiento interno del modelo BERT, representado mediante sus valores de atención, no puede resumirse completamente con unas pocas dimensiones. Aunque las primeras componentes permiten obtener una visualización útil de la estructura global, una parte relevante de la información permanece distribuida en componentes posteriores. Por tanto, el PCA resulta adecuado como herramienta exploratoria, pero sus primeras componentes no deben interpretarse como una representación completa del comportamiento del modelo.

8.3.1. Representación de las observaciones en el espacio PCA

Una vez calculado el modelo PCA, se representaron las observaciones en distintos planos definidos por las componentes principales. En la Figura 8.7 se muestra la proyección de las 40 frases en el plano formado por PC1 y PC2, diferenciando las frases positivas y negativas mediante colores.




Figura 8.7: Representación de las observaciones en el plano formado por PC1 y PC2.

La representación muestra que las observaciones no se separan de forma clara únicamente en función de la etiqueta positiva o negativa. En varias zonas del plano aparecen puntos de ambas clases próximos entre sí, lo que indica que los patrones de atención extraídos por BERT no generan una separación lineal simple entre sentimientos positivos y negativos en las dos primeras componentes principales.

Como se puede observar en el conjunto de frases experimentales incluido en el Apéndice A, las muestras se han construido siguiendo una estructura pareada. Es decir, para cada frase positiva se ha definido una frase negativa equivalente, manteniendo prácticamente la misma estructura gramatical y modificando únicamente el término que introduce la carga sentimental de la oración, como un adjetivo, verbo o modificador.

Esta decisión permite que la diferencia principal entre ambas frases sea la polaridad semántica del término sustituido, reduciendo la influencia de otros factores lingüísticos como la longitud de la frase, el orden de los tokens o la estructura sintáctica. De esta forma, el análisis se centra en estudiar cómo varían los patrones internos del modelo cuando cambia el contenido emocional de la frase, manteniendo constante el resto de la construcción lingüística. Por ese motivo, algunas observaciones aparecen agrupadas en regiones concretas del espacio, mientras que otras se sitúan en zonas más alejadas. Esta dispersión sugiere que el PCA está capturando diferencias internas entre fra-

ses, aunque estas diferencias no corresponden exclusivamente a la polaridad del sentimiento. Es posible que las primeras componentes estén recogiendo otros factores, como la estructura sintáctica de la frase, la posición de determinados tokens, la presencia de palabras concretas o patrones generales de atención del modelo.

La Figura 8.8 muestra la representación de las observaciones en el plano formado por PC1 y PC3. El objetivo de esta visualización es comprobar si la tercera componente permite mejorar la separación entre clases o revelar una estructura diferente a la observada en PC1-PC2.




Figura 8.8: Representación de las observaciones en el plano formado por PC1 y PC3.

En este segundo plano se mantiene una conclusión similar. Las frases positivas y negativas no aparecen completamente separadas, sino que continúan mostrando cierto solapamiento. Esto indica que la diferencia entre clases no queda representada de forma directa por una única componente principal ni por una combinación simple de las primeras componentes. Sin embargo, la existencia de regiones diferenciadas en el espacio PCA confirma que las matrices de atención contienen variabilidad estructurada, aunque dicha estructura no coincide de manera inmediata con la etiqueta de sentimiento.

Este resultado es importante porque muestra una limitación habitual en el análisis de modelos profundos: las representaciones internas pueden contener información relevante, pero no siempre se organizan de forma directamente

interpretable en función de la variable objetivo. Por ello, resulta necesario complementar el PCA con una técnica que permita volver al espacio original de variables y estudiar qué valores concretos de atención contribuyen a las diferencias entre grupos.

8.4. Análisis global del vector oMEDA

Tras el análisis PCA, se aplicó la implementación manual de oMEDA para comparar el grupo de frases positivas frente al grupo de frases negativas. El resultado principal es un vector de dimensión 9216×1 (omeda_vec), donde cada elemento indica la contribución de una variable de atención a la diferencia entre ambos grupos.

En la Figura 8.9 se representa el vector oMEDA completo. El eje horizontal corresponde al índice de la variable de atención, mientras que el eje vertical indica el valor oMEDA asociado. Los valores positivos representan variables más asociadas al grupo positivo, mientras que los valores negativos representan variables más asociadas al grupo negativo.




Figura 8.9: Vector oMEDA obtenido al comparar frases positivas frente a frases negativas.

La gráfica muestra que la mayoría de las variables presentan valores cercanos a cero, lo que indica que muchas relaciones de atención no contribuyen de forma destacada a diferenciar ambos grupos. Sin embargo, también se observa un conjunto de variables con valores de mayor magnitud, tanto positivos como negativos. Estas variables son las que presentan una mayor capacidad para explicar la diferencia media entre frases positivas y negativas en el espacio PCA.

Un aspecto especialmente relevante es que la amplitud de los valores oMEDA aumenta en la parte final del vector. Teniendo en cuenta que las variables se ordenaron siguiendo la estructura de capas y cabezas del modelo, este comportamiento sugiere que las capas más profundas de BERT tienen una mayor contribución en la diferenciación entre ambos grupos. Este resultado es coherente con la interpretación habitual de los modelos Transformer, donde las capas iniciales tienden a capturar relaciones más locales o superficiales, mientras que las capas finales suelen estar más relacionadas con representaciones abstractas y próximas a la tarea de clasificación.

8.4.1. Distribución de la importancia de las variables

Para analizar la relevancia de cada variable sin tener en cuenta el signo de su contribución, se calculó la importancia como el valor absoluto del vector oMEDA. La Figura 8.10 muestra el histograma de importancia de las 9216 variables.




Figura 8.10: Distribución de la importancia absoluta de las 9216 variables de atención.

La distribución presenta una forma claramente asimétrica. La mayor parte de las variables se concentra en valores bajos de importancia, mientras que solo un conjunto reducido alcanza valores elevados, en concreto solo son 512 variables las que superan el umbral establecido. Esto indica que la diferencia entre frases positivas y negativas no depende de todas las variables de atención por igual, sino de un subconjunto más limitado de relaciones entre tokens, capas y cabezas.

En la gráfica también se incluye un umbral estadístico definido como la media de las importancias más dos veces su desviación típica. Este umbral permi-

te identificar automáticamente aquellas variables cuya contribución destaca respecto al comportamiento general del conjunto. Las variables situadas por encima de este valor pueden considerarse especialmente relevantes en el análisis exploratorio, ya que presentan una contribución superior a la esperada en la distribución global.

Este resultado refuerza la utilidad de oMEDA como herramienta de interpretación, ya que permite reducir el número de variables candidatas a analizar. En lugar de estudiar manualmente las 9216 relaciones de atención, el método permite focalizar la interpretación en aquellas que presentan una mayor contribución a la diferencia entre grupos.

8.4.2. Importancia acumulada por capas

Para interpretar los resultados de oMEDA de forma estructural, se agrupó la importancia de las variables en función de la capa de BERT a la que pertenecen. La Figura 8.11 muestra la importancia acumulada por capa.




Figura 8.11: Importancia acumulada por capa del modelo BERT.

El resultado muestra una tendencia clara: la importancia acumulada aumenta progresivamente hacia las capas finales del modelo. Las primeras capas presentan una contribución más reducida, mientras que las capas superiores concentran los mayores valores de importancia. En particular, las últimas capas destacan de forma notable respecto al resto.

Este resultado es especialmente relevante desde el punto de vista de la interpretación del modelo. En BERT, las capas iniciales suelen estar más relacionadas con patrones léxicos y relaciones locales entre tokens, mientras que las capas finales tienden a capturar información más abstracta y más

vinculada a la tarea específica para la que el modelo ha sido ajustado. Dado que el modelo utilizado está ajustado para clasificación de sentimiento, resulta razonable que las capas finales tengan un papel más importante en la diferenciación entre frases positivas y negativas.

Por tanto, el análisis por capas sugiere que la información más discriminativa para la tarea no se encuentra distribuida de manera uniforme a lo largo de toda la arquitectura, sino que aparece concentrada principalmente en los niveles superiores del modelo. Esto no implica que las primeras capas no sean importantes, ya que forman la base de la representación, pero sí indica que las diferencias más relevantes entre clases se manifiestan con mayor intensidad en las capas finales.

Como línea futura, podría estudiarse la reducción de la complejidad del modelo mediante el entrenamiento o ajuste de una versión más compacta de BERT. Los resultados obtenidos en el análisis por capas sugieren que algunas capas presentan una contribución menor en la diferenciación entre frases positivas y negativas, mientras que las capas finales concentran una mayor relevancia. Esto podría motivar el uso de técnicas de compresión, poda o reducción del número de capas, con el objetivo de disminuir el número de parámetros y el coste computacional del modelo. No obstante, esta hipótesis debería validarse experimentalmente comparando el rendimiento y las explicaciones obtenidas con el modelo completo frente a versiones reducidas.

8.4.3. Importancia por capa y cabeza de atención

Para obtener una interpretación más detallada, se analizó también la importancia acumulada por cada combinación de capa y cabeza de atención. El resultado se muestra en la Figura 8.12, donde cada celda representa la importancia asociada a una cabeza concreta dentro de una capa determinada.




Figura 8.12: Mapa de importancia acumulada por capa y cabeza de atención.

El mapa confirma la tendencia observada en el análisis por capas: las mayores contribuciones aparecen en las capas superiores, especialmente en la última capa del modelo. Además, dentro de esas capas finales, no todas las cabezas presentan la misma importancia. Algunas cabezas muestran valores claramente superiores, lo que indica que determinadas cabezas de atención tienen un papel más relevante en la diferenciación entre frases positivas y negativas.

Este resultado pone de manifiesto que la importancia del modelo no solo varía entre capas, sino también entre cabezas dentro de una misma capa. Esta observación es coherente con la idea de que las cabezas de atención pueden especializarse en capturar distintos tipos de relaciones entre tokens. Mientras algunas cabezas pueden centrarse en relaciones estructurales o posicionales, otras pueden capturar patrones más relacionados con el contenido semántico de la frase o con la tarea de clasificación.

La presencia de zonas de alta importancia en las capas finales sugiere que ciertas cabezas actúan como componentes especialmente relevantes en la construcción de la representación final utilizada para clasificar el sentimiento. No obstante, esta interpretación debe realizarse con cautela. Una cabeza con alta importancia oMEDA no debe entenderse automáticamente como la causa directa de la predicción, sino como una región del modelo cuyas variables de atención están más asociadas a la diferencia observada entre los grupos analizados.

8.4.4. Importancia relativa por token mediante oMEDA

Además del análisis de importancia por capas y cabezas, se ha calculado la importancia relativa por posición de token mediante oMEDA. Dado que cada variable de atención está asociada a una relación entre un token origen y un token destino, la importancia de cada posición se ha calculado considerando ambas contribuciones: cuando el token actúa como origen de la atención, cuando actúa como destino y como suma combinada de ambas.




Figura 8.13: Importancia relativa por posición de token obtenida mediante oMEDA.

En la Figura 8.13 se observa que la importancia no se distribuye de forma uniforme entre todas las posiciones. Las posiciones asociadas a [CLS], al token final [SEP] y al punto presentan una contribución elevada. Este resultado indica que, desde el punto de vista de oMEDA, las diferencias entre frases positivas y negativas no se concentran únicamente en una palabra concreta, sino en varias posiciones de la secuencia y en las relaciones de atención que estas establecen.

Resulta especialmente relevante la importancia de los tokens especiales [CLS] y [SEP]. Aunque no representan palabras con significado léxico directo, forman parte de la representación interna de BERT y participan en la organización de la secuencia. El token [CLS], en particular, tiene un papel estructural importante en tareas de clasificación, ya que su representación final suele utilizarse como resumen de la frase completa. Por ello, que aparezca como una posición relevante en oMEDA es coherente con el funcionamiento interno del modelo.

También se aprecia que las contribuciones como origen, destino y combinada siguen perfiles relativamente parecidos. Esto sugiere que la importancia de cada posición no depende únicamente de recibir atención o de emitirla, sino de su participación global en las relaciones internas de la frase.

8.4.5. Importancia global de tokens mediante oMEDA-PCA




Figura 8.14: Tokens más importantes según oMEDA-PCA en el conjunto experimental.

La Figura 8.14 muestra los tokens con mayor importancia media relativa obtenidos mediante oMEDA-PCA. En este caso, el ranking está encabezado por palabras con una carga sentimental clara, como *dumb*, *bad*, *stale*, *good*, *liked*, *warm*, *hated*, *smart*, *sharp*, *annoying*, *fresh*, *loved*, *awful* o *dull*. Por tanto, el resultado presenta una correspondencia razonable con la polaridad de las frases del conjunto experimental.

Aun así, también aparecen algunos tokens menos directamente asociados al sentimiento, como *worked*, *natural*, *looked*, *it*, *this* o *soundtrack*. Esta presencia es esperable, ya que oMEDA-PCA no calcula una atribución directa de cada palabra sobre la salida final del modelo, sino que trabaja sobre las variables internas de atención. En este análisis, un token resulta relevante cuando participa en relaciones de atención que tienen peso en la estructura multivariante capturada por el PCA.

El resultado obtenido es coherente ya que la mayoría de los tokens destacados sí tienen una relación clara con la polaridad positiva o negativa. Esto sugiere

que, al aplicar oMEDA-PCA siguiendo el esquema de cálculo planteado para la toolbox, la importancia acumulada por token refleja mejor las diferencias entre frases positivas y negativas.

No obstante, la interpretación debe mantenerse separada de la de SHAP. SHAP mide el efecto directo de ocultar o perturbar un token sobre la predicción final de BERT. oMEDA-PCA, en cambio, identifica qué tokens participan en relaciones de atención relevantes dentro del espacio latente. Por ello, aunque ambos métodos puedan destacar palabras sentimentalmente importantes, no están midiendo exactamente el mismo fenómeno.

En conjunto, la gráfica indica que las variables de atención asociadas a términos con carga valorativa tienen un papel destacado en la estructura interna analizada mediante oMEDA-PCA. La presencia de algunos tokens contextuales muestra, además, que la información utilizada por BERT no depende únicamente de palabras aisladas, sino también de relaciones internas entre los distintos elementos de la secuencia.

8.4.6. Relación entre PCA y oMEDA

Los resultados obtenidos mediante PCA y oMEDA deben interpretarse de forma complementaria. En primer lugar, el PCA, calculado mediante la MEDA Toolbox a partir de la matriz de atención preprocesada, permite estudiar la estructura global de las 40 frases en un espacio de menor dimensión. Esta representación ofrece una visión exploratoria de la distribución de las observaciones y permite comprobar si existen patrones internos en las matrices de atención extraídas de BERT. Sin embargo, la separación entre frases positivas y negativas no aparece necesariamente de forma directa en los primeros planos de componentes principales, lo que indica que la información discriminativa no se concentra únicamente en una proyección bidimensional sencilla.

A partir del modelo PCA obtenido con la MEDA Toolbox, el análisis oMEDA permite dar un paso más en la interpretación. Para ello, se define un contraste entre frases positivas y negativas mediante una variable *dummy*, y se emplea la función `omeda` de la propia toolbox para proyectar dicha diferencia de nuevo sobre el espacio original de variables. De esta forma, se obtiene un vector oMEDA asociado a las 9216 variables de atención, donde cada valor cuantifica la contribución de una relación de atención concreta al contraste entre ambos grupos.

Esta combinación resulta especialmente útil en el contexto del análisis de modelos BERT. Si se considerara únicamente el PCA, podría concluirse que la separación entre clases no es evidente en las primeras componentes. No obstante, oMEDA muestra que sí existen variables internas con contribuciones diferenciadas, especialmente concentradas en las capas finales del modelo. Este resultado sugiere que la información relacionada con la polaridad de las

frases no se manifiesta como una separación visual simple entre observaciones, sino como un patrón distribuido en múltiples variables de atención.

Por tanto, PCA y oMEDA proporcionan dos niveles distintos de análisis. El PCA ofrece una visión global y geométrica de las observaciones, mientras que oMEDA permite identificar qué variables originales participan con mayor intensidad en la diferencia entre frases positivas y negativas. Al haberse realizado ambos análisis dentro del mismo entorno metodológico de la MEDA Toolbox, los resultados mantienen una mayor coherencia: el modelo PCA se obtiene mediante `pcaEig` y el contraste interpretativo se calcula posteriormente con `omeda` utilizando los *loadings* del propio modelo. Esta relación permite pasar de una visualización exploratoria de la estructura de los datos a una interpretación más concreta de las relaciones de atención relevantes dentro de BERT.

8.5. Análisis mediante PLS-DA y comparación con oMEDA

Con el objetivo de complementar el análisis exploratorio realizado mediante PCA y oMEDA, se ha repetido el estudio utilizando PLS-DA. Esta técnica permite introducir las etiquetas de clase durante el análisis, por lo que resulta adecuada para comprobar si las variables de atención contienen información discriminante entre frases positivas y negativas.

A diferencia del PCA, que busca las direcciones de máxima variabilidad sin conocer las clases, PLS-DA construye un espacio latente orientado a separar los grupos definidos previamente. Por este motivo, el análisis PLS-DA no sustituye al PCA, sino que lo complementa desde una perspectiva supervisada.

8.5.1. Selección del número de componentes

En primer lugar, se evaluó el número de componentes PLS mediante validación cruzada tipo *leave-one-out*. La Figura 8.15 muestra la precisión obtenida en función del número de componentes utilizado.




Figura 8.15: Selección del número de componentes en PLS-DA mediante validación cruzada.

Se observa que con una única componente la precisión ya alcanza un valor elevado, mientras que a partir de dos componentes el modelo consigue separar correctamente las observaciones del conjunto experimental. Esto indica que las variables de atención contienen información suficiente para discriminar entre las frases positivas y negativas cuando se utiliza un enfoque supervisado.

No obstante, este resultado debe interpretarse con cautela, ya que el número de observaciones es reducido. La finalidad de esta prueba no es construir un clasificador definitivo, sino comprobar si la información interna extraída de BERT presenta capacidad discriminante entre ambos grupos de frases.

8.5.2. Varianza residual de la variable de clase en PLS-DA

Además de la validación cruzada mediante PLS-DA, se analizó la evolución de la variable de clase en función del número de variables latentes del modelo. Para ello, se utilizó la función `varPls` de la MEDA Toolbox, que permite estudiar cómo varía la parte no explicada de la variable respuesta al aumentar el número de variables latentes.

En este caso, la variable respuesta corresponde a la etiqueta de polaridad de cada frase, codificada como $+1$ para frases positivas y -1 para frases negativas. Por tanto, el análisis no se realiza sobre una magnitud física continua, sino sobre una variable de clase utilizada para construir el modelo PLS-DA.




Figura 8.16: Evolución de la varianza residual de la variable de clase en función del número de variables latentes del modelo PLS-DA.

En la Figura 8.16 se observa que, para cero variables latentes, el valor de la varianza residual es máximo. Esto es coherente, ya que en ausencia de variables latentes el modelo no incorpora información de la matriz de atención para explicar la variable de clase. Al introducir la primera variable latente, la varianza residual disminuye de forma muy acusada, lo que indica que gran parte de la información relacionada con la separación entre frases positivas y negativas queda recogida ya en la primera dirección latente del modelo.

A partir de la segunda variable latente, la reducción de la varianza residual es mucho más suave. Esto sugiere que las variables latentes adicionales aportan información complementaria, pero con una contribución progresivamente menor respecto a la primera. En otras palabras, la estructura supervisada que relaciona las matrices de atención con la polaridad de las frases parece estar concentrada principalmente en las primeras variables latentes.

Este resultado debe interpretarse de forma complementaria a la validación cruzada. La gráfica no representa directamente el error de clasificación ni el *accuracy* del modelo, sino la evolución de la parte residual de la variable de clase dentro del modelo PLS-DA. Por este motivo, la elección final del número de variables latentes debe apoyarse principalmente en la validación cruzada, mientras que esta representación resulta útil para comprender cómo el modelo va capturando progresivamente la información asociada a la polaridad.

8.5.3. Representación de las observaciones en el espacio PLS-DA

Una vez ajustado el modelo, se representaron las observaciones en el espacio definido por las dos primeras variables latentes, LV1 y LV2. El resultado se muestra en la Figura 8.17.




Figura 8.17: Representación de las observaciones en el espacio PLS-DA formado por LV1 y LV2.

A diferencia de lo observado en el PCA, en este caso las frases positivas y negativas aparecen claramente separadas en el eje LV1. Las frases negativas se sitúan principalmente en la zona izquierda del gráfico, mientras que las positivas se agrupan en la zona derecha. Este resultado confirma que, al introducir las etiquetas de clase, las variables de atención permiten construir un espacio latente con capacidad discriminante entre ambos grupos.

Esta diferencia frente al PCA es esperable. PCA no utiliza las etiquetas, por lo que sus primeras componentes no tienen por qué estar relacionadas con la polaridad de las frases. PLS-DA, en cambio, busca precisamente aquellas direcciones que mejor relacionan las variables de atención con la clase de cada observación.

8.5.4. Predicción continua y matriz de confusión

La salida continua del modelo PLS-DA se representa en la Figura 8.18. En esta gráfica, los valores superiores al umbral 0.5 se interpretan como clase positiva, mientras que los valores inferiores se interpretan como clase negativa.




Figura 8.18: Predicción continua del modelo PLS-DA para las 40 frases del conjunto experimental.

La separación entre ambos grupos es clara. Las frases positivas se sitúan por encima del umbral, mientras que las frases negativas quedan por debajo. Esto muestra que el modelo PLS-DA es capaz de asignar salidas diferenciadas a las dos clases a partir de las variables de atención extraídas de BERT.

La Figura 8.19 muestra la matriz de confusión obtenida.




Figura 8.19: Matriz de confusión obtenida mediante PLS-DA.

En las condiciones del experimento, el modelo clasifica correctamente las frases positivas y negativas del conjunto analizado. Este resultado refuerza la idea de que las matrices de atención contienen información relacionada con la polaridad de las frases. Aun así, debido al tamaño reducido del conjunto experimental, esta matriz debe interpretarse como una evidencia exploratoria y no como una medida definitiva de rendimiento.

8.5.5. Distribución de importancia de variables

Para analizar qué variables participan en la separación entre clases, se estudió la importancia de las variables a partir de los coeficientes del modelo PLS-DA. La Figura 8.20 muestra la distribución de estas importancias.

PLS-DA MEDA: distribución de importancia de variables




Figura 8.20: Distribución de la importancia de variables en PLS-DA a partir de los coeficientes del modelo.

La distribución presenta una forma asimétrica, con muchas variables de importancia reducida y un número menor de variables con contribución más elevada. Este comportamiento es similar al observado en el análisis oMEDA: la diferencia entre frases positivas y negativas no depende de una única variable, sino de un conjunto distribuido de relaciones de atención.

8.5.6. Importancia por capas y cabezas de atención

Para interpretar los resultados de forma estructural, la importancia de las variables obtenida mediante PLS-DA se agrupó según la capa de BERT a la que pertenece cada variable. En este caso la importancia se calcula a partir del valor absoluto de los coeficientes del modelo PLS-DA. De esta forma, cada variable de atención contribuye a la importancia acumulada de la capa correspondiente en función de la magnitud de su coeficiente.




Figura 8.21: Importancia acumulada por capa obtenida mediante los coeficientes del modelo PLS-DA.

La Figura 8.21 muestra una tendencia clara: la importancia acumulada aumenta progresivamente hacia las capas finales del modelo. Las primeras capas presentan una contribución reducida y relativamente estable, mientras que a partir de las capas intermedias-altas comienza a observarse un incremento más marcado. Las capas 10, 11 y 12 concentran la mayor parte de la importancia, siendo la capa 12 la que presenta el valor más elevado.

Este resultado es coherente con lo observado previamente mediante oMEDA. Ambos análisis apuntan a que las capas finales de BERT participan de forma más intensa en la diferenciación entre frases positivas y negativas. En el caso de PLS-DA, esta conclusión procede de los coeficientes del modelo supervisado, que relacionan directamente las variables de atención con la variable de clase codificada como $+1$ para frases positivas y -1 para frases negativas.

La interpretación debe realizarse en términos relativos: una mayor importancia acumulada en una capa indica que las relaciones de atención pertenecientes a esa capa tienen, en conjunto, una mayor contribución al modelo PLS-DA. Por tanto, la gráfica no indica que una única variable sea responsable de la separación entre clases, sino que las variables asociadas a las capas finales acumulan una mayor influencia en la discriminación positiva-negativa.

La Figura 8.22 muestra la importancia acumulada por combinación de capa y cabeza de atención.




Figura 8.22: Importancia acumulada por capa y cabeza de atención obtenida mediante PLS-DA.

El mapa confirma que la importancia no se distribuye de manera uniforme dentro del modelo. Las mayores contribuciones se concentran en las capas superiores y, dentro de ellas, en determinadas cabezas concretas. Esto sugiere que algunas cabezas de atención tienen un papel más relevante en la discriminación entre frases positivas y negativas.

No obstante, esta interpretación debe entenderse como una asociación estadística dentro del análisis PLS-DA, no como una prueba causal directa. Una cabeza con mayor importancia indica que sus variables de atención contribuyen más a la separación supervisada, pero no implica por sí sola que sea la causa única de la decisión del modelo.

8.5.7. Comparación entre oMEDA y PLS-DA

Una parte fundamental del análisis consiste en comparar los resultados obtenidos mediante oMEDA y PLS-DA. Aunque ambos métodos parten de enfoques diferentes, ambos permiten estudiar qué variables de atención están más asociadas a la diferencia entre frases positivas y negativas.

La Figura 8.23 muestra la comparación de la importancia normalizada por capas obtenida con ambos métodos.




Figura 8.23: Comparación de la importancia normalizada por capas obtenida mediante oMEDA y PLS-DA utilizando la MEDA Toolbox.

La Figura 8.23 compara la distribución de importancia por capas obtenida mediante oMEDA y PLS-DA, normalizando previamente ambas medidas para hacerlas comparables. Esta normalización es necesaria porque los valores absolutos de ambos métodos no están en la misma escala: oMEDA calcula la contribución de cada variable al contraste positivo-negativo dentro del modelo PCA, mientras que PLS-DA utiliza los coeficientes del modelo supervisado para relacionar las variables de atención con la clase de cada frase.

A pesar de esta diferencia metodológica, ambos métodos muestran una tendencia común: la importancia aumenta hacia las capas finales de BERT. Las capas iniciales presentan una contribución reducida, mientras que las capas 10, 11 y 12 concentran la mayor parte de la importancia en ambos análisis. Este resultado refuerza la interpretación de que las representaciones internas más profundas del modelo contienen mayor información relacionada con la diferenciación entre frases positivas y negativas.

No obstante, también se observan diferencias entre ambos métodos. En oMEDA, la importancia aparece más concentrada en las capas 11 y 12, especialmente en la capa 12, que presenta la contribución normalizada más elevada. En cambio, PLS-DA muestra una distribución algo más repartida a lo largo de las capas intermedias y finales, aunque mantiene igualmente un incremento claro hacia las capas superiores. Esto indica que oMEDA resalta con más intensidad las variables que explican el contraste positivo-negativo dentro del modelo PCA, mientras que PLS-DA reparte la contribución según el ajuste supervisado de los coeficientes del modelo.

Por tanto, la comparación confirma que ambos enfoques son coherentes en la conclusión general, pero no idénticos en la forma de asignar importancia. oMEDA ofrece una interpretación ligada al contraste entre grupos proyec-

tado desde el modelo PCA, mientras que PLS-DA proporciona una lectura supervisada basada en la capacidad de las variables de atención para predecir la polaridad. La coincidencia en la relevancia de las capas finales aporta solidez al análisis, ya que dos métodos distintos señalan la misma zona del modelo como la más relacionada con la tarea de clasificación de sentimiento.

La Figura 8.24 muestra la comparación variable a variable entre la importancia absoluta obtenida mediante oMEDA y la importancia calculada mediante los coeficientes en PLS-DA.




Figura 8.24: Comparación variable a variable entre la importancia obtenida mediante oMEDA y PLS-DA.

La Figura 8.24 muestra la comparación variable a variable entre la importancia obtenida mediante oMEDA y la importancia obtenida mediante PLS-DA. Cada punto representa una de las 9216 variables de atención, asociada a una combinación concreta de capa, cabeza, token origen y token destino.

En el eje horizontal se representa el valor absoluto de oMEDA, mientras que en el eje vertical se representa el valor absoluto del coeficiente del modelo PLS-DA. En ambos casos se emplea el valor absoluto porque el objetivo de esta comparación es analizar la magnitud de la importancia, independientemente de la dirección positiva o negativa de la contribución.

La distribución de los puntos muestra una tendencia creciente clara. Esto indica que las variables que reciben una importancia elevada según oMEDA tienden también a presentar coeficientes elevados en el modelo PLS-DA. Por tanto, aunque ambos métodos tienen fundamentos distintos, existe una relación consistente entre las variables destacadas por cada uno de ellos.

Debe tenerse en cuenta que las escalas numéricas de ambos métodos no son directamente comparables. oMEDA mide la contribución de cada variable al contraste positivo-negativo dentro del modelo PCA, mientras que PLS-

DA asigna coeficientes a las variables en un modelo supervisado orientado a separar las clases. Por ello, la interpretación de la figura debe centrarse en la tendencia y en la relación relativa entre ambas medidas, no en la comparación directa de sus magnitudes absolutas.

La acumulación de puntos en la zona inferior izquierda indica que la mayoría de variables presentan una importancia reducida en ambos métodos. En cambio, los puntos situados hacia la zona superior derecha corresponden a variables que son relevantes tanto para oMEDA como para PLS-DA. Esta coincidencia refuerza la consistencia del análisis, ya que dos enfoques distintos identifican patrones similares dentro de las matrices de atención de BERT.

8.5.8. Importancia relativa por token mediante PLS-DA

En el caso de PLS-DA, la importancia por posición de token se ha obtenido a partir del valor absoluto de los coeficientes del modelo PLS-DA calculado con la MEDA Toolbox. Cada coeficiente está asociado a una variable de atención concreta y, por tanto, a una combinación formada por capa, cabeza, token origen y token destino. Para interpretar estos resultados a nivel de secuencia, las importancias se han acumulado según la posición del token como origen, como destino y mediante una medida combinada.




Figura 8.25: Importancia relativa por posición de token obtenida mediante los coeficientes del modelo PLS-DA.

La Figura 8.25 muestra que la importancia no se concentra únicamente en

una posición concreta, sino que aparece distribuida a lo largo de la secuencia. No obstante, se observan diferencias entre tokens. Las posiciones [CLS], [SEP] y el punto final presentan una contribución elevada, mientras que posiciones intermedias como el Token 3 muestran una importancia menor. También se aprecia una contribución relevante en los Tokens 5 y 6, lo que indica que las palabras situadas hacia la parte final de la frase participan de forma apreciable en el modelo supervisado, siendo estas equivalentes a los modificadores y adjetivos de las frases.

La presencia de importancia elevada en [CLS] y [SEP] debe interpretarse con cautela. Estos tokens no corresponden a palabras con significado léxico propio, sino a posiciones estructurales introducidas por BERT durante la tokenización. Su relevancia en PLS-DA indica que un número considerable de relaciones de atención asociadas a estas posiciones contribuye al modelo de separación entre frases positivas y negativas. Por tanto, no debe entenderse como una carga semántica directa, sino como una participación estructural dentro de las matrices de atención.

La comparación entre las contribuciones como token origen y como token destino permite observar si una posición destaca más por emitir atención hacia otros tokens o por recibir atención desde ellos. En general, las tres medidas muestran perfiles similares, especialmente en la importancia combinada, lo que sugiere que las posiciones más relevantes participan de forma global en las relaciones de atención. En este sentido, PLS-DA confirma que la discriminación entre frases positivas y negativas no depende únicamente de una palabra aislada, sino de patrones distribuidos de atención entre varias posiciones de la secuencia.

Este resultado es coherente con la interpretación obtenida mediante oMEDA. Aunque ambos métodos asignan importancia de forma distinta, oMEDA a partir del contraste positivo-negativo proyectado desde el modelo PCA y PLS-DA mediante un modelo supervisado basado en coeficientes, ambos señalan que las posiciones estructurales y los tokens finales de la secuencia tienen un papel relevante en la diferenciación entre clases.

8.5.9. Importancia global de tokens mediante PLS-DA




Figura 8.26: Tokens más importantes según PLS-DA en el conjunto experimental.

La Figura 8.26 muestra los tokens con mayor importancia media relativa obtenidos mediante PLS-DA. En este caso, el ranking está dominado por palabras con una carga sentimental clara, tanto negativa como positiva. Entre los términos más relevantes aparecen tokens negativos como *dumb*, *bad*, *stale*, *hated*, *annoying*, *awful* o *dull*, junto con tokens positivos como *good*, *liked*, *warm*, *smart*, *sharp*, *fresh* o *loved*.

Este resultado es coherente con el carácter supervisado de PLS-DA. A diferencia de PCA, que busca únicamente direcciones de máxima variabilidad en la matriz de atención, PLS-DA utiliza la variable de clase para construir un modelo orientado a separar las frases positivas y negativas. Por ello, los tokens que aparecen con mayor importancia son aquellos cuyas relaciones de atención están más asociadas a la discriminación entre ambas clases.

También aparecen algunos tokens menos directamente sentimentales, como *worked*, *natural*, *looked*, *it*, *this* o *soundtrack*. Su presencia indica que PLS-DA no está midiendo únicamente el significado aislado de cada palabra, sino la importancia acumulada de las relaciones de atención en las que participa cada token. Así, una palabra puede resultar relevante no solo por su polaridad propia, sino por el papel que desempeña dentro del patrón interno de atención utilizado para separar las clases.

Este resultado presenta una interpretación más clara a nivel lingüístico, ya

que la mayoría de los tokens destacados sí están relacionados con el sentimiento de la frase. Esto refuerza la idea de que, siguiendo el esquema de cálculo planteado para la toolbox, PLS-DA captura información discriminante de las matrices de atención asociada a la polaridad positiva o negativa.

Por tanto, el análisis mediante PLS-DA permite concluir que las relaciones de atención de BERT contienen información útil para separar las clases de sentimiento. Los tokens más relevantes no deben interpretarse como una explicación directa de la predicción palabra a palabra, como ocurre con SHAP, sino como posiciones cuyas relaciones de atención tienen un peso importante dentro del modelo supervisado.

8.6. Análisis mediante ASCA

Con el objetivo de completar el estudio multivariante de las matrices de atención, se ha aplicado ASCA sobre el mismo conjunto experimental utilizado en los análisis anteriores. Esta técnica permite estudiar la variabilidad de los datos en función de los factores definidos en el diseño experimental. En este caso, el factor principal de interés es la clase de sentimiento, es decir, si la frase es positiva o negativa.

A diferencia de PLS-DA, ASCA no se utiliza como un clasificador supervisado, sino como una herramienta de descomposición de la variabilidad. Su objetivo es analizar si el factor clase produce un efecto apreciable sobre las matrices de atención y, posteriormente, estudiar en qué capas, cabezas y tokens se concentra dicho efecto.

8.6.1. Representación del efecto de clase

En primer lugar, se analiza la representación de scores asociada al Factor 1 del modelo ASCA. En este trabajo, el Factor 1 corresponde a la clase de sentimiento, con dos niveles: frases positivas y frases negativas. La Figura 8.27 muestra la proyección de las observaciones sobre la primera componente principal del efecto de clase.




Figura 8.27: Representación de scores asociada al Factor 1 del modelo ASCA, correspondiente al efecto de clase positiva o negativa.

La figura muestra una separación clara entre las frases positivas y negativas. Las frases positivas aparecen agrupadas en un lado de la componente, mientras que las negativas se sitúan en el lado opuesto. El signo de la componente no tiene una interpretación semántica directa, ya que en los análisis basados en componentes el sentido positivo o negativo del eje puede invertirse sin cambiar el significado del resultado. Lo relevante es que ambas clases quedan diferenciadas.

Este resultado indica que el factor clase introduce una variación sistemática en las matrices de atención. En otras palabras, el cambio de polaridad entre frases positivas y negativas no solo afecta a la predicción final del modelo, sino que también se refleja en los patrones internos de atención extraídos de BERT. Además, la primera componente del efecto de clase explica una parte relevante de la variabilidad asociada a dicho factor, lo que sugiere que la diferencia entre clases puede describirse mediante una dirección dominante en el espacio latente.

Este resultado es coherente con lo observado mediante PLS-DA, donde también se apreciaba una separación clara entre frases positivas y negativas. Sin embargo, la interpretación de ambos métodos es diferente. PLS-DA busca directamente una dirección discriminante entre clases, mientras que ASCA separa primero la variabilidad asociada al factor clase y después la representa mediante componentes principales.

8.6.2. Análisis de importancia mediante ASCA

Una vez obtenida la matriz asociada al factor clase mediante la MEDA Toolbox, se analizó la importancia de las variables de atención. En este caso, la importancia no procede de una predicción supervisada ni de un enmascaramiento de tokens, sino de la variabilidad atribuida por ASCA al factor clase. Para cada variable de atención, la importancia se calcula como la suma de cuadrados de la matriz de efecto correspondiente a la diferencia entre frases positivas y negativas.

ASCA MEDA: distribución de importancia de variables




Figura 8.28: Distribución de la importancia ASCA de las variables de atención.

La Figura 8.28 muestra que la mayor parte de las variables presentan una importancia reducida. La distribución está fuertemente concentrada cerca de cero y presenta una cola hacia valores más altos. Este comportamiento indica que el efecto clase no se reparte de manera uniforme entre las 9216 variables de atención, sino que queda concentrado en un subconjunto más reducido de relaciones internas. En otras palabras, muchas variables apenas participan en la diferencia entre frases positivas y negativas, mientras que unas pocas acumulan una contribución claramente superior.

8.6.3. Importancia por token origen

También se analizó la importancia de las variables en función del token origen. En una matriz de atención, el token origen se interpreta como la posición desde la cual parte la atención hacia el resto de tokens de la secuencia.

En las figuras siguientes, el Token 1 corresponde a [CLS], el Token 7 corres-

ponde al punto final de la frase y el Token 8 corresponde a [SEP].




Figura 8.29: Importancia relativa ASCA por token origen.

La Figura 8.29 muestra que la importancia como token origen no se reparte de forma uniforme entre las posiciones de la secuencia. Destacan especialmente el Token 1, el Token 7 y el Token 8, correspondientes a [CLS], el punto final y [SEP], respectivamente.

Este resultado indica que las relaciones de atención que parten de posiciones estructurales de la secuencia tienen una contribución relevante al efecto clase. En particular, la importancia de [CLS] es coherente con el papel que este token desempeña en BERT en tareas de clasificación, ya que suele actuar como una posición agregadora de información global de la secuencia.

La importancia elevada de los tokens finales también sugiere que las relaciones de atención que parten del cierre de la frase participan de forma apreciable en la diferenciación entre frases positivas y negativas.

8.6.4. Importancia por token destino

De forma complementaria, se analizó la importancia acumulada en función del token destino. En este caso, el token destino representa la posición hacia la cual se dirige la atención desde otros tokens de la secuencia.




Figura 8.30: Importancia relativa ASCA por token destino.

La Figura 8.30 muestra que el Token 1 presenta la mayor importancia como destino de atención. También destacan los tokens situados al final de la secuencia, especialmente el Token 7 y el Token 8. En cambio, algunas posiciones intermedias, como los Tokens 2 y 3, presentan una contribución menor.

La elevada importancia de [CLS] como token destino indica que muchas relaciones de atención relevantes para el efecto clase se dirigen hacia esta posición. Esto refuerza la interpretación de [CLS] como un elemento estructural importante en la representación global de la frase.

Por otro lado, la importancia de las posiciones finales sugiere que el cierre de la secuencia también interviene en la organización interna de la atención asociada a la polaridad. De nuevo, este resultado no debe interpretarse como que estos tokens tengan carga semántica propia, sino como que participan en relaciones estructurales relevantes dentro del modelo.

8.6.5. Importancia por cabezas de atención

Además de la agrupación por capas, se analizó la importancia acumulada por cabeza de atención. En esta representación, cada cabeza corresponde a una de las doce cabezas presentes en cada capa de BERT, acumulando su contribución a lo largo de todas las capas.




Figura 8.31: Importancia relativa acumulada por cabeza de atención obtenida mediante ASCA.

La Figura 8.31 muestra que la importancia no se distribuye de manera completamente uniforme entre las cabezas de atención. Algunas cabezas presentan una contribución mayor al efecto clase, destacando especialmente las cabezas 2 y 10. Por el contrario, otras cabezas, como la 8 y la 11, muestran una contribución más reducida.

Esta representación permite observar qué cabezas acumulan más importancia de forma global. Sin embargo, debe interpretarse con cautela, ya que cada cabeza aparece repetida en las doce capas del modelo. Por tanto, que una cabeza tenga una importancia global elevada no implica necesariamente que sea relevante en todas las capas, sino que su contribución acumulada es mayor al sumar todas sus apariciones.

Por este motivo, la importancia por cabeza debe complementarse con el análisis conjunto por capa y cabeza, que permite localizar con mayor precisión en qué zonas de la arquitectura se concentra el efecto clase.

8.6.6. Importancia por capa

Para interpretar los resultados de forma más estructural, las variables de atención se agruparon según la capa de BERT a la que pertenecen. De esta forma, la importancia de cada capa se obtiene acumulando la importancia ASCA de todas las variables asociadas a dicha capa.




Figura 8.32: Importancia relativa por capa obtenida mediante ASCA.

La Figura 8.32 muestra una tendencia clara hacia las capas finales del modelo. Las primeras capas presentan una contribución reducida, mientras que a partir de las capas intermedias-altas la importancia comienza a aumentar de forma más acusada. Las capas 10, 11 y 12 concentran la mayor parte de la importancia relativa, siendo la capa 12 la que presenta el valor más elevado.

Este resultado indica que la diferencia entre frases positivas y negativas se manifiesta principalmente en las representaciones internas más profundas de BERT. Las capas iniciales parecen tener una menor contribución al efecto clase, mientras que las capas finales acumulan relaciones de atención más asociadas a la polaridad de las frases.

La conclusión es coherente con los análisis realizados mediante oMEDA y PLS-DA, donde también se observó una mayor relevancia de las capas finales. En ASCA, esta interpretación procede directamente del efecto clase obtenido a partir del diseño experimental, no de un modelo supervisado ni de un análisis por enmascaramiento.

8.6.7. Importancia por capa y cabeza de atención

Para obtener una visión más detallada de la distribución de la importancia dentro de la arquitectura de BERT, se representó la importancia acumulada por combinación capa-cabeza. Esta representación permite identificar no solo qué capas son más relevantes, sino también qué cabezas concretas destacan dentro de cada capa.




Figura 8.33: Mapa de importancia ASCA agrupada por capa y cabeza de atención.

La Figura 8.33 confirma que las mayores contribuciones se concentran en las capas finales del modelo, especialmente en las capas 11 y 12. En las capas iniciales, la importancia es notablemente menor y aparece distribuida de forma más uniforme.

En la capa 12 se observan varias cabezas con una contribución elevada, especialmente en las primeras posiciones y en algunas cabezas intermedias. Esto indica que el efecto clase no depende únicamente de una cabeza aislada, sino de un patrón distribuido entre varias cabezas de las capas más profundas.

La lectura conjunta de esta figura y de la importancia por capa sugiere que la capa es un factor estructural especialmente relevante. Aunque existen diferencias entre cabezas, el aumento más claro de la importancia se produce al avanzar hacia las últimas capas del modelo. Por tanto, ASCA señala que la información relacionada con la polaridad se concentra principalmente en las representaciones profundas de BERT.

8.6.8. Importancia combinada por posición de token

Para resumir la contribución de cada posición de token, se representó conjuntamente la importancia como token origen, como token destino y una medida combinada obtenida a partir de ambas. Esta representación permite comparar si una posición destaca más por emitir atención, por recibir atención o por ambas funciones.




Figura 8.34: Importancia relativa por posición de token obtenida mediante ASCA, considerando el token como origen, como destino y de forma combinada.

La Figura 8.34 confirma que las posiciones [CLS], el punto final y [SEP] concentran una parte destacada de la importancia. Estas posiciones presentan valores elevados tanto en la medida combinada como en alguna de las dos contribuciones individuales, ya sea como origen o como destino.

Las posiciones intermedias presentan una importancia más moderada, aunque no despreciable. Esto indica que el efecto clase no se reduce únicamente a una posición concreta, sino que se distribuye entre varias relaciones de atención dentro de la secuencia.

La relevancia de [CLS] y [SEP] debe interpretarse desde el punto de vista estructural. Estos tokens no son palabras con significado léxico directo, sino elementos especiales introducidos durante la tokenización de BERT. Su importancia indica que las relaciones de atención asociadas a estas posiciones participan en la diferenciación entre frases positivas y negativas.

8.6.9. Importancia ASCA por pares de tokens

Finalmente, se representó la importancia ASCA acumulada para cada par token origen-token destino. A diferencia del mapa anterior, esta figura no muestra la dirección del efecto, sino únicamente la magnitud de la contribución de cada relación de atención al factor clase.




Figura 8.35: Mapa de importancia ASCA acumulada por pares de tokens.

La Figura 8.35 muestra que la importancia no está distribuida de manera uniforme entre todos los pares de tokens. Se observa una concentración destacada en relaciones que involucran [CLS], el punto final y [SEP]. En particular, las relaciones en las que [CLS] actúa como origen o destino presentan una importancia elevada.

Este resultado refuerza la idea de que el efecto clase no depende únicamente de la atención entre palabras con contenido semántico directo, sino también de relaciones estructurales propias de la representación de BERT. Las posiciones especiales de la secuencia parecen participar de forma relevante en la organización de la información que diferencia frases positivas y negativas.

En conjunto, los mapas por pares de tokens muestran que la polaridad se refleja en patrones distribuidos de atención. Algunas relaciones destacan por su magnitud, mientras que otras permiten diferenciar la dirección del efecto hacia el grupo positivo o negativo. Esta lectura complementa el análisis por capas y cabezas, aportando una visión más localizada de las relaciones internas asociadas al factor clase.

8.6.10. Importancia global de tokens mediante ASCA




Figura 8.36: Tokens más importantes según ASCA en el conjunto experimental.

La Figura 8.36 muestra los tokens con mayor importancia media relativa obtenidos mediante ASCA. En este caso, el ranking está dominado principalmente por palabras con una carga semántica claramente asociada al sentimiento de la frase. Entre los tokens más relevantes aparecen términos positivos como *loved*, *smart*, *fresh*, *enjoyed*, *liked*, *strong*, *good*, *lovely*, *warm* o *nice*, junto con términos negativos como *weak*, *stale*, *hated*, *disliked*, *flat*, *dumb*, *bad*, *poor* o *dreadful*.

Este resultado es más coherente desde el punto de vista lingüístico, ya que ASCA no destaca de forma prioritaria elementos puramente estructurales de la frase, sino palabras que sí están relacionadas con la polaridad positiva o negativa. Esto indica que, al aplicar el procedimiento individualizado siguiendo el esquema planteado para la toolbox, la importancia acumulada por token refleja mejor el efecto asociado al factor de clase.

La interpretación debe hacerse teniendo en cuenta que ASCA no explica directamente la salida final del modelo BERT, como ocurre en SHAP. En este caso, la importancia procede del análisis multivariante de las matrices de atención y de la parte de la variabilidad asociada al diseño experimental. Por tanto, un token aparece como relevante cuando sus relaciones de atención participan de forma importante en el patrón que diferencia las frases positivas y negativas.

Aun así, el hecho de que los tokens más destacados sean mayoritariamente palabras con significado sentimental refuerza la validez del análisis. ASCA no está identificando únicamente posiciones estructurales de la secuencia, sino que también captura términos que, desde un punto de vista lingüístico, son determinantes para la polaridad de las frases. En este sentido, el resultado se aproxima más al comportamiento observado con SHAP, aunque la forma de calcular la importancia sea distinta.

Por tanto, este análisis permite interpretar que el factor clase produce cambios en las matrices de atención asociados principalmente a palabras con contenido valorativo. La presencia simultánea de términos positivos y negativos entre los tokens más importantes indica que ASCA está capturando diferencias relevantes entre ambos grupos de frases, no solo variaciones generales de estructura sintáctica.

8.7. Comparación conjunta entre oMEDA, PLS-DA, ASCA y SHAP


En esta sección se comparan de forma conjunta los resultados obtenidos mediante oMEDA, PLS-DA, ASCA y SHAP. El objetivo es analizar si los distintos métodos conducen a conclusiones coherentes sobre la estructura interna del modelo BERT y, al mismo tiempo, identificar las diferencias de interpretación que existen entre ellos.

La comparación se organiza en tres niveles. En primer lugar, se estudia la importancia agregada por capas del modelo. Después, se analiza la distribución conjunta por capa y cabeza de atención. Finalmente, se comparan los rankings globales de tokens. En este último caso se incluye también SHAP, ya que este método trabaja directamente sobre los tokens de entrada y no sobre las variables internas de atención agrupadas por capa y cabeza.


Debe tenerse en cuenta que las escalas numéricas no son directamente equivalentes entre métodos. oMEDA, PLS-DA y ASCA calculan la importancia a partir de criterios matemáticos distintos: contraste en el espacio PCA, coeficientes de un modelo supervisado y variabilidad atribuible al factor clase, respectivamente. Por tanto, la comparación debe interpretarse principalmente en términos de tendencias, zonas de concentración de importancia y coherencia estructural entre métodos.

8.7.1. Comparación de la importancia por capas


La Figura 8.37 muestra la importancia agregada por capas obtenida mediante oMEDA, PLS-DA y ASCA. En los tres casos se observa una tendencia común: las capas finales concentran la mayor parte de la importancia.



(a) oMEDA: importancia acumulada por capa.



(b) PLS-DA: importancia acumulada por capa.



(c) ASCA: importancia relativa por capa.

Figura 8.37: Comparación de la importancia por capas.


El resultado más relevante es la coincidencia entre los tres métodos en señalar las últimas capas como las más importantes. En oMEDA, la importancia aumenta de forma muy acusada en las capas 10, 11 y 12, siendo especialmente destacada la capa 12. PLS-DA presenta una tendencia muy similar: las primeras capas tienen una contribución baja y las capas finales concentran la mayor parte del peso del modelo discriminante. ASCA confirma este mismo comportamiento desde una perspectiva basada en el diseño experimental, mostrando que el efecto asociado al factor clase se concentra principalmente en las capas superiores.

Esta coincidencia es importante porque los tres métodos no calculan la importancia de la misma forma. oMEDA parte del contraste entre grupos en el espacio PCA, PLS-DA utiliza un modelo supervisado para separar frases positivas y negativas, y ASCA descompone la matriz de atención según los factores experimentales. A pesar de estas diferencias, los tres análisis apuntan a una misma conclusión: la información relacionada con la polaridad de las frases aparece con mayor intensidad en las capas finales de BERT.


Este comportamiento es coherente con la arquitectura del modelo. Las capas iniciales suelen recoger relaciones más locales o superficiales entre tokens, mientras que las capas finales integran representaciones más abstractas y más vinculadas a la tarea de clasificación. En este caso, al tratarse de un modelo ajustado para análisis de sentimiento, resulta razonable que las capas superiores contengan más información útil para diferenciar frases positivas y negativas.

8.7.2. Comparación de la importancia por capa y cabeza de atención


Además de agrupar la importancia únicamente por capas, se analizó la distribución conjunta por capa y cabeza de atención. Esta representación permite localizar con mayor precisión qué regiones internas de BERT concentran la importancia según cada método.

oMEDA MEDA Toolbox: importancia por layer-head

(a) oMEDA: importancia por capa y cabeza.

PLS-DA MEDA: importancia por layer-head

(b) PLS-DA: importancia por capa y cabeza.

ASCA MEDA: importancia por layer-head

(c) ASCA: importancia por capa y cabeza.

La Figura 8.38 confirma visualmente la conclusión obtenida en el análisis por capas. En los tres métodos, las zonas de mayor intensidad se concentran en las capas finales, especialmente en las capas 11 y 12. Las capas iniciales presentan valores mucho menores y una distribución más homogénea.


En oMEDA se observa una concentración clara en la capa 12, con varias cabezas que presentan una importancia elevada. PLS-DA muestra un patrón muy parecido, aunque con una escala distinta, destacando también varias cabezas de las capas superiores. ASCA reproduce la misma tendencia general, con máximos localizados en las últimas capas y, dentro de ellas, en determinadas cabezas concretas.

Este resultado sugiere que la polaridad no está asociada a una única cabeza aislada, sino a un patrón distribuido entre varias cabezas de las capas profundas. La importancia no aparece repartida de forma uniforme por toda la arquitectura, sino que se concentra en regiones concretas del modelo. Esta observación refuerza la idea de que las representaciones finales de BERT son las que contienen información más directamente relacionada con la tarea de clasificación de sentimiento.


También conviene señalar que las cabezas no deben interpretarse de forma independiente del nivel de capa en el que aparecen. Una misma cabeza, por ejemplo la cabeza 2 o la cabeza 10, puede tener una importancia distinta según la capa. Por este motivo, el mapa capa-cabeza resulta más informativo que un análisis global por cabezas, ya que permite observar dónde se localiza realmente la contribución dentro de la arquitectura.

8.7.3. Comparación global de importancia por tokens

Finalmente, se comparó la importancia global por tokens. En este caso sí se incluye SHAP, ya que este método proporciona directamente una importancia asociada a los tokens de entrada. Sin embargo, la interpretación no es equivalente a la de oMEDA, PLS-DA y ASCA. SHAP mide el efecto de cada token sobre la predicción final del modelo, mientras que los métodos multivariantes acumulan la importancia de las variables de atención en las que participa cada token como origen o destino.



(a) SHAP: tokens más importantes según su contribución directa a la predicción.




(b) oMEDA-PCA: tokens más importantes según la importancia acumulada de sus relaciones de atención.


Figura 8.39: Comparación global de los tokens más importantes mediante SHAP y oMEDA-PCA.

8.7. Comparación conjunta entre oMEDA, PLS-DA, ASCA y SHAP

160



(a) PLS-DA: tokens más importantes según el modelo supervisado sobre variables de atención.



(b) ASCA: tokens más importantes según la variabilidad atribuible al factor clase.

Figura 8.40: Comparación global de los tokens más importantes mediante PLS-DA y ASCA.

La diferencia entre SHAP y los métodos multivariantes es clara. En SHAP, los tokens más importantes son mayoritariamente palabras con carga sentimental directa. Aparecen términos como *disliked*, *hated*, *dreadful*, *painful*,

boring, poor, dull, bad, unpleasant, awful, annoying o *stale*. Este resultado es coherente con la naturaleza de SHAP, ya que el método evalúa cómo contribuye cada token a la salida final del clasificador.

En el caso de oMEDA-PCA, PLS-DA y ASCA, la mayoría de los tokens destacados corresponden a palabras con una polaridad clara, como *dumb, bad, stale, good, liked, warm, hated, smart, fresh* o *loved*. Esto indica que, al aplicar los métodos siguiendo el esquema de la MEDA Toolbox, la importancia acumulada por token refleja mejor la diferencia entre frases positivas y negativas.

No obstante, también aparecen algunos términos menos directamente sentimentales, como *worked, looked, this, it, natural* o *soundtrack*. Estos tokens no deben interpretarse como palabras con polaridad propia, sino como elementos que participan en relaciones de atención relevantes dentro del patrón multivariante analizado. Por tanto, los métodos multivariantes no ofrecen una explicación léxica directa como SHAP, pero sí permiten identificar qué tokens están asociados a relaciones internas de atención útiles para diferenciar las clases.

Esta diferencia no debe interpretarse como una contradicción entre métodos, sino como consecuencia de que cada uno analiza un objeto distinto. SHAP trabaja sobre la entrada textual y mide el impacto de cada token sobre la predicción. Por eso destaca principalmente palabras con polaridad explícita. En cambio, oMEDA-PCA, PLS-DA y ASCA trabajan sobre las matrices de atención de BERT. En estos métodos, un token puede resultar importante porque aparece implicado en muchas relaciones internas relevantes, aunque no sea por sí mismo una palabra positiva o negativa.

La comparación global de tokens permite distinguir dos niveles de explicación. SHAP ofrece una explicación más léxica, cercana a la decisión final del modelo. Los métodos multivariantes ofrecen una explicación más estructural, centrada en cómo se organiza internamente la atención. Por ello, la presencia de verbos, sujetos, determinantes o sustantivos en oMEDA, PLS-DA y ASCA indica que la clasificación de sentimiento no se refleja únicamente en palabras aisladas, sino también en patrones distribuidos de atención.

8.7.4. Interpretación conjunta

La comparación conjunta permite extraer una conclusión consistente. Los tres métodos basados en matrices de atención, oMEDA, PLS-DA y ASCA, coinciden en señalar las capas finales de BERT como las más relevantes para la diferenciación entre frases positivas y negativas. Esta coincidencia aparece tanto en el análisis agregado por capas como en el análisis detallado por capa y cabeza de atención.

Por otro lado, el análisis global de tokens muestra una diferencia importante entre SHAP y los métodos multivariantes. SHAP identifica principalmente palabras con polaridad semántica directa, mientras que oMEDA-PCA, PLS-DA y ASCA asignan importancia también a tokens con función estructural o contextual dentro de la frase. Esta diferencia confirma que ambos enfoques son complementarios.

En conjunto, SHAP permite interpretar qué palabras influyen de forma más directa en la predicción final del modelo, mientras que oMEDA, PLS-DA y ASCA permiten estudiar cómo se distribuye internamente la información en las matrices de atención. La lectura conjunta de todos los resultados sugiere que BERT no basa la clasificación únicamente en palabras sentimentales aisladas, sino que organiza la información mediante relaciones distribuidas entre tokens, capas y cabezas de atención.

8.8. Conclusiones del análisis

El conjunto de resultados obtenidos permite extraer una conclusión principal: las matrices de atención de BERT contienen información relacionada con la polaridad de las frases, pero dicha información no aparece de forma simple, directa ni concentrada en un único elemento del modelo. Al contrario, se manifiesta como un patrón distribuido entre múltiples variables de atención, capas, cabezas y posiciones de token. Por este motivo, el análisis realizado no puede reducirse a una única técnica de explicabilidad, sino que requiere combinar varios enfoques complementarios.

El primer nivel de análisis lo proporciona el PCA. A partir de la matriz de atención, formada por 40 observaciones y 9216 variables, el PCA permite estudiar la estructura global del conjunto experimental en un espacio de menor dimensión. Los resultados muestran que existe una estructura interna apreciable en los datos, pero que las frases positivas y negativas no se separan de forma clara en los primeros planos de componentes principales. Esta ausencia de separación directa no implica que las matrices de atención no contengan información sobre la clase, sino que dicha información no se organiza de manera lineal y sencilla en las primeras componentes.

La varianza explicada confirma esta interpretación. Aunque las primeras componentes principales recogen una parte relevante de la variabilidad, es necesario conservar un número mayor de componentes para alcanzar porcentajes elevados de varianza acumulada. Esto indica que el comportamiento interno del modelo no puede resumirse adecuadamente en una representación bidimensional. Las matrices de atención codifican relaciones procedentes de distintas capas, cabezas y pares de tokens, por lo que resulta esperable que la información esté distribuida en varias direcciones latentes.

A partir de este resultado, oMEDA permite avanzar desde la visualización global del PCA hacia una interpretación más concreta en el espacio original de variables. Mientras que PCA muestra cómo se distribuyen las observaciones, oMEDA identifica qué variables de atención contribuyen con mayor intensidad al contraste entre frases positivas y negativas. El vector oMEDA obtenido muestra que la mayoría de las 9216 variables presentan valores cercanos a cero, mientras que un subconjunto reducido concentra las contribuciones más relevantes. Por tanto, la diferencia entre ambos grupos no depende de todas las relaciones de atención por igual, sino de determinadas variables asociadas a capas, cabezas y pares de tokens concretos.

Uno de los resultados más consistentes del análisis oMEDA es la concentración de importancia en las capas finales de BERT. La agrupación por capas muestra un aumento progresivo de la contribución hacia los niveles superiores del modelo. Este comportamiento es coherente con la arquitectura de BERT y con la tarea analizada. Las capas iniciales suelen capturar relaciones más locales o superficiales, mientras que las capas finales integran representaciones más abstractas y más próximas a la tarea para la que el modelo ha sido ajustado. En este caso, al tratarse de clasificación de sentimiento, resulta razonable que las diferencias más relevantes entre frases positivas y negativas aparezcan con mayor intensidad en las últimas capas.

El análisis por capa y cabeza de atención refuerza esta misma idea. Las cabezas no contribuyen de forma uniforme: algunas presentan una importancia claramente superior, especialmente dentro de las capas finales. Esto sugiere que la información relacionada con la polaridad no se encuentra repartida de manera homogénea por toda la arquitectura, sino que determinadas regiones del modelo participan más activamente en la diferenciación entre clases. No obstante, esta interpretación debe plantearse con prudencia. Una cabeza con alta importancia no debe entenderse como la causa única de la predicción, sino como una zona del modelo cuyas variables de atención están más asociadas al contraste analizado.

El análisis mediante PLS-DA aporta una validación supervisada a estas observaciones. A diferencia del PCA, que no utiliza las etiquetas de clase, PLS-DA construye un espacio latente orientado a separar frases positivas y negativas. Los resultados muestran una separación mucho más clara entre ambos grupos, lo que confirma que las variables de atención contienen información discriminante sobre la polaridad. La matriz de confusión obtenida en el conjunto experimental refuerza esta idea, aunque debe interpretarse como una evidencia exploratoria debido al tamaño reducido de la muestra.

La comparación entre oMEDA y PLS-DA resulta especialmente importante. Aunque ambos métodos tienen fundamentos distintos, sus resultados son coherentes. oMEDA identifica variables relevantes a partir del contraste positivo-negativo proyectado desde el PCA, mientras que PLS-DA asigna

importancia mediante los coeficientes de un modelo supervisado. A pesar de esta diferencia, ambos métodos señalan una mayor relevancia de las capas finales y muestran una tendencia semejante en la comparación variable a variable. Las variables con alta importancia en oMEDA tienden también a presentar coeficientes relevantes en PLS-DA. Esta coincidencia fortalece la conclusión de que las capas superiores de BERT concentran una parte importante de la información asociada a la clasificación de sentimiento.

ASCA aporta una tercera perspectiva multivariante, basada en el diseño experimental. En este caso, el objetivo no es construir un clasificador, sino estudiar el efecto del factor clase sobre la matriz de atención. Los resultados muestran que el factor positivo-negativo introduce una variación apreciable en los datos. La representación de scores asociada al factor clase separa de forma clara ambos grupos, lo que indica que la polaridad de la frase se refleja en la estructura multivariante de las atenciones.

El análisis de importancia mediante ASCA confirma de nuevo que la contribución no se distribuye de manera uniforme entre todas las variables. La mayoría presenta una importancia reducida, mientras que un conjunto menor concentra valores más elevados. Además, la agrupación por capas vuelve a mostrar una tendencia clara hacia las capas finales, especialmente las capas 10, 11 y 12. Esta coincidencia entre oMEDA, PLS-DA y ASCA es uno de los resultados más sólidos del capítulo: tres enfoques diferentes señalan que las representaciones profundas de BERT son las más relacionadas con la diferenciación entre frases positivas y negativas.

El análisis de ASCA por tokens y por pares de tokens permite completar esta interpretación. Las posiciones especiales de la secuencia, como [CLS] y [SEP], así como el punto final, presentan una contribución destacada en varios análisis basados en atención. Este resultado no significa que dichos tokens tengan una carga sentimental propia, sino que participan en la organización interna de la representación. En BERT, [CLS] cumple un papel estructural relevante en tareas de clasificación, ya que su representación final se utiliza como resumen de la secuencia. Por ello, resulta coherente que numerosas relaciones de atención asociadas a este token aparezcan como relevantes en los métodos multivariantes.

La comparación con SHAP introduce un nivel de interpretación diferente. Mientras que oMEDA-PCA, PLS-DA y ASCA trabajan sobre variables internas de atención, SHAP analiza directamente la contribución de los tokens de entrada sobre la predicción final del modelo BERT. Por este motivo, sus resultados se aproximan más a una explicación léxica de la decisión. En las gráficas individuales, SHAP destaca con claridad los términos que modifican la polaridad de la frase, como *charming* en la frase positiva o *boring* en la frase negativa. Del mismo modo, en el análisis global, los tokens más relevantes según SHAP son mayoritariamente palabras con polaridad explícita, como

disliked, hated, dreadful, painful, boring, poor, dull, bad, unpleasant, awful, annoying o *stale*.

En el caso de oMEDA-PCA, PLS-DA y ASCA, los rankings globales también destacan numerosas palabras con carga sentimental clara, como *dumb, bad, stale, good, liked, warm, hated, smart, fresh, loved* o *dull*. Esto indica que las variables de atención asociadas a términos relevantes para la polaridad participan de forma importante en la estructura multivariante del modelo.

Aun así, la interpretación no es idéntica a la de SHAP. En los métodos multivariantes también aparecen algunos tokens menos directamente sentimentales, como *worked, looked, natural, this, it* o *soundtrack*. Estos términos no deben entenderse necesariamente como palabras con polaridad propia, sino como elementos que intervienen en relaciones internas de atención relevantes para diferenciar las clases. Por tanto, SHAP ofrece una explicación más directa de la predicción a nivel de palabra, mientras que oMEDA-PCA, PLS-DA y ASCA permiten analizar cómo se distribuye esa información dentro de las matrices de atención del modelo.

Esta distinción permite separar dos niveles de explicabilidad. El primer nivel es léxico y está directamente relacionado con la salida del modelo: qué palabras empujan la predicción hacia la clase positiva o negativa. SHAP se sitúa en este nivel. El segundo nivel es estructural y se refiere a cómo BERT organiza internamente la información mediante relaciones de atención distribuidas entre capas, cabezas y tokens. oMEDA, PLS-DA y ASCA pertenecen a este segundo nivel. Ambos niveles son necesarios para obtener una interpretación más completa del modelo.

Los resultados globales por tokens refuerzan esta idea. En SHAP, la relevancia se concentra en tokens con contenido sentimental claro. En los métodos multivariantes, la importancia aparece más repartida y puede incluir palabras sin polaridad evidente. Esto indica que BERT no basa su funcionamiento únicamente en palabras aisladas con carga positiva o negativa, sino que construye representaciones contextuales donde también intervienen elementos gramaticales, posiciones especiales y relaciones internas entre tokens. La clasificación de sentimiento no se refleja solo en el vocabulario, sino también en la forma en que el modelo organiza la información a través de la atención.

También es importante destacar que los resultados basados en atención no deben interpretarse como explicaciones causales directas. Una relación de atención elevada, o una variable importante según oMEDA, PLS-DA o ASCA, indica una asociación relevante dentro del análisis realizado, pero no demuestra por sí sola que dicha relación sea la causa única de la decisión del modelo. Esta cautela es especialmente importante en modelos Transformer, donde la información se transforma de manera no lineal a lo largo de múltiples capas. Por ello, la comparación con SHAP resulta útil como contraste, ya que permite distinguir entre importancia interna de la atención e

influencia directa sobre la predicción.

En conjunto, el capítulo muestra que cada técnica aporta una parte distinta de la interpretación. PCA permite estudiar la geometría global de las observaciones y comprobar si existe una estructura latente en las matrices de atención. oMEDA permite volver al espacio original de variables e identificar qué relaciones de atención contribuyen al contraste entre frases positivas y negativas. PLS-DA confirma, desde un enfoque supervisado, que las variables de atención contienen información útil para discriminar entre clases. ASCA permite analizar el efecto del diseño experimental sobre la matriz completa de atenciones, separando la variabilidad atribuible al factor clase. Finalmente, SHAP proporciona una explicación directa a nivel de token sobre la salida final del clasificador.

La integración de estos resultados permite concluir que la información relacionada con la polaridad no está localizada en una única palabra, componente, cabeza o capa. Las palabras con carga sentimental son importantes para la decisión final, como muestra SHAP, pero las matrices de atención revelan una organización más distribuida, donde intervienen posiciones estructurales y relaciones internas a lo largo del modelo. Esta conclusión es coherente con el funcionamiento de BERT como modelo contextual: el significado de una palabra y su influencia en la clasificación dependen del conjunto de la secuencia y de las representaciones construidas progresivamente en las capas del Transformer.

Por último, los resultados deben entenderse dentro de las limitaciones del estudio. El conjunto experimental está formado por un número reducido de frases y ha sido diseñado de forma controlada, con pares positivo-negativo de estructura similar. Esta configuración resulta útil para explorar el comportamiento del modelo y comparar métodos de explicación, pero no permite extraer conclusiones definitivas sobre el funcionamiento general de BERT en cualquier contexto lingüístico. Del mismo modo, los resultados de PLS-DA y ASCA deben interpretarse como evidencias exploratorias, no como validaciones estadísticas concluyentes sobre un corpus amplio.

Aun con estas limitaciones, el análisis realizado demuestra que la combinación de técnicas multivariantes y métodos de atribución permite estudiar el comportamiento interno de BERT desde una perspectiva más rica que la simple observación de la etiqueta predicha. El modelo no solo clasifica correctamente las frases, sino que sus matrices de atención contienen patrones estructurados relacionados con la polaridad. La principal aportación del capítulo es mostrar que dichos patrones pueden analizarse desde distintos niveles: global, mediante PCA; variable a variable, mediante oMEDA y PLS-DA; por factores experimentales, mediante ASCA; y a nivel léxico de predicción, mediante SHAP.

En definitiva, la explicabilidad de un modelo BERT requiere combinar he-

ramientas complementarias. Ninguna de las técnicas utilizadas proporciona por sí sola una explicación completa, pero la lectura conjunta de todas ellas permite obtener una interpretación más sólida y matizada. SHAP muestra qué palabras influyen directamente en la predicción; los métodos basados en atención muestran cómo se organiza internamente la información; y los análisis multivariantes permiten localizar qué capas, cabezas y relaciones de atención participan con mayor intensidad en la diferenciación entre frases positivas y negativas. Esta combinación constituye una metodología útil para explorar modelos Transformer aplicados a clasificación de sentimiento y abre la puerta a estudios posteriores con conjuntos de frases más amplios, diseños factoriales más complejos y comparaciones entre versiones comprimidas o ajustadas del modelo.

Capítulo 9

Conclusiones y líneas de trabajo futuro

9.1. Conclusiones

El presente Trabajo Fin de Grado ha tenido como objetivo principal estudiar el papel de la Inteligencia Artificial Explicativa en el análisis de modelos complejos, prestando especial atención a los modelos basados en *Transformers* y, en particular, a BERT. A lo largo del trabajo se ha abordado tanto una parte teórica, centrada en la revisión de métodos y enfoques de explicabilidad, como una parte práctica, basada en una prueba de concepto aplicada a clasificación de sentimiento.

La primera conclusión que puede extraerse es que la explicabilidad se ha convertido en un elemento esencial dentro del desarrollo actual de la inteligencia artificial. Los modelos modernos son capaces de alcanzar resultados muy precisos en tareas complejas, pero esa precisión no siempre viene acompañada de comprensión. En muchos casos, el modelo ofrece una respuesta correcta, pero el proceso que ha seguido para llegar a ella permanece oculto. Esta situación genera una tensión importante entre rendimiento y confianza, especialmente en aplicaciones donde no basta con obtener una predicción, sino que también es necesario comprenderla, justificarla y evaluarla críticamente.

En este sentido, la Inteligencia Artificial Explicativa no debe entenderse únicamente como un complemento técnico, sino como una condición necesaria para avanzar hacia sistemas más transparentes, responsables y fiables. La explicabilidad permite analizar el comportamiento de un modelo, detectar posibles sesgos, identificar errores, comprender patrones internos y facilitar que el usuario final pueda confiar de forma razonada en los resultados obtenidos. Por ello, la XAI no busca sustituir a los modelos complejos, sino proporcionar herramientas que permitan interpretarlos mejor.

A nivel teórico, el trabajo ha permitido revisar distintas familias de métodos explicativos, desde técnicas centradas en los datos hasta métodos *post-hoc*, modelos intrínsecamente interpretables, enfoques basados en ejemplos, métodos de atribución, visualización, teoría de juegos y explicabilidad específica para modelos *Transformer*. Esta revisión ha puesto de manifiesto que no existe una única técnica universal de explicabilidad. Cada método aporta una perspectiva distinta y presenta sus propias ventajas y limitaciones. Por tanto, la interpretación de un modelo complejo debe abordarse como un proceso plural, donde diferentes herramientas permiten observar el problema desde ángulos complementarios.

En la parte práctica se ha trabajado con un modelo BERT previamente entrenado para clasificación binaria de sentimiento. El objetivo no ha sido entrenar un nuevo modelo, sino analizar el comportamiento interno de uno ya existente. Para ello, se han extraído mapas de atención de distintas frases y se han estudiado las relaciones que el modelo establece entre los tokens de entrada. Esta aproximación ha permitido visualizar cómo BERT distribuye internamente la información de una frase y cómo distintas capas y cabezas de atención pueden presentar patrones de comportamiento diferentes.

Uno de los aspectos más relevantes del análisis es que los mapas de atención ofrecen una forma intuitiva de observar el funcionamiento interno del modelo, pero no deben interpretarse como una explicación definitiva de la predicción. Una atención elevada entre dos tokens indica que existe una relación interna destacada dentro del modelo, pero no implica necesariamente que dicha relación sea la causa directa de la decisión final. Esta idea es especialmente importante, ya que evita caer en interpretaciones simplistas de modelos profundamente complejos.

La aplicación del Análisis de Componentes Principales ha permitido reducir la dimensionalidad de los datos obtenidos a partir de las matrices de atención. Gracias a PCA ha sido posible representar las frases en un espacio de menor dimensión y estudiar si existían agrupamientos o tendencias entre frases positivas y negativas. Los resultados muestran que no aparece una separación clara y directa entre ambas clases en los primeros planos de componentes principales. Esta conclusión es significativa, ya que indica que la información interna del modelo no se organiza de forma simple ni lineal únicamente en función de la etiqueta de sentimiento.

Sin embargo, esta ausencia de separación clara no debe interpretarse como un fracaso del análisis. Al contrario, refleja una característica propia de los modelos profundos: la información relevante no suele concentrarse en una única dirección ni en una única variable, sino que aparece distribuida en múltiples niveles internos. En este caso, las matrices de atención contienen información estructurada, pero esa estructura no se reduce de manera inmediata a una división simple entre frases positivas y negativas.

La técnica oMEDA ha permitido completar esta interpretación, proyectando la diferencia entre los grupos de frases positivas y negativas hacia el espacio original de variables de atención. Este análisis ha mostrado que, aunque la mayoría de variables tienen una contribución reducida, existe un subconjunto de relaciones de atención que presenta una importancia mayor en la diferenciación entre ambos grupos. Además, al agrupar la importancia por capas y cabezas, se observa que las capas finales de BERT concentran una mayor contribución.

Este resultado resulta coherente con la forma en que suelen funcionar los modelos de lenguaje profundos. Las primeras capas tienden a capturar relaciones más básicas o locales, mientras que las capas finales integran información más abstracta y más próxima a la tarea de clasificación. En el caso de este trabajo, al tratarse de una tarea de análisis de sentimiento, parece razonable que las capas superiores tengan un papel más relevante en la construcción de la decisión final.

En conjunto, los resultados obtenidos muestran que la combinación de mapas de atención, PCA y oMEDA proporciona una metodología útil para explorar el comportamiento interno de BERT. Cada técnica aporta una perspectiva distinta: los mapas de atención permiten observar relaciones locales entre tokens, PCA ayuda a estudiar la estructura global de las observaciones y oMEDA permite identificar qué variables internas contribuyen en mayor medida a las diferencias entre grupos. La utilidad del enfoque reside precisamente en esta combinación, ya que ninguna de las técnicas por separado ofrece una explicación completa.

La incorporación de SHAP y PLS-DA ha permitido reforzar el análisis explicativo desarrollado en el trabajo. SHAP ha aportado una perspectiva centrada directamente en los tokens de entrada, mostrando qué palabras contribuyen en mayor medida a la predicción final del modelo. Esta comparación resulta especialmente útil porque permite contrastar los mapas de atención con una técnica de atribución ampliamente utilizada. Mientras que la atención muestra relaciones internas entre tokens, SHAP ofrece una explicación más directa sobre la salida del clasificador.

Por su parte, PLS-DA ha permitido repetir el análisis multivariante desde una perspectiva supervisada. A diferencia del PCA, que no utiliza las etiquetas de clase, PLS-DA incorpora la información de frases positivas y negativas durante la construcción del espacio latente. Los resultados obtenidos muestran una separación clara entre ambas clases, lo que confirma que las variables de atención extraídas de BERT contienen información útil para diferenciar la polaridad de las frases.

Uno de los resultados más relevantes es la coincidencia entre oMEDA y PLS-DA. Ambos métodos destacan una mayor importancia en las capas finales del modelo, y la comparación variable a variable muestra una relación muy

marcada entre las variables relevantes identificadas por cada técnica. Esta coherencia refuerza la interpretación de que las capas superiores de BERT concentran información más relacionada con la tarea de clasificación de sentimiento.

En conjunto, la combinación de mapas de atención, PCA, oMEDA, SHAP y PLS-DA permite analizar el modelo desde perspectivas complementarias. Los mapas de atención muestran relaciones internas entre tokens, PCA permite estudiar la estructura global de las observaciones, oMEDA identifica variables de atención relevantes, SHAP aporta una explicación directa a nivel de palabra y PLS-DA confirma de forma supervisada la capacidad discriminante de dichas variables. Esta integración de métodos constituye una aproximación más completa y robusta al análisis explicativo de modelos BERT.

Un aspecto especialmente relevante de esta integración ha sido la comparación entre la importancia por posición de token y la importancia por token real. Los métodos basados en matrices de atención, como oMEDA, PLS-DA y ASCA, permiten analizar qué posiciones de la secuencia, capas, cabezas y relaciones internas tienen mayor relevancia dentro del modelo. Sin embargo, esta importancia es principalmente estructural, ya que procede de las variables de atención y no directamente del significado individual de cada palabra.

En cambio, SHAP proporciona una interpretación más cercana al contenido lingüístico de la frase, al asignar importancia directamente a los tokens reales de entrada. Esta diferencia ha permitido distinguir dos niveles de análisis complementarios: por un lado, la importancia interna de las posiciones y relaciones de atención; por otro, la influencia directa de determinadas palabras sobre la predicción final del clasificador.

La incorporación de ASCA ha permitido añadir una perspectiva adicional al análisis explicativo realizado. A diferencia de PCA, que estudia la variabilidad global sin tener en cuenta las etiquetas, y de PLS-DA, que busca una separación supervisada entre clases, ASCA permite descomponer la variabilidad de las matrices de atención en función de los factores experimentales definidos. En este trabajo, el factor principal analizado ha sido la clase de sentimiento, diferenciando entre frases positivas y negativas.

Los resultados obtenidos muestran que el factor clase tiene un efecto apreciable sobre las matrices de atención del modelo BERT. La representación asociada a dicho factor muestra una separación clara entre frases positivas y negativas, lo que indica que la polaridad de la frase no solo se refleja en la salida final del clasificador, sino también en los patrones internos de atención.

Uno de los aspectos más relevantes es que ASCA vuelve a destacar la importancia de las capas finales del modelo. Esta conclusión coincide con los resultados obtenidos mediante oMEDA y PLS-DA, reforzando la idea de que

las capas superiores de BERT concentran información más vinculada a la tarea de clasificación de sentimiento. La repetición de esta tendencia en métodos distintos aporta mayor solidez a la interpretación general del trabajo.

Además, ASCA ha permitido analizar la importancia desde otras perspectivas, como la cabeza de atención, el token origen, el token destino y las relaciones entre pares de tokens. Esto ha enriquecido el análisis, ya que no solo permite localizar capas relevantes, sino también estudiar cómo se distribuye el efecto de clase entre las distintas dimensiones internas del modelo.

En conjunto, la incorporación de ASCA refuerza la idea central de este Trabajo Fin de Grado: la explicabilidad de modelos complejos como BERT no puede depender de una única técnica. Los mapas de atención, PCA, oMEDA, SHAP, PLS-DA y ASCA ofrecen perspectivas complementarias. Cada una permite observar un aspecto diferente del comportamiento interno del modelo, y solo mediante su combinación es posible construir una interpretación más rica, prudente y fundamentada.

La comparación global entre los cuatro métodos ha mostrado que no todos explican el modelo desde el mismo nivel. oMEDA, PLS-DA y ASCA presentan una mayor coherencia entre sí porque trabajan sobre variables derivadas de las matrices de atención. SHAP, por su parte, ofrece una lectura más próxima a la decisión final del modelo y destaca principalmente palabras con carga semántica o sentimental. Esta diferencia no supone una contradicción, sino una confirmación de que la explicabilidad de BERT requiere combinar herramientas que analicen tanto su funcionamiento interno como el efecto de los tokens sobre la salida final.

En este sentido, una de las conclusiones más importantes del trabajo es que la importancia de una palabra dentro del modelo no puede entenderse desde una única perspectiva. Una palabra puede ser relevante porque influye directamente en la predicción, como muestra SHAP, o porque aparece en una posición que participa de forma destacada en las relaciones internas de atención, como muestran oMEDA, PLS-DA y ASCA. La integración de ambos puntos de vista permite obtener una interpretación más completa y menos simplista del comportamiento del modelo.

A pesar de ello, los resultados deben interpretarse con prudencia. El conjunto experimental utilizado es reducido y ha sido construido de forma controlada, por lo que las conclusiones no deben entenderse como una caracterización general definitiva del comportamiento de BERT. Sin embargo, el trabajo demuestra que la combinación de varias técnicas explicativas permite obtener una visión más rica y razonada del funcionamiento interno de un modelo complejo.

No obstante, el trabajo también ha puesto de manifiesto varias limitaciones. En primer lugar, el conjunto experimental utilizado es reducido y ha sido

generado de forma controlada, por lo que los resultados deben entenderse como una prueba de concepto y no como una caracterización general del comportamiento de BERT. En segundo lugar, las técnicas empleadas tienen una naturaleza exploratoria, por lo que permiten detectar patrones y asociaciones, pero no demostrar causalidad. En tercer lugar, el análisis se ha centrado en un único modelo y en una única tarea, por lo que sería necesario ampliar el estudio para obtener conclusiones más robustas.

A pesar de estas limitaciones, el trabajo cumple su objetivo principal: mostrar cómo es posible aproximarse al funcionamiento interno de un modelo complejo mediante herramientas explicativas y análisis multivariante. La aportación principal no reside en obtener una explicación absoluta del modelo, sino en demostrar que es posible construir un procedimiento ordenado para observar, analizar y reflexionar sobre sus mecanismos internos.

Desde una perspectiva más amplia, este trabajo refuerza una idea fundamental: explicar un modelo de inteligencia artificial no significa simplificarlo hasta eliminar su complejidad, sino aprender a dialogar con esa complejidad. Los modelos como BERT no toman decisiones a partir de una única regla visible, sino mediante la interacción de muchas representaciones internas. Por ello, la explicabilidad debe entenderse como un proceso gradual, que combina visualización, análisis estadístico, conocimiento del modelo y prudencia interpretativa.

En definitiva, el desarrollo de este Trabajo Fin de Grado ha permitido comprender que la inteligencia artificial explicativa no solo es una herramienta técnica, sino también una forma de acercar los modelos a las personas. En un contexto donde la inteligencia artificial tiene cada vez más presencia en la sociedad, la capacidad de interpretar sus decisiones será tan importante como su capacidad de acertar. La confianza en estos sistemas no puede basarse únicamente en su rendimiento, sino también en la posibilidad de comprender, cuestionar y justificar sus resultados.

9.2. Líneas de trabajo futuro

A partir del trabajo desarrollado, se abren distintas líneas de continuación que permitirían ampliar, mejorar y profundizar el análisis realizado.

Una primera línea de trabajo consistiría en ampliar el conjunto experimental de frases. En este proyecto se ha trabajado con un conjunto reducido y equilibrado de 40 frases, lo que resulta adecuado para una prueba de concepto, pero limitado para extraer conclusiones generales. Una ampliación del conjunto permitiría estudiar con mayor solidez si los patrones observados se mantienen al analizar un número mayor de ejemplos, frases más largas, estructuras lingüísticas más variadas y diferentes grados de intensidad emo-

cional.

Otra línea futura sería utilizar frases procedentes directamente de datasets reales, como SST-2 u otros conjuntos de análisis de sentimiento. Esto permitiría comparar el comportamiento del modelo sobre frases generadas de forma controlada frente a frases extraídas de datos reales. De esta manera, se podría evaluar si los patrones detectados en este trabajo se conservan cuando el modelo se enfrenta a textos más diversos y menos artificialmente equilibrados.

También sería interesante comparar distintos modelos de lenguaje. En este trabajo se ha utilizado un modelo BERT ajustado para clasificación de sentimiento, pero podrían analizarse otras variantes, como RoBERTa, DistilBERT, ALBERT o modelos multilingües. Esta comparación permitiría estudiar si las diferencias observadas en capas y cabezas son propias de BERT o si aparecen también en otras arquitecturas similares.

Una línea especialmente relevante consistiría en complementar los mapas de atención con otros métodos de explicabilidad. Por ejemplo, podrían aplicarse técnicas de atribución como Integrated Gradients, LRP, o métodos basados en perturbaciones. Esto permitiría comparar si las relaciones destacadas por los mapas de atención coinciden con las características consideradas relevantes por otros métodos explicativos. Esta comparación ayudaría a obtener una interpretación más robusta y menos dependiente de una única técnica.

En relación con esta línea, también sería interesante formalizar la comparación entre métodos que trabajan sobre niveles distintos de interpretación. En este trabajo se ha observado que los métodos basados en matrices de atención, como oMEDA, PLS-DA y ASCA, proporcionan principalmente una importancia estructural asociada a posiciones, capas, cabezas y relaciones entre tokens. En cambio, métodos como SHAP ofrecen una atribución más directa sobre los tokens reales de entrada. Una posible continuación consistiría en estudiar de forma sistemática cómo se relacionan ambos niveles: la importancia interna dentro de las matrices de atención y la importancia léxica asociada a la predicción final.

Además, se podría profundizar en el análisis individual de las variables identificadas por oMEDA. En este trabajo se ha estudiado la importancia de las variables de forma global, por capas y por cabezas, pero una continuación natural sería traducir las variables más relevantes a relaciones concretas entre tokens. De este modo, se podría analizar qué palabras concretas atienden a cuáles, en qué capas ocurre y cómo cambia este comportamiento entre frases positivas y negativas.

Esta línea podría extenderse además a una traducción más precisa entre variables internas y lenguaje natural. Una continuación especialmente útil sería desarrollar un procedimiento que, para cada variable relevante, indique no so-

lo la capa, la cabeza y el par token origen–destino, sino también las palabras reales implicadas en cada frase. Esto permitiría pasar de una interpretación puramente posicional a una explicación más cercana al contenido lingüístico, manteniendo al mismo tiempo la información interna proporcionada por las matrices de atención.

Otra posible mejora sería desarrollar una herramienta visual interactiva que integre los resultados del modelo, los mapas de atención, las proyecciones PCA y las variables relevantes obtenidas mediante oMEDA. Esta herramienta facilitaría la exploración manual de los resultados y permitiría analizar cada frase de forma más intuitiva. Un sistema de este tipo podría ser útil tanto en investigación como en docencia, ya que ayudaría a comprender visualmente el comportamiento interno de los modelos *Transformer*.

9.3. Valoración de una línea futura propuesta

Entre todas las líneas de trabajo posibles, una de las más interesantes sería ampliar el análisis hacia una metodología comparativa entre varios métodos de explicabilidad. En concreto, se propone como línea futura aplicar, sobre el mismo conjunto de frases y el mismo modelo BERT, técnicas como mapas de atención, Integrated Gradients o LRP, comparando posteriormente los resultados obtenidos.

Esta línea resulta especialmente valiosa porque permitiría evaluar hasta qué punto diferentes métodos explicativos coinciden o discrepan al señalar las partes importantes de una frase. Si varios métodos independientes destacan los mismos tokens, capas o relaciones internas, la interpretación obtenida tendría mayor solidez. En cambio, si cada método señala elementos distintos, se pondría de manifiesto la necesidad de interpretar las explicaciones con cautela y de no depender de una única técnica.

Desde el punto de vista académico, esta ampliación permitiría pasar de una prueba de concepto centrada en una metodología concreta a un estudio comparativo más completo sobre explicabilidad en modelos de lenguaje. Además, permitiría reforzar una de las ideas principales del trabajo: la explicabilidad no debe entenderse como una respuesta única, sino como un proceso de análisis en el que distintas herramientas proporcionan evidencias complementarias.

La propia evolución de este trabajo refuerza el interés de esta línea futura. La incorporación de SHAP, PLS-DA y ASCA ha mostrado que cada técnica aporta una lectura diferente del modelo: SHAP permite interpretar la predicción desde los tokens reales, PLS-DA valida de forma supervisada la capacidad discriminante de las variables de atención, y ASCA permite estudiar el efecto del factor clase sobre la estructura completa de las atenciones.

Esta experiencia confirma que el análisis comparativo no es únicamente una ampliación posible, sino una vía natural para seguir profundizando en la explicabilidad de modelos Transformer.

Desde el punto de vista práctico, esta línea también sería viable. El flujo de trabajo ya desarrollado en este TFG proporciona una base sólida: existe un modelo seleccionado, un conjunto de frases, un procedimiento de extracción de atenciones y una metodología de análisis en Python y MATLAB. Por tanto, la incorporación de nuevos métodos explicativos podría realizarse como una extensión natural del trabajo, reutilizando gran parte de la estructura ya creada.

Además, una continuación de esta línea permitiría definir criterios más claros para comparar explicaciones. No bastaría con observar visualmente si dos métodos destacan zonas similares, sino que podrían emplearse medidas de coincidencia entre rankings de tokens, capas o variables relevantes. De esta forma, el análisis pasaría de una comparación principalmente cualitativa a una evaluación más sistemática de la coherencia entre métodos explicativos.

En definitiva, el trabajo futuro más prometedor consistiría en ampliar el estudio hacia un marco comparativo de explicabilidad para modelos BERT. Esta continuación permitiría obtener conclusiones más robustas, evaluar la fiabilidad de los mapas de atención frente a otros métodos y avanzar hacia una interpretación más completa del comportamiento interno de los modelos *Transformer*.

Apéndice A

Frases utilizadas en el conjunto experimental

En este anexo se recogen las frases utilizadas en el conjunto experimental del caso de estudio. El conjunto está formado por 40 frases en inglés, divididas de forma equilibrada en 20 frases positivas y 20 frases negativas. Estas frases fueron empleadas como entrada del modelo BERT para la extracción de mapas de atención y el posterior análisis mediante PCA, oMEDA, SHAP y PLS-DA.

Cuadro A.1: Frases positivas y negativas utilizadas en el conjunto experimental.

Nº	Frase positiva	Frase negativa
1	The movie was very good.	The movie was very bad.
2	This film was really nice.	This film was really awful.
3	I found the story charming.	I found the story boring.
4	The acting felt quite natural.	The acting felt quite wooden.
5	This movie looked very beautiful.	This movie looked very cheap.
6	The ending was truly satisfying.	The ending was truly annoying.
7	I enjoyed this film today.	I disliked this film today.
8	The plot felt warm throughout.	The plot felt weak throughout.
9	This was a lovely movie.	This was a dreadful movie.
10	The cast gave strong performances.	The cast gave poor performances.
11	I liked the final scene.	I hated the final scene.
12	This film felt deeply moving.	This film felt deeply empty.
13	The soundtrack was very pleasant.	The soundtrack was very unpleasant.
14	The script was smart overall.	The script was dumb overall.
15	I found it quite enjoyable.	I found it quite painful.
16	The movie felt fresh today.	The movie felt stale today.

Nº	Frase positiva	Frase negativa
17	This story was very warm.	This story was very dull.
18	The pacing worked very well.	The pacing worked very poorly.
19	I loved this movie completely.	I hated this movie completely.
20	The dialogue felt sharp throughout.	The dialogue felt flat throughout.

Bibliografía

- [1] T. Jiang, J. L. Gradus y A. J. Rosellini, «Supervised machine learning: a brief primer,» *Behavior therapy*, vol. 51, n.º 5, págs. 675-687, 2020.
- [2] X. Liu et al., «Self-supervised learning: Generative or contrastive,» *IEEE transactions on knowledge and data engineering*, vol. 35, n.º 1, págs. 857-876, 2021.
- [3] R. Xu y D. Wunsch, «Survey of clustering algorithms,» *IEEE Transactions on neural networks*, vol. 16, n.º 3, págs. 645-678, 2005.
- [4] D. Maulud y A. M. Abdulazeez, «A review on linear regression comprehensive in machine learning,» *Journal of applied science and technology trends*, vol. 1, n.º 2, págs. 140-147, 2020.
- [5] E. Christodoulou, J. Ma, G. S. Collins, E. W. Steyerberg, J. Y. Verbakel y B. Van Calster, «A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models,» *Journal of clinical epidemiology*, vol. 110, págs. 12-22, 2019.
- [6] M. Kubat, *An introduction to machine learning*. Springer, 2017.
- [7] L. P. Kaelbling, M. L. Littman y A. W. Moore, «Reinforcement learning: A survey,» *Journal of artificial intelligence research*, vol. 4, págs. 237-285, 1996.
- [8] S. Dong, P. Wang y K. Abbas, «A survey on deep learning and its applications,» *Computer Science Review*, vol. 40, pág. 100 379, 2021.
- [9] S. Khan, M. Naseer, M. Hayat, S. W. Zamir, F. S. Khan y M. Shah, «Transformers in vision: A survey,» *ACM computing surveys (CSUR)*, vol. 54, n.º 10s, págs. 1-41, 2022.
- [10] S. Minaee et al., «Large language models: A survey,» *arXiv preprint arXiv:2402.06196*, 2024.
- [11] F. M. Shiri, T. Perumal, N. Mustapha y R. Mohamed, «A comprehensive overview and comparative analysis on deep learning models: CNN, RNN, LSTM, GRU,» *arXiv preprint arXiv:2305.17473*, 2023.

- [12] R. Dey y F. M. Salem, «Gate-variants of gated recurrent unit (GRU) neural networks,» en *2017 IEEE 60th international midwest symposium on circuits and systems (MWSCAS)*, IEEE, 2017, págs. 1597-1600.
- [13] S. Ren, K. He, R. Girshick y J. Sun, «Faster r-cnn: Towards real-time object detection with region proposal networks,» *Advances in neural information processing systems*, vol. 28, 2015.
- [14] J. Hosang, R. Benenson y B. Schiele, «Learning non-maximum suppression,» en *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, págs. 4507-4515.
- [15] T. Shehzadi, K. A. Hashmi, M. Liwicki, D. Stricker y M. Z. Afzal, «Object detection with transformers: A review,» *Sensors*, vol. 25, n.º 19, pág. 6025, 2025.
- [16] Y. Fang et al., «You only look at one sequence: Rethinking transformer in vision through object detection,» *Advances in Neural Information Processing Systems*, vol. 34, págs. 26 183-26 197, 2021.
- [17] W. Wang et al., «Pyramid vision transformer: A versatile backbone for dense prediction without convolutions,» en *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, págs. 568-578.
- [18] J. Yu et al., «Vector-quantized image modeling with improved vqgan,» *arXiv preprint arXiv:2110.04627*, 2021.
- [19] M. Ding et al., «Cogview: Mastering text-to-image generation via transformers,» *Advances in neural information processing systems*, vol. 34, págs. 19 822-19 835, 2021.
- [20] J. Lu, D. Batra, D. Parikh y S. Lee, «Vilbert: Pretraining task-agnostic visiolinguistic representations for vision-and-language tasks,» *Advances in neural information processing systems*, vol. 32, 2019.
- [21] H. Tan y M. Bansal, «Lxmert: Learning cross-modality encoder representations from transformers,» en *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)*, 2019, págs. 5100-5111.
- [22] X. Li, S. Li, S. Song, J. Yang, J. Ma y J. Yu, «Pmet: Precise model editing in a transformer,» en *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, 2024, págs. 18 564-18 572.
- [23] Y. Li et al., «Supervision exists everywhere: A data efficient contrastive language-image pre-training paradigm,» *arXiv preprint arXiv:2110.05208*, 2021.
- [24] S. Ali et al., «Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence,» *Information fusion*, vol. 99, pág. 101 805, 2023.

- [25] J. Matejka y G. Fitzmaurice, «Same stats, different graphs: generating datasets with varied appearance and identical statistics through simulated annealing,» en *Proceedings of the 2017 CHI conference on human factors in computing systems*, 2017, págs. 1290-1294.
- [26] J. Heinrich y D. Weiskopf, «State of the Art of Parallel Coordinates.,» *Eurographics (state of the art reports)*, págs. 95-116, 2013.
- [27] D. Smilkov, N. Thorat, C. Nicholson, E. Reif, F. B. Viégas y M. Wattenberg, «Embedding Projector: Interactive Visualization and Interpretation of Embeddings,» *arXiv preprint arXiv:1611.05469*, 2016.
- [28] X. Wang, H. Chen, S. Tang, Z. Wu y W. Zhu, «Disentangled representation learning,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, n.º 12, págs. 9677-9696, 2024.
- [29] T. Gebru et al., «Datasheets for Datasets,» *Communications of the ACM*, vol. 64, n.º 12, págs. 86-92, 2021. DOI: 10.1145/3458723.
- [30] E. M. Bender y B. Friedman, «Data Statements for Natural Language Processing: Toward Mitigating System Bias and Enabling Better Science,» *Transactions of the Association for Computational Linguistics*, vol. 6, págs. 587-604, 2018. DOI: 10.1162/tac1_a_00041.
- [31] M. W. Craven y J. W. Shavlik, «Extracting Tree-Structured Representations of Trained Networks,» en *Advances in Neural Information Processing Systems 8*, MIT Press, 1996, págs. 24-30.
- [32] M. Raissi, P. Perdikaris y G. E. Karniadakis, «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,» *Journal of Computational Physics*, vol. 378, págs. 686-707, 2019. DOI: 10.1016/j.jcp.2018.10.045.
- [33] K. Kashinath, M. Mustafa, A. Albert, J. Wu, C. Jiang et al., «Physics-informed machine learning: case studies for weather and climate modelling,» *Philosophical Transactions of the Royal Society A*, vol. 379, n.º 2194, págs. 20200093, 2021. DOI: 10.1098/rsta.2020.0093.
- [34] Y. Zhu, R.-H. Zhang, J. N. Moum, F. Wang, X. Li y D. Li, «Physics-informed deep-learning parameterization of ocean vertical mixing improves climate simulations,» *National Science Review*, vol. 9, n.º 8, nwac044, 2022. DOI: 10.1093/nsr/nwac044.
- [35] P. Bhasme, J. Vagadiya y U. Bhatia, «Enhancing predictive skills in physically-consistent way: Physics Informed Machine Learning for hydrological processes,» *Journal of Hydrology*, vol. 615, págs. 128618, 2022. DOI: 10.1016/j.jhydrol.2022.128618.

- [36] V. Steidl, J. L. Bamber y X. X. Zhu, «Physics-aware machine learning for glacier ice thickness estimation: a case study for Svalbard,» *The Cryosphere*, vol. 19, págs. 645-661, 2025. DOI: 10.5194/tc-19-645-2025.
- [37] G. Cheng, M. Krishna y M. Morlighem, «A Python library for solving ice sheet modeling problems using physics-informed neural networks, PINNICLE v1.0,» *Geoscientific Model Development*, vol. 18, págs. 5311-5327, 2025. DOI: 10.5194/gmd-18-5311-2025.
- [38] Z. C. Lipton, «The Mythos of Model Interpretability,» *Queue*, vol. 16, n.º 3, págs. 31-57, 2018. DOI: 10.1145/3236386.3241340.
- [39] A. Barredo Arrieta et al., «Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI,» *Information Fusion*, vol. 58, págs. 82-115, 2020. DOI: 10.1016/j.inffus.2019.12.012.
- [40] N. Papernot y P. McDaniel, «Deep k-Nearest Neighbors: Towards Confidential, Interpretable and Robust Deep Learning,» *arXiv preprint arXiv:1803.04765*, 2018.
- [41] D. Card, M. Zhang y N. A. Smith, «Deep Weighted Averaging Classifiers,» en *Proceedings of the Conference on Fairness, Accountability, and Transparency*, 2019, págs. 369-378. DOI: 10.1145/3287560.3287595.
- [42] D. Alvarez-Melis y T. S. Jaakkola, «Towards Robust Interpretability with Self-Explaining Neural Networks,» en *Advances in Neural Information Processing Systems*, 2018.
- [43] W. Brendel y M. Bethge, «Approximating CNNs with Bag-of-local-Features Models Works Surprisingly Well on ImageNet,» en *International Conference on Learning Representations*, 2019.
- [44] D. Yu, B. Yang, D. Liu, H. Wang y S. Pan, «A Survey on Neural-Symbolic Learning Systems,» *Neural Networks*, vol. 166, págs. 105-126, 2023. DOI: 10.1016/j.neunet.2023.06.028.
- [45] H. Jaeger, «Conceptors: An Easy Introduction,» *arXiv preprint arXiv:1406.2671*, 2014.
- [46] G. Ciravegna et al., «Logic Explained Networks,» *Artificial Intelligence*, vol. 314, pág. 103822, 2023. DOI: 10.1016/j.artint.2022.103822.
- [47] T. Lesort, N. Díaz-Rodríguez, J.-F. Goudou y D. Filliat, «State Representation Learning for Control: An Overview,» *Neural Networks*, vol. 108, págs. 379-392, 2018. DOI: 10.1016/j.neunet.2018.07.006.

- [48] I. C. Kaadoud, A. Bennetot, B. Mawhin, V. Charisi y N. Díaz-Rodríguez, «Explaining Aha! Moments in Artificial Agents through IKE-XAI: Implicit Knowledge Extraction for eXplainable AI,» *Neural Networks*, vol. 155, págs. 95-118, 2022. DOI: 10.1016/j.neunet.2022.08.007.
- [49] N. Díaz-Rodríguez et al., «Gender and Sex Bias in COVID-19 Epidemiological Data through the Lenses of Causality,» *Information Processing & Management*, vol. 60, n.º 4, pág. 103 276, 2023. DOI: 10.1016/j.ipm.2023.103276.
- [50] M. Hind et al., «TED: Teaching AI to Explain its Decisions,» en *Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society*, Association for Computing Machinery, 2019, págs. 123-129. DOI: 10.1145/3306618.3314273.
- [51] L. A. Hendricks, Z. Akata, M. Rohrbach, J. Donahue, B. Schiele y T. Darrell, «Generating Visual Explanations,» en *Computer Vision – ECCV 2016*, Springer, 2016, págs. 3-19. DOI: 10.1007/978-3-319-46493-0_1.
- [52] T. Lei, R. Barzilay y T. Jaakkola, «Rationalizing Neural Predictions,» en *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, Association for Computational Linguistics, 2016, págs. 107-117. DOI: 10.18653/v1/D16-1011.
- [53] D. H. Park et al., «Multimodal Explanations: Justifying Decisions and Pointing to the Evidence,» en *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, págs. 8779-8788. DOI: 10.1109/CVPR.2018.00915.
- [54] A. Vaswani et al., «Attention Is All You Need,» en *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [55] M. Wu, M. C. Hughes, S. Parbhoo, M. Zazzi, V. Roth y F. Doshi-Velez, «Beyond Sparsity: Tree Regularization of Deep Models for Interpretability,» en *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence*, AAAI Press, 2018, págs. 1670-1678.
- [56] A. S. Ross, M. C. Hughes y F. Doshi-Velez, «Right for the Right Reasons: Training Differentiable Models by Constraining their Explanations,» en *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence*, 2017, págs. 2662-2670. DOI: 10.24963/ijcai.2017/371.
- [57] R. Ghaeini, X. Fern, H. Shahbazi y P. Tadepalli, «Saliency Learning: Teaching the Model Where to Pay Attention,» en *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*, Association for Computational Linguistics, 2019, págs. 4016-4025. DOI: 10.18653/v1/N19-1404.

- [58] G. Montavon, S. Bach, A. Binder, W. Samek y K.-R. Müller, «Explaining NonLinear Classification Decisions with Deep Taylor Decomposition,» *Pattern Recognition*, vol. 65, págs. 211-222, 2017. DOI: 10.1016/j.patcog.2016.11.008.
- [59] M. T. Ribeiro, S. Singh y C. Guestrin, «“Why Should I Trust You?”: Explaining the Predictions of Any Classifier,» en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Association for Computing Machinery, 2016, págs. 1135-1144. DOI: 10.1145/2939672.2939778.
- [60] R. Guidotti, A. Monreale, S. Ruggieri, D. Pedreschi, F. Turini y F. Giannotti, «Local Rule-Based Explanations of Black Box Decision Systems,» *arXiv preprint arXiv:1805.10820*, 2018.
- [61] N. El Bekri, J. Kling y M. F. Huber, «A Study on Trust in Black Box Models and Post-hoc Explanations,» en *14th International Conference on Soft Computing Models in Industrial and Environmental Applications (SOCO 2019)*, ép. Advances in Intelligent Systems and Computing, vol. 950, Springer, 2019, págs. 35-46. DOI: 10.1007/978-3-030-20055-8_4.
- [62] I. Ahern, A. Noack, L. Guzman-Nateras, D. Dou, B. Li y J. Huan, «NormLime: A New Feature Importance Metric for Explaining Deep Neural Networks,» *arXiv preprint arXiv:1909.04200*, 2019.
- [63] M. T. Ribeiro, S. Singh y C. Guestrin, «Anchors: High-Precision Model-Agnostic Explanations,» en *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence*, 2018, págs. 1527-1535. DOI: 10.1609/aaai.v32i1.11491.
- [64] M. D. Zeiler y R. Fergus, «Visualizing and Understanding Convolutional Networks,» en *Computer Vision – ECCV 2014*, Springer, 2014, págs. 818-833. DOI: 10.1007/978-3-319-10590-1_53.
- [65] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh y D. Batra, «Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization,» en *2017 IEEE International Conference on Computer Vision*, 2017, págs. 618-626. DOI: 10.1109/ICCV.2017.74.
- [66] J. T. Springenberg, A. Dosovitskiy, T. Brox y M. Riedmiller, «Striving for Simplicity: The All Convolutional Net,» en *International Conference on Learning Representations Workshop*, 2015.
- [67] H. Wang et al., «Score-CAM: Score-Weighted Visual Explanations for Convolutional Neural Networks,» en *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2020, págs. 111-119. DOI: 10.1109/CVPRW50498.2020.00020.

- [68] K. Simonyan, A. Vedaldi y A. Zisserman, «Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps,» en *Workshop at International Conference on Learning Representations*, 2014.
- [69] D. Smilkov, N. Thorat, B. Kim, F. Viégas y M. Wattenberg, «SmoothGrad: Removing Noise by Adding Noise,» *arXiv preprint arXiv:1706.03825*, 2017.
- [70] M. Sundararajan, A. Taly y Q. Yan, «Axiomatic Attribution for Deep Networks,» en *Proceedings of the 34th International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 70, PMLR, 2017, págs. 3319-3328.
- [71] S. Bach, A. Binder, G. Montavon, F. Klauschen, K.-R. Müller y W. Samek, «On Pixel-Wise Explanations for Non-Linear Classifier Decisions by Layer-Wise Relevance Propagation,» *PLOS ONE*, vol. 10, n.º 7, e0130140, 2015. DOI: 10.1371/journal.pone.0130140.
- [72] L. Kaufman y P. J. Rousseeuw, «Clustering by Means of Medoids,» en *Statistical Data Analysis Based on the L1-Norm and Related Methods*, North-Holland, 1987, págs. 405-416.
- [73] B. Kim, R. Khanna y O. O. Koyejo, «Examples Are Not Enough, Learn to Criticize! Criticism for Interpretability,» en *Advances in Neural Information Processing Systems*, vol. 29, 2016.
- [74] I. J. Goodfellow, J. Shlens y C. Szegedy, «Explaining and Harnessing Adversarial Examples,» en *International Conference on Learning Representations*, 2015.
- [75] A. Aamodt y E. Plaza, «Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches,» *AI Communications*, vol. 7, n.º 1, págs. 39-59, 1994.
- [76] T. Miller, «Contrastive Explanation: A Structural-Model Approach,» *The Knowledge Engineering Review*, vol. 36, e14, 2021. DOI: 10.1017/S0269888921000102.
- [77] L. S. Shapley, «Stochastic games,» *Proceedings of the national academy of sciences*, vol. 39, n.º 10, págs. 1095-1100, 1953.
- [78] S. M. Lundberg y S.-I. Lee, «A Unified Approach to Interpreting Model Predictions,» en *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [79] S. M. Lundberg et al., «From Local Explanations to Global Understanding with Explainable AI for Trees,» *Nature Machine Intelligence*, vol. 2, págs. 56-67, 2020. DOI: 10.1038/s42256-019-0138-9.

- [80] J. Lei, M. G'Sell, A. Rinaldo, R. J. Tibshirani y L. Wasserman, «Distribution-free predictive inference for regression,» *Journal of the American Statistical Association*, vol. 113, n.º 523, págs. 1094-1111, 2018.
- [81] A. Fisher, C. Rudin y F. Dominici, «All models are wrong, but many are useful: Learning a variable's importance by studying an entire class of prediction models simultaneously,» *Journal of Machine Learning Research*, vol. 20, n.º 177, págs. 1-81, 2019.
- [82] A. Ali, T. Schnake, O. Eberle, G. Montavon, K.-R. Müller y L. Wolf, «XAI for transformers: Better explanations through conservative propagation,» en *International conference on machine learning*, PMLR, 2022, págs. 435-451.
- [83] H. Chefer, S. Gur y L. Wolf, «Transformer Interpretability Beyond Attention Visualization,» en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, págs. 782-791.
- [84] S. Serrano y N. A. Smith, «Is Attention Interpretable?» En *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, Association for Computational Linguistics, 2019, págs. 2931-2951. DOI: 10.18653/v1/P19-1282.
- [85] S. Jain y B. C. Wallace, «Attention is not Explanation,» en *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Association for Computational Linguistics, 2019, págs. 3543-3556. DOI: 10.18653/v1/N19-1357.
- [86] J. Devlin, M.-W. Chang, K. Lee y K. Toutanova, «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,» en *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, vol. 1, Association for Computational Linguistics, 2019, págs. 4171-4186. DOI: 10.18653/v1/N19-1423.
- [87] R. Socher et al., «Recursive Deep Models for Semantic Compositionality Over a Sentiment Treebank,» en *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing*, Association for Computational Linguistics, 2013, págs. 1631-1642.
- [88] A. Wang, A. Singh, J. Michael, F. Hill, O. Levy y S. R. Bowman, «GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding,» en *Proceedings of the 2018 EMNLP Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP*, Association for Computational Linguistics, 2018, págs. 353-355. DOI: 10.18653/v1/W18-5446.

-
- [89] J. Camacho, A. Pérez-Villegas, R. A. Rodríguez-Gómez y E. Jiménez-Mañas, «Multivariate Exploratory Data Analysis (MEDA) Toolbox for MATLAB,» *Chemometrics and Intelligent Laboratory Systems*, vol. 143, págs. 49-57, 2015. DOI: 10.1016/j.chemolab.2015.02.003.
- [90] A. K. Smilde, J. J. Jansen, H. C. J. Hoefsloot, R.-J. A. N. Lamers, J. van der Greef y M. E. Timmerman, «ANOVA-simultaneous component analysis (ASCA): a new tool for analyzing designed metabolomics data,» *Bioinformatics*, vol. 21, n.º 13, págs. 3043-3048, 2005. DOI: 10.1093/bioinformatics/bti476.

